



复旦大学生命科学学院

School of Life Sciences Fudan University

课程自用讲义

基因组学

2025 秋

本讲义采用知识共享署名-非商业性使用-禁止演绎 4.0 国际许可协议 (CC BY-NC-ND 4.0) 发布。您可以自由复制、学习和分发本作品，但必须注明作者姓名，且不得用于商业目的，也不得对本作品进行任何修改或改编。协议全文见：<https://creativecommons.org/licenses/by-nc-nd/4.0/>

制作：复旦 23 生科系 若许_lysis

Contents

I 绪论 人类基因组计划与基因组学	1
0.1 人类参考基因组的演化历程	1
0.1.1 中国人群泛基因组联盟 (CPC)	2
0.1.2 从二代测序 (TGS) 到三代测序 (NGS)	2
II 第一章 遗传的分子基础	3
1 DNA 的化学与生物学	3
1.1 基因组 (Genome)	4
1.2 DNA 的结构特点	4
1.2.1 核苷酸的化学极性与生物学	4
1.2.2 DNA 双螺旋链的生物学	4
2 基因组序列的结构与复杂性	5
2.0.1 同源	5
2.1 原核与真核生物基因组间的异同	6
2.1.1 C 值悖论	6
2.1.2 基因组 DNA 的序列组成	6
2.2 特殊结构基因	7
2.2.1 重叠基因 (overlapping gene)	7
2.2.2 基因内基因 (gene in gene)	7
2.2.3 反义基因 (antisense gene, 正负链均转录并且反向重叠)	8

2.2.4	间隔基因 (separate gene, 由两段非连续 DNA 组成的基因)	8
2.2.5	全新基因的产生	8
2.3	基因家族与假基因	8
2.3.1	假基因的功能	9
2.4	基因组变异的一些基础概要	9
2.4.1	假基因的特点	9
2.4.2	SNP 的遗传身份和祖先状态确定	10
2.4.3	遗传多态性的分布	11
2.4.4	基因突变的连续性	12
2.5	基因组在群体水平的结构特征	12
2.5.1	确定单倍型	13
2.5.2	单倍型的一些特征	13
III	第二章 遗传图与物理图谱	15
3	第一节 遗传图绘制	15
3.1	基因组测序	15
3.1.1	分子标记与基因组作图	15
3.1.2	座位 (locus) 与位点 (site)	16
3.2	限制性片段长度多态性 (RFLP)	16
3.2.1	特点	16
3.2.2	寻找 RFLP 标记的方法	17
3.3	重复顺序多样性 (simple sequence repeat)	17
3.3.1	寻找 SNP	17

3.3.2	检测 SSR	17
3.3.3	优势	18
3.4	单核苷酸多态性 (Single nucleotide polymorphisms)	18
3.4.1	检测 SNP	18
3.4.2	群体多态性组成频率 (PIC)	18
3.5	遗传图绘制	20
3.5.1	通过有性杂交实验遗传作图	20
3.5.2	系谱分析遗传作图	22
3.5.3	单倍体基因组生物的遗传作图	24
4	第二节 物理图绘制	24
4.1	限制性酶切位点物理图	25
4.1.1	琼脂糖包埋法	25
4.1.2	稀有切点限制酶	25
4.2	基于大分子克隆的基因组作图	26
4.2.1	脉冲交变电场电泳 (OFAGE)	26
4.2.2	均一脉冲电场电泳 (CHEF)	26
4.2.3	通过大分子 DNA 技术绘制 E. coli 基因组物理图	26
4.3	荧光原位杂交	28
4.4	序列标签位点	28
4.4.1	辐射杂种作图	28
4.4.2	基因组计划	29
4.5	图位克隆	30

IV 第三章 基础基因组测序技术 31

4.6 测序所用 DNA 聚合酶 31

4.6.1 曾经使用过的测序 DNA 聚合酶 31

4.7 一代测序 33

4.7.1 原理 33

4.8 二代测序 34

4.8.1 焦磷酸测序 (pyrosequencing) 34

4.8.2 装置 34

4.8.3 特点 35

4.8.4 技术分类 35

4.9 三代测序 37

4.9.1 单分子荧光信号测序 (SMRT) 37

4.9.2 纳米孔单分子 DNA 电流阻遏测序 37

V 第四章 全基因组测序 39

5 第一节 测序策略 39

5.1 图位法测序 (map-based sequencing) 39

5.1.1 作图测序法的物种 40

5.2 全基因组鸟枪法测序 (whole-genome shotgun sequencing) 40

5.2.1 鸟枪法测序法的物种 40

6 第二节 基因组组装 41

6.1 N50 41

6.2 间隙 42

6.3	覆盖面与测序深度	42
6.4	计算	42
6.4.1	根据读长与基因组大小计算测序覆盖面	42
6.4.2	需要的 reads 量	43
6.5	组装完成的两个阶段	43
7	第三节 全基因组测序方法	43
7.1	基因组重测序	44
7.2	短读长测序与长读长测序	44
8	第四节 人类参考宏基因组	44
8.1	尼安德特人草图序列 (2010)	45
VI	第五章 单细胞测序	46
9	第一节 单细胞 RNA 测序技术简介	46
9.1	单细胞工作流程	46
10	第二节 10X 单细胞 RNA 测序的工作原理	47
10.1	单细胞 RNA-seq	47
10.2	10x Genomics Single-Cell Multiome	47
11	第三节 单细胞 RNA 测序分析	48
11.1	细胞分析仪 (Cell Ranger)	48
11.2	质量控制 (Quality Control)	49
11.2.1	细胞周期因素对表达的影响	49
11.3	特征选择、降维与后续处理	49

11.3.1 整合	49
VII 第六章 基因组注释	51
12 第一节 搜寻基因	51
12.1 基因结构特征	51
12.1.1 开放读框 (open reading frame, ORF)	51
12.2 同源性比较	52
12.2.1 同源性 (homology)	52
12.3 功能域注释	53
12.3.1 根据协同进化进行基因注释	53
12.3.2 基因注释软件	53
13 第二节 基因命名	53
13.0.1 脊椎动物基因和蛋白质缩写规定	54
13.0.2 拟南芥基因注释 ID 编写规则	54
13.0.3 人类的基因注释分类	55
13.0.4 水稻注释基因类群的划分标准	56
14 第三节 基因功能验证	56
14.1 反向遗传学 (reverse genetics) 方法	56
VIII 第七章 基因组解剖	57
15 第一节 原核生物基因组	57
15.1 操纵子结构 (Operon)	57

15.1.1 色氨酸操纵子	57
15.2 质粒	57
15.2.1 霍乱弧菌的基因组	58
16 第二节 真核生物基因组、细胞器基因组	58
16.1 线粒体	58
16.1.1 人类线粒体基因组结构	58
16.2 高等植物叶绿体基因组	59
16.3 细胞器基因组的其他特点	59
16.3.1 多拷贝现象	59
16.3.2 核线粒体 DNA 片段	59
17 第三节 基因组研究方法进展	60
17.1 一代测序（双脱氧链终止测序，Sanger 法）	60
17.1.1 步骤	60
17.2 第二代测序技术（Next Generation Sequence, NGS）	60
17.2.1 二代测序平台	61
17.3 三代测序	61
IX 第八章 基因组的复制与进化	62
18 第一节 基因组复制模型的发现	62
19 第二节 基因组复制的过程和特点	62
19.1 基因组复制的过程	62
19.1.1 后随链合成的冈崎模型	63

19.1.2 复制体 (Replisome)	63
19.2 原核生物的基因组复制	65
19.2.1 复制子	65
19.2.2 大肠杆菌复制起始和延伸	65
19.2.3 细菌的 DNA 聚合酶	66
19.2.4 滑行夹 (sliding clamp) 及其加载机制	66
19.2.5 大肠杆菌复制终止	66
19.3 真核生物的基因组复制	66
19.3.1 高等真核生物 DNA 复制起点	67
19.3.2 人类主要 DNA 聚合酶	68
19.3.3 复制与转录冲突	68
19.3.4 DNA 末端复制问题	69
20 第三节 真核生物基因组复制的调控	70
20.0.1 前复制复合物 (pre-RC)	71
20.0.2 细胞周期检查点	71
20.0.3 细胞周期中的 DNA 损伤调控	71
21 第四节 突变与人类演化	72
21.1 基因组突变	72
21.1.1 DNA 复制差错的来源	72
21.1.2 单点突变 (Point Mutation)	72
21.1.3 结构变异 (Structural Variation)	73
21.1.4 基因组变异注释	73
21.2 DNA 复制错误与人类进化	73

21.2.1 人类基因组的演变	73
21.2.2 人类基因组多样性的产生	74
21.3 基因突变与人群致病	75
X 第九章 转录组与基因组转录调控	78
22 第一节 基因组层面的转录调控	78
22.1 rRNA 基因 (Pol I 基因)	78
22.1.1 rRNA 基因启动子剖析	79
22.2 Pol II 基因	79
22.2.1 原核生物和真核生物启动子	79
22.2.2 增强子	80
22.2.3 经典案例: 酵母半乳糖代谢基因	82
22.3 Pol III 基因	83
22.3.1 tRNA 基因的结构	83
22.3.2 转录因子	83
23 第二节 组成、加工、降解与定位	85
23.1 转录组概况	85
23.1.1 转录组与基因组	85
23.1.2 转录组的用途	86
23.1.3 基因类别与 RNA 组成	86
23.1.4 决定转录组的相关因素	86
23.2 转录组与 mRNA 编辑	87
23.2.1 mRNA 加帽	87

23.2.2	mRNA 加 polyA 尾	88
23.2.3	前体 mRNA 剪接	89
23.2.4	基因组转录面积	91
23.3	mRNA 的定位与降解	91
23.3.1	mRNA 的定位	92
23.3.2	mRNA 的降解	92
24	第三节 非编码 RNA	94
24.1	RNAi 的发现	94
24.2	植物 VIGS 技术及其运用	94
24.3	产生内源性 siRNA (nat-siRNA/ta-siRNA) 的基因组位点	95
24.4	miRNA	95
24.4.1	<i>lin-4</i> 和 <i>let-7</i> RNA 发育调控	96
24.4.2	miRNA 转录与加工	96
24.4.3	miRNA 如何调控基因表达	96
24.4.4	动物和植物 miRNA 的区别	97
24.4.5	siRNA 与 miRNA 的区别	97
24.5	piRNA (piwi-interacting RNA)	98
24.5.1	小鼠小 RNA 的结构与表达	98
24.5.2	piRNA 扩增及降解靶标的乒乓模型	98
24.5.3	piRNA 的生物学功能	98
XI	第十章 蛋白质组	99
25	第一节 蛋白质的翻译调控	99

25.1 翻译过程及其简单调节	99
25.1.1 mRNA 翻译起始复合物组装	99
25.1.2 翻译起始与延伸	99
25.2 翻译调控点	100
25.2.1 5' 帽结构与翻译整体调控	101
25.2.2 Poly(A) 与翻译调控	101
25.2.3 mRNA 5' 发夹结构与翻译的专一性调控	102
25.2.4 翻译的专一性调控因子 miRNA	104
25.2.5 uORF 与 5' 专一性翻译调控	104
25.2.6 mRNA 内部起始翻译的 IRES 顺序	105
25.2.7 Kozak 顺序与顺式调控	106
25.2.8 程序性移码	106
25.3 核糖体作图	106
25.3.1 应用	107
26 第二节 蛋白质的翻译调节	108
26.1 蛋白质的剪接	108
26.1.1 内含肽 (Intein)	108
26.1.2 蛋白质的反式剪接	108
26.2 蛋白质的折叠	109
26.2.1 蛋白质的折叠过程	109
26.3 蛋白质的修饰	110
26.3.1 蛋白质修饰的方式	111
26.3.2 蛋白质修饰的功能	111

26.3.3	蛋白质修饰的动态性和不均质性	112
26.4	蛋白质的定位	113
26.4.1	蛋白质的定位信号	113
26.4.2	蛋白质的分选与转运	113
26.5	蛋白质的降解	114
26.5.1	蛋白质降解的顺式信号	114
26.5.2	蛋白质降解系统	114
26.5.3	蛋白质泛素化过程	116
26.5.4	其他与蛋白质降解相关的机制	117
26.6	lncRNA	117
26.6.1	第一个 lncRNA	118
26.6.2	第一个功能 lncRNA	118
26.6.3	<i>Xist</i> RNA	118
26.6.4	lncRNA 的特点	118
26.6.5	lncRNA 的其他生物学功能	120
26.6.6	lncRNA 研究中的主要问题	121
XII	第十一章 表观遗传	122
27	第一节 表观遗传和表观遗传现象	122
28	第二节 DNA 甲基化	122
28.1	CpG 与甲基化	123
28.1.1	CpG 岛	123
28.2	DNA 甲基化反应	123

28.2.1 DNA 甲基化酶的结构	123
28.2.2 DNA 重新甲基化与维持甲基化	124
28.2.3 DNA 甲基化与基因沉默	124
28.2.4 5mC 影响基因表达的分子机制	124
28.3 基因组印记 (genomic imprinting)	125
28.3.1 小鼠 <i>Igf2</i> 基因印记	125
28.4 去甲基化	125
28.4.1 哺乳动物基因组程序化周期	125
28.4.2 5mC 羟甲基化介导的去甲基化机制	126
28.5 甲基化 DNA 测序	126
29 第三节 组蛋白修饰与其他表观遗传效应	126
29.1 真核生物染色体	126
29.1.1 染色质构象与基因表达	127
29.1.2 细胞的遗传记忆	127
29.2 核小体组蛋白与基因调控	128
29.2.1 组蛋白修饰位点及专一性修饰酶	128
29.2.2 组蛋白修饰的生物学意义	128
29.2.3 组蛋白密码	129
29.3 座位控制区 (locus control region, LCR)	129
29.4 绝缘子与 3D 基因组	129
29.4.1 绝缘子的三种特性	129
29.4.2 染色质环挤出模型 (loop extrusion model)	130
29.4.3 3D 基因组	130

绪论 人类基因组计划与基因组学

几个八卦：人类基因组计划的唯一中国力量就是华大基因；于 1988 年实施，原定 15 年，于 2003 年完成全部顺序测序。实际花了 13 年，于 2001 年初宣布完成草图顺序。

国际水稻基因组计划：以粳稻日本晴单株种子为材料。

早起发布的个人基因组：杨焕明院士的基因组 (*Nature*, 2008)。

人类基因组计划的遗产：一本“天书”、一张参考图（可以将测序产物映射到参考基因组上）。

基因组研究的范式转变：个体水平的线性基因组 → 群体水平的图基因组。

人类参考基因组的演化历程

HGP (Human Genome Project) 由 2001/2003 完成第一版。后面交由 GRC (Genome Reference Consortium) 维护，不断改进和更新。当时的 HGP 模型很单一，每个基因组区域只用一条代表性序列，没法体现群体多样性。

当前的模型 GRCh38 在参考基因组中引入了 ALT LOCI (备用等位区段)，ALT LOCI 不是简单的单碱基变异或小缺失，而是大片段的结构差异，比如基因区域的不同拷贝、大片段倒位、插入缺失等。因此在 GRCh38 中，一个区域可能会有多条不同版本的序列，反映群体差异。

在 GRCh38 中，70% 的序列来自 RP11 这个 BAC 文库 (African-European 混合个体)，另外 30% 来自少量其他文库。这意味着早期参考基因组带有人群偏倚：**非洲、亚洲群体的代表性不足**。经典表现为，可用于研究亚洲人、中国人的基因组数据很少，发现的疾病风险变异对亚洲人、中国人不适用。因此，有必要建立族群特异性的参考基因组。

2022 年 T2T 基因组 (Telomere-to-Telomere, 端粒至端粒的完整基因组组装) 在 *Science* 上发布。T2T 基因组主要是通过多种测序平台、高深度测序，结合多种软件方式来获得具有端粒与着丝粒的 gap-free 或 gap-less 的高质量基因组。目前版本为 T2T-CHM13, N50 值为 154.26Mbp，是 GRCh38 的三倍至多。

0.1.1 中国人群泛基因组联盟 (CPC)

为了形成我国自主可控的人类基因组资源与核心技术，并建立我国在人类基因组学领域的国际学术地位。1 期：复旦大学牵头，西安交通大学、中国医科院、中科院、南京医科大学、华大基因研究中心、四川大学华西医学中心、中南大学、西湖大学共建。

涵盖：个体基因组新序列、东亚人特异基因组变异（以 HPRC 做参照）、非参考基因序列的祖源解析（各族群基因谱系的来龙去脉及适应性演化）、建议泛基因组研究范式（是疾病易感性的遗传基础）。目标是进行复杂结构编译解析。


0.1.2 从二代测序 (TGS) 到三代测序 (NGS)

三代测序结构变异检出率相较二代测序提升了约 3 倍，且在大规模结构变异检测方面有显著优势。


第一章 遗传的分子基础

DNA 的化学与生物学

生物逻辑信息的循环：



中心法则暗示了，一旦拥有了一个物种的 DNA 序列，我们就掌握了生物的所有信息。但这是真的吗？实际上不是这样的，事情往往更加复杂：



扩展的中心法则，即表观基因组-转录组-蛋白质组网络，或三层 epi 网络：传统中心法则强调 DNA → RNA → 蛋白质的线性流动，而该模型则突出表观组学的多维修饰：DNA 的甲基化、羟甲基化等构成表观基因组（epigenome）；RNA 的 m⁶A、5' 端修饰、

多聚腺苷酸化等构成**表观转录组** (epitranscriptome); 蛋白质的磷酸化、乙酰化、SUMO 化等翻译后修饰构成**表观蛋白质组** (epiproteome)。这些修饰不仅调节分子功能, 还通过可遗传或可传递的形式 (如 iDNA、iRNA、iProtein) 影响细胞状态与跨代信息传递。图中箭头表明 DNA、RNA 与蛋白质之间存在复杂的双向反馈, 例如逆转录、RNA 结合蛋白及朊病毒介导的调控, 构成了超越经典中心法则的动态分子遗传网络。

基因组 (Genome)

一个基因组是一个单细胞或者一个组织中所有 DNA 的总和, 包含在染色体上的所有 DNA, 涵盖基因、基因间序列、重复等。或者更具体一些, 是指一个细胞器中所有的 DNA。真核生物可以有 2-3 个基因组, 包含核、线粒体与质体基因组。如果没有详细指定, 基因组通常指的是核基因组。

人类的基因组的组织形式: 3% 编码, 其余的都是垃圾 (重复的 DNA), 包含核与线粒体基因组。不同个体的基因组相似度可以达到 99.9%。

..... 甚至香蕉也惊人地与人类共享约 60% 的相同 DNA。

DNA 的结构特点

由两条具有极性的互补单链组成。两条互补单链走向相反, DNA 双螺旋大小沟槽交替排列, 碱基配对原则: A-T, C-G, A-T 配对形成 2 对氢键, C-G 配对形成 3 对氢键。每旋转一圈为 10.5 bp (碱基对)。

1.2.1 核苷酸的化学极性与生物学

DNA 的合成具有方向性, 造成前导链与延迟链复制方式的差异。DNA 的降解具有方向性, $3' \rightarrow 5'$ 和 $5' \rightarrow 3'$ 的降解由不同的酶执行。遗传密码的编排具有方向性, 只有正链才具有编码功能; 转录也具有方向性, 具体来说是 $5' \rightarrow 3'$ 。


1.2.2 DNA 双螺旋链的生物学

DNA 双螺旋互补链极性排列, 决定复制的方向; DNA 双螺旋的大小沟具有结构信息, 许多蛋白质都与大沟结合; G:C 碱基对氢键能量高于 A:T 碱基对, 解链需要更多能量, 因而不同功能的序列有特征性的碱基排列; DNA 双螺旋产生了环状 DNA 和长

链 DNA 分子的拓扑学构像变化，使复制与转录的物理过程复杂化；DNA 双螺旋的螺距 10.5 bp，转录因子结合在 DNA 双螺旋的同一侧，缠绕核小体的 DNA 序列朝向与此有关；长链 DNA 分子可以弯曲，使二维水平相离很远的序列可以互作，是表达调控的结构基础。

一、DNA 大沟

DNA 大小沟的结构信息。位于 DNA 大小沟中的碱基基团和原子空间位置，蓝色圈-H 位置为提供氢键的供体，红色圈 (-N) 为氢键受体 (与碱基或蛋白互作)。绿色圈 (-CH3) 为疏水性甲基基团，白色圈 (-H) 不提供氢键的氢原子。**DNA 双螺旋大沟提供了更多的空间结构信息。**



基因组序列的结构与复杂性

挑战：遗传、结构信息是冗余的；基因和蛋白质是亚稳态，单个基因具有多种功能。基因是一维的，但功能取决于三维结构，

2.0.1 同源

即进化上相关的基因。

直系同源/正同源 (Orthologs): 不同物种中从共同祖先的同一基因进化而来的同源基因；**旁系同源/旁同源 (Paralogs):** 由同一生物体中单个基因的复制产生的同源基因。

两者的区别：正同源基因是同源序列，旁同源基因是类似序列。同源序列比旁系同源序列更相似。同源序列存在于同一生物体中；旁系同源序列存在于不同生物体中。同源序列存在于不同生物体中；旁系同源序列存在于同一生物体中。

原核与真核生物基因组间的异同

原核生物：结构紧凑，大小多在 5Mb 以下，重复顺序与非编码顺序极少，有 DNA 转座子，无逆转座子。

真核生物：结构松弛，大小多大于 10^7 bp，拥有大量重复与非编码顺序，有 DNA 转座子和逆转座子。

2.1.1 C 值悖论

生物体的单倍体基因组所含 DNA 总量称为 C 值。生物基因组的大小同生物的复杂性及其在进化上所处的地位无关。

2.1.2 基因组 DNA 的序列组成

①**单一序列：**基因组中只有单拷贝的顺序，分散分布，人类 70%；

②**中度重序列：**拷贝数在 1-10 万，长度 50-1000bp 在基因组中分散分布，人类 13%；

③**高度重复序列：**集中分布，串接排列，拷贝数达数百万，离心时形成卫星带，人类 8%。

人类基因组组成：44% 散在分布重复序列；15% 串接重复序列；15% 单一序列；24% 内含子及调控序列；1.5% 外显子。

分子对基因的定义为：由不同的 DNA 片段共同组成完整的独立的表达单元，由调控区和转录区组成，有一个特定的表达产物，表达产物可以是 RNA 分子也可以是多肽分子。

各种真核生物中未中断和中断基因的分布。大部分基因在酵母中都是不间断的，大多数基因在果蝇中被一或二个内含子打断；大多数基因在哺乳动物中被许多内含子打断。同时**观察不同生物中基因的大小**，酵母基因很小，果蝇和哺乳动物中的基因具有分散的双峰分布，延伸到非常长的尺寸。另一点需要注意的是，编码蛋白质的外显子通常很短，但内含子通常从非常短到非常长的范围。

一、简单的真核转录单元

在真核生物中，一些 DNA 编码一个蛋白质，而其他 DNA 则编码多个蛋白质。这意味着有些基因具有简单的转录单元，而其他基因具有复杂的转录单元。

特殊结构基因

2.2.1 重叠基因 (overlapping gene)

一、 ϕ X174 基因组中的重叠基因

病毒基因组的大小受到外壳蛋白包装体积的限制，长度有限，不能编码足够数量的基因。为了维持生存，存在不少重叠基因。 ϕ X174 基因组 5386bp，共编码 11 个基因，其中有 7 个基因为重叠基因。这是第一个测序的基因组与第一个发现的重叠基因。

二、人类和老鼠核基因组的重叠基因

人类 INK4a/ARF 基因座含**两个重叠基因**：p14/ARF 和 p16/INK4a。这两个基因分别由**两个独立的启动子**调控，共享外显子 2 和 3，p14/ARF 含外显子 1 β ，p16/INK4a 含外显子 α 。

三、基因的多重可选启动子

果蝇求爱基因 (fru) 有 **4 个可选启动子**，14 个外显子。在雄性与雌性个体中启用的启动子不同，转录产物的加工也不同。有共享外显子，也有不同外显子。

2.2.2 基因内基因 (gene in gene)

①线虫内含子中独立的基因。线虫基因组中一段 30 kb 的区段中含有 8 个基因，其中 FGAM(甘氨酸胺合成酶) 基因长 25 kb，有 21 个内含子。内含子 9 中含有一个独立的基因，内含子 11 中含有 4 个独立的基因，基因内基因分别具有独立的外显子和内含子。

②人类 *NFI* 基因第 27 内含子含 3 个独立表达的基因。人类神经成纤维细胞瘤 1(neurofibromatosis1) 基因编码 GTPase 的激酶，是致癌基因 RAS 的负调控因子，长 350kb，60 个内含子，蛋白质产物 2839 aa。27 号内含子编码 3 个独立表达的基因。

2.2.3 反义基因 (antisense gene, 正负链均转录并且反向重叠)

在另一条 DNA 链上转录并且与正义基因反向重叠的基因。反义基因可以通过多种方式影响正义基因的表达。

2.2.4 间隔基因 (separate gene, 由两段非连续 DNA 组成的基因)

蓝细菌 *Synechocystis* sp. PCC6803 基因组中编码 DNA 聚合酶 III α 亚基的基因 *dnaE* 由两个分开表达的区段组成, *dnaE-n* 和 *dnaE-c*, 位于两条相反的 DNA 链的不同区段。两个独立结构的区段转录后翻译成两段独立多肽链, 经反式剪接组成活性蛋白。

2.2.5 全新基因的产生

①基因进化通过“分子修整”(Francois Jacob) 进行。

②基因复制: DNA 片段的复制包括一个完整的基因, 提供了一个第二个基因拷贝, 可以发生突变, 获得专门的功能, 包括新功能化: 获得新功能; 分权化: 职能分割; 伪基因形成: 功能丧失。外显子重排: DNA 重排(间基因或内基因)将新组合的外显子结合在一起, 可以获得新的功能。

基因家族与假基因

基因家族。同一物种或不同物种中来自一个共同的祖先, 因加倍趋异而产生的一组具有相似顺序组成的基因成员: ①具有氨基酸相似性; ②具有相同的功能域。

假基因 (Pseudogenes) 是来源于功能基因但已失去该活性的 DNA 顺序: ①重复假基因: 串接排列, 具有祖先基因的组成特点, 具内含子和外显子, 突变失活; ②加工假基因: 由 RNA 反转录再插入基因组中的基因顺序, 无内含子; ③残缺假基因: 因不等交换使部分顺序缺失而失去功能的假基因; ④单一假基因: 由于点突变而失去功能的基因。

单一假基因。高等动物中均含有编码 L-古洛糖酸伽马内酯氧化酶 (GULO) 的基因, 涉及维生素 C 的合成。但在人类和黑猩猩中, GULO 基因未加倍, 但编码序列发生了终止突变, 产生无效蛋白。GULO 无效假基因一直保留在群体中未被淘汰, 通常称其为**单一假基因** (unitary pseudogenes), 可引起坏血病 (维生素 C 缺乏病)。

2.3.1 假基因的功能

①相对于原来的功能基因，失去了正常功能；②但同时可能差生了全新工农。但是同时，假基因也能转录，但功能缺失。

随着基因组数据的积累，现在已知有不少假基因仍然保持转录活性，特别是起源于重复基因的假基因和获得启动子的加工的假基因。假基因的表达产物已失去那些功能，那就去发明一眼民间技术吧。

一、基因家族的特点

同一家族中的成员有时紧密的排列在一起，成为一个基因簇，比如组蛋白基因家族就成簇地集中在第 7 号染色体长臂 3 区 2 带到 3 区 6 带区域内；更多的时候，它们却分散在同一染色体的不同部位，甚至位于不同染色体上，具有各自不同的表达调控模式，比如珠蛋白基因家族；在多基因家族中，某些成员并不产生有原功能的基因产物，这些基因称为假基因。

二、假基因可以衍生新的功能

假基因可产生新的功能：①产生反义 RNA，抑制靶基因功能；②在 RNA 水平与功能基因的 mRNA 竞争，起调控作用，如老鼠的 *Makorin1* 基因的转录；③在 DNA 水平与功能基因竞争转录因子，起抑制作用。④作为人类免疫球蛋白多样性的顺序库。

如调控人类肿瘤生长的假基因 *PTENP1*。研究发现人类和小鼠肿瘤抑制基因 *PTENP* 的表达受 miRNA 调控，*PTENP* 的重复假基因 *PTENP1* 的产物可以竞争性地结合干扰 miRNA，调控 *PTENP* 的表达，影响肿瘤的生长。

基因组变异的一些基础概要

2.4.1 假基因的特点

两层含义：①相对于原来的功能基因而言，假基因已失去正常功能。②假基因可能产生了新的功能：i. 产生反义 RNA，抑制靶基因功能；ii. 在 RNA 水平与功能基因的 mRNA 竞争，起调控作用，如老鼠的 *Makorin1* 基因的转录；iii. 在 DNA 水平与功能基因竞争转录因子，起抑制作用；iv. 作为人类免疫球蛋白多样性的顺序库。

假基因也能转录，但**功能缺失**。①随着基因组数据的积累，现在已知有不少假基因仍然保持转录活性，特别是起源于重复基因的假基因和获得启动子的加工的假基因；②假

基因的表达产物已失去原有功能，如产生残缺蛋白质。③有些假基因在进化出新的功能。

调控人类肿瘤生长的假基因 *PTENP1*。人类和小鼠肿瘤抑制基因 *PTENP* 的表达受 miRNA 调控，*PTENP* 的重复假基因 *PTENP1* 的产物可以竞争性地结合干扰 miRNA，调控 *PTENP* 的表达，影响肿瘤的生长。

一、重复假基因

串接排列，具组学基因的组成特点，先启动子、内含子与外显子，最后所有突变都将失去活性。

二、加工假基因

由 mRNA 反转录再借助于细胞的逆转录机制插入基因组中的基因顺序，无内含子结构。全基因组范围分析人类基因组发现存在 19 724 个假基因，与功能基因数目大致相当。这些假基因中约 70% 属于加工假基因 (*Genome Research* 13:2559–2567, 2006)。

三、残缺假基因

高胆固醇遗传病的机制：胆固醇是细胞必需的成分，由低密度脂蛋白 (LDL) 颗粒转运。LDL 颗粒与细胞跨膜受体蛋白结合，借助胞内网格蛋白内吞进入细胞。LDL 受体基因可因不等交换突变成残缺假基因，因失去功能使胆固醇阻止在胞外，滞留在血管引起高血压。

四、单一假基因

高等动物中均含有编码 L-古洛糖酸伽马内酯氧化酶 (GULO) 的基因，涉及**维生素 C 的合成**。但在人类和黑猩猩中，GULO 基因未加倍，但编码序列发生了终止突变，产生无效蛋白。GULO 无效假基因一直保留在群体中未被淘汰，通常称其为单一假基因 (unitary pseudogenes)，可引起坏血病 (维生素 C 缺乏病)。

2.4.2 SNP 的遗传身份和祖先状态确定

当两个等位基因以及它们的共同祖先在某一 SNP 位点上都携带相同的等位基因 (这里是 C) 时，可以认为它们在该位点上表现出遗传上的一致性。相反，如果共同祖先在该位点携带的是另一种等位基因 (T)，那么这两个等位基因与祖先之间同样表现出状态上的一致性，只是等位基因类型不同。

在一个 SNP 位点上，如果在人类序列中观察到 T/C 的多态性，而与之对应的大猿同源序列中为 T，那么可以将 T 定义为该位点的原始状态（记为 0）。由此推断，产生该多态性的突变事件是从 T（0）向 C（1）的改变。

需要指出的是，同一基因位点的多态性有时也会在其他灵长类动物中独立出现。因此，在比较不同物种时，如果能对每个物种分析多个个体，将有助于更准确地判断等位基因的演化状态和突变方向。

一、CpG

在基因组中，C 核苷酸后面跟着一个 G（表示为 CpG）的突变率较平常相比高十倍有余。这是因为人类基因组中多数 CpG 位点发生了化学修饰。大约 75% 的 CpG 二核苷酸是 DNA 甲基化的靶点。因此，甲基化的胞嘧啶核苷酸，即 CpG 二核苷酸，是突变的热点。

CpG 倾向于突变为 TpG 或 CpA。胞嘧啶的甲基化应该导致转换突变的增加。确实观察到 CpG 二核苷酸处的转换突变增加了五倍以上，但其具体机制尚不清楚。

对 1000 基因组计划数据的分析揭示了每个基因组大约有 10,000 个非同义变异和 30 个无意义的 SNP。

2.4.3 遗传多态性的分布

蛋白编码基因中潜在编码变异和功能丧失（LoF）变异的估计数量

变异类型	每个基因组的平均数量
同义突变（Synonymous）	10,572–12,126 ^a
非同义突变（错义突变，Missense）	9,966–10,819 ^a
产生终止密码子的突变（无义突变，Nonsense）	26.2（5.2） ^b
剪接位点变异（Splice site variant）	11.2（1.9） ^b
导致移码的小插入/缺失（Frameshift indel）	38.2（9.2） ^b
大片段缺失（Large deletion）	28.3（6.2） ^b
功能丧失（LoF）变异总数	103.9（22.5） ^b

- 数据来源：1000 Genomes Project Consortium（2010），低覆盖度数据集，*Nature* 467:1061。
- ^a 表示 CEU、CHB、JPT 和 YRI HapMap 样本中，每个个体变异数量的四分位范围。
- ^b 表示 CEU 样本中的平均变异数，括号内为纯合状态下的平均数量；数据来源于 MacArthur DG 等（2012），*Science* 335:823。

- LoF: loss of function, 功能丧失。

最典型的是 SNP，它们在核基因组中分布非常广泛、几乎遍布全基因组；mtDNA 中也以碱基替换为主。某些插入型变异具有区域偏好，例如 Alu 元件插入更常见于 GC 含量较高区域，而 L1 元件插入更偏向 AT 富集区域。**多等位多态性** (multiallelic polymorphisms)：**微卫星**和非 GC 富集的迷你卫星在基因组中较为分散；**GC 富集的迷你卫星**往往集中在染色体末端附近；**端粒重复序列**严格位于染色体末端；**卫星序列**主要集中在着丝粒区域。

2.4.4 基因突变的连续性

- ①**点突变** (每 800 bp 一个)。
- ②**小插入或删除**。包含框架移位、微卫星与小卫星。
- ③**移动元素**。包含经典元素的插入 (300bp-10kb)。
- ④**大规模基因组拷贝数变异** (>10 kb)。包含大规模删除，片段复制。
- ⑤**本地重新排列**。
- ⑥**染色体变异**。包含转位、倒位、融合。

结构变异，涉及 DNA 片段长度超过 1kb 的基因组改变。拷贝数多态性 (CNP) 是一种在人群中的拷贝数变异。在定量 (CNVs) 上，包含删除、复制、插入；在位置性上，包括转位；在定向上，包含反转。

基因组在群体水平的结构特征

单倍型 (Haplotype)：在一个染色体中存在一种独特的基因标记组合。

双倍型 (Diplotype)：人类是二倍体的，在每个 SNP 中有两个等位基因，它们以基因型的形式被观察到。每个基因都有两个单倍型。

2001 年，一批关于人类基因组的连锁不平衡结构 (或单倍域结构) 的研究工作在《Science》和《Nature》上陆续发表。这些研究证实了人类基因组中**单倍域结构**的广泛存在，这是由连锁不平衡与重组历史共同塑造的结果。这种现象可以归纳为**阴阳** (Yin-Yang) 现象：单倍型区块中常常由两条互补的主单倍型主导群体遗传结构，这正是连锁不平衡长期积累的结果。

2.5.1 确定单倍型

收集家系 → 通过体细胞混合从二倍体变为单倍体 → Allele-specific PCR → 统计推断。有克拉克算法、E-M 算法（基于似然的算法）、PHASE 算法（基于贝叶斯算法）。

一、克拉克算法（基于简约主义的算法）

一种基于确定性规则、逐步消解歧义的单倍型推断方法，核心思想：先从完全确定的基因型出发，再用已知单倍型去解释未知样本，不断迭代。

①寻找不含歧义的单倍型（seed haplotypes）。在所有个体的基因型中，优先识别两类无歧义情况：i. 纯合个体的两个单倍型完全相同，因此可以直接读出单倍型；ii. 仅在一个位点为杂合、其余位点纯合的个体，这类个体的两条单倍型也可以唯一确定。直接得到的单倍型构成算法的初始已知单倍型库。

②用两个已知单倍型解释一个歧义的双倍型。对于仍然存在多位点杂合的个体，如果其基因型可以表示为两个已知单倍型的组合，且这种组合是唯一的，那么该个体的单倍型配对就被成功解析，并加入单倍型库。


③如果某个个体的基因型中，有一条单倍型已经在库中存在，同时还可新推导的单倍型完成推导，继续加入单倍型库。如此往复知道单倍型库无法继续扩充。

2.5.2 单倍型的一些特征

单倍型块：至少有 80% 的观察到的单倍型具有 $\geq 5\%$ 的可能可以分组为常见模式 (Hinds et al., *Science* 2005)。

由 147 个常见人类染色体 21 位点 SNP 定义的 20 条独立且全球分布广泛的染色体上的等位基因型模式。这 147 个 SNP 覆盖了 106 kb 的基因组 DNA 序列，被划分为 18 个区块。

标签 SNP (Tag SNP) 是 SNP 的一个小子集，足以进行关联研究，而不会失去使用所有 SNP 的效力。实际上没有必要去穷举所有的 SNPs。实质上是选一组在组合层面能唯一编码单倍型的 SNP。



①SNPs S_3, S_4, S_5 可以作为一组标签 SNPs;

② S_1, S_2, S_3 不可以作为一组标签 SNPs, 这是因为 P_1 与 P_4 容易混淆。不是 SNP 数量不够, 而是判别信息不充分。

③ S_1 与 S_{12} 可以作为一组标签 SNPs。这是这个例子中数量最少的组合。

第二章 遗传图与物理图谱

第一节 遗传图绘制

遗传图 (Genetic Map): 通过遗传学方法, 以遗传图距 (cM) 为单位绘制的染色体上基因或标记之间相对位置的连锁图。(centimorgan, cM)

物理图 (Physical Map): 通过 DNA 克隆, 细胞原位杂交或 DNA 测序等方法将 DNA 克隆 (基因) 或 DNA 分子标记锚定在染色体的确定空间位置上而绘制的连锁图。物理图是一种**实物图**, 有确定的物理距离, 如碱基对数目。

为何要绘制遗传图和物理图? ①基因组太大, 必须分散测序, 然后将分散的顺序按原来位置组装, 需要图谱进行指导; ②基因组存在大量重复测序, 会干扰排序, 因此要高密度基因组图; ③遗传图和物理图各有优缺点, 必须相互整合校正。

基因组测序

第一步: 作图 (遗传图、物理图), 将两图整合。

第二步: 测序 (图谱测序、随机测序), 联合校正。

第三步: 组装 (骨架图、空隙填补), 生成草图与精图。

3.1.1 分子标记与基因组作图

目标: 基因组测序的基本策略是将整个基因组分割成一些小片段分别测序, 然后将测序的片段进行组装, 使其回归到原来的位置。

标记。为了确保分散的 DNA 片段正确归位, 必须寻找一批标记, 它们在染色体上的位置是已知的、唯一的、确定的, 并位于不同的测序片段之中。这些标记可以指导 DNA 克隆准确地锚定到染色体的确切位置。

一、基因测序的策略

- ①全基因组鸟枪法测序。生成小分子 DNA 克隆，进行测序与组装、构建重叠群。
- ②基于克隆物理图的测序。生成大分子 DNA 克隆。进行测序与组装，构建重叠群。

二、分子标记

染色体上的基因和 DNA 顺序均可作为路标，路标具有物理属性，它们由特定的 DNA 顺序组成。路标位于染色体上的位置是固定的，唯一的，不会更改的，因而提供了作图的依据。基因组路标就是 DNA 分子标记。

3.1.2 座位 (locus) 与位点 (site)

座位 (Locus) 是经典遗传学中常用的概念，系指染色体上经遗传分析确定的某个位置，它们可以是基因、DNA 顺序或分子标记，但具体物理位置不确定。因此 locus 系指遗传单元在染色体所占据的相对位置。

位点 (Site) 是指基因组物理图上某一确定的 DNA 顺序。

当 locus 是指确定的 DNA 顺序或基因序列时，也可称为 site。

限制性片段长度多态性 (RFLP)

第一代分子标记, **限制性片段长度多态性** (Restriction Fragment Length Polymorphism, RFLP)。这是最早发现的 DNA 分子标记。同源染色体的相同位置含有同源 DNA 区段, 它们之间可能存在某些碱基序列的差异 (碱基插入、缺失、重组或突变)。这些差异如果发生在限制酶识别的位置, 在进行限制酶酶切时, 就会产生长短不一的片段。

3.2.1 特点

- ①处于染色体上的**位置相对固定**;
- ②同一亲本及其子代相同位点上的**多态性片段特征不变**;
- ③同一凝胶电泳可显示等位区段不同多态性片段, 表现为**共显性**;
- ④需要用 Southern 杂交检测显示。

3.2.2 寻找 RFLP 标记的方法

- ①随机克隆筛选;
- ②将其它方法获得的 DNA 标记, 如 RAPD (random amplified polymorphism DNA) 标记转换为 RFLP 标记;
- ③从 cDNA 中寻找 RFLP。
- ④计算机筛选, 即电子杂交。

重复顺序多样性 (simple sequence repeat)

第二代分子标记, 可变排列的简单重复顺序 (simple sequence repeat, SSR), 即重复次数不一。在染色体的同一座位重复顺序拷贝数不同。在 1-6 个核苷酸之间, 是常用的分子标记。

SSR 的类型: ①小卫星序列 (minisatellite), 重复单位较长; ②微卫星序列 (microsatellite), 重复单位较短。

应用场景有核心种质分析与新品种 DNA 指纹鉴定。

3.3.1 寻找 SNP

①现已证实人和老鼠基因组中平均每 18-28 kb 含有一个多态性 (CA)_n。水稻中大概 23kb 左右就有一个 SSR 标记 (430Mb, 18828 个左右 SSR 标记)。

②获取方法: i. 计算机搜寻; ii. 用 *Sau3A*, *RsaI*, *HaeIII* 或 *AluI* 限制酶酶切基因组 DNA, 构建 DNA 文库。合成简单寡聚重复核苷酸作为探针从 DNA 文库中筛选。

③根据简单重复顺序两侧的序列设计引物, 用同位素标记 PCR 扩增样品, 经聚丙烯酰胺凝胶电泳分辨。

3.3.2 检测 SSR

在 SSR 多态性位点 DNA 序列两侧存在保守的顺序。根据这些序列可设计成对引物扩增, 经测序凝胶电泳分辨, 检测不同 SSR 分子标记。

3.3.3 优势

- ①在基因组中分布均匀;
- ②可用 DNA 测序凝胶直接显示, 检测方便;
- ③杂合子 DNA 多态性表现共显性;
- ④群体中 SSR 标记的多态性信息量高。

单核苷酸多态性 (Single nucleotide polymorphisms)

同源 DNA 单链的每个碱基位置可有 4 种选择: A, T, C, G, 即 4 种可能的多态性。因此 SNP 可由核苷酸代换产生。

SNP 密度高, 分布均一。人类基因组平均 600bp 含一个 SNP, 总量大约 500 万。紧密连锁的 SNP 可组成单倍型 (Haplotype), 便于构建进化树。

SNP 的缺点: 需要 DNA 测序或芯片杂交确定, 费用较高。

3.4.1 检测 SNP

①经典实验手段。采用 PCR-单链构象多态性 (PCR-SSCP) 分析、RFLP、dHPLC 和 HA 等, 必须通过凝胶电泳等进行分析。

②高通量检测 SNP。如 MALDI-TOF、DNA Chip 以及 DNA 测序、动态特异等位基因杂交 (dynamic allele-specific hybridization)。

3.4.2 群体多态性组成频率 (PIC)

①杂合性 (heterozygosity)。表示一个群体中某一位点等位基因杂合性的程度; 在一个群体中等位基因位点杂合个体占总样本的比例, 与等位形式多少有关。

②多态性信息量 (polymorphic information content, PIC)。PIC 用来表示群体中某一遗传位点多态性的程度。PIC 值小于 0.25 表示群体的多态性较低, PIC 值处于 0.25-0.5 之间属于中度多态性, PIC 值大于 0.5 为高度多态性。

③分子标记按多态性频率大小排列: SNP>SSR>RFLP。

一、PIC 的计算

$$PIC_i = 1 - \sum_{j=1}^n p_{ij}^2$$

- PIC_i : 第 i 个标记在群体中的多态性信息含量;
- n : 该标记的等位基因数;
- p_{ij} : 第 i 个标记中第 j 个等位基因在群体中的频率。

用中文阐述即, i 的 PIC 为 1 减去各等位形式在群体中频率的平方和。

【例 1】 标记 A 有两个等位基因, 第一个等位基因的频率为 50%, 第二个等位基因的频率也为 50%。标记 A 的多态性信息含量 (PIC) 为?

$$\begin{aligned} PIC_A &= 1 - (0.5^2 + 0.5^2) \\ &= 1 - (0.25 + 0.25) \\ &= 0.5 \end{aligned}$$

【例 2】 标记 B 有两个等位基因, 第一个等位基因的频率为 90%, 第二个等位基因的频率为 10%。标记 B 的多态性信息含量 (PIC) 为?

$$\begin{aligned} PIC_B &= 1 - (0.9^2 + 0.1^2) \\ &= 1 - (0.81 + 0.01) \\ &= 0.18 \end{aligned}$$

【例 3】 标记 C 有两个等位基因, 其中一个等位基因在群体中的频率为 30%, 另一个等位基因的频率为 70%。标记 C 的多态性信息含量 (PIC) 为?

$$\begin{aligned} PIC_C &= 1 - (0.3^2 + 0.7^2) \\ &= 1 - (0.09 + 0.49) \\ &= 0.42 \end{aligned}$$

【例 4】 标记 D 有 10 个等位基因, 且每个等位基因在群体中的频率均为 10%。标记

D 的多态性信息含量 (PIC) 为?

$$\begin{aligned} \text{PIC}_D &= 1 - \sum_{i=1}^{10} (0.1)^2 \\ &= 1 - (10 \times 0.1^2) \\ &= 1 - 0.1 \\ &= 0.9 \end{aligned}$$

【例 4】说明了，在等位基因数目增加且频率分布均匀时，PIC 值显著增大。

遗传图绘制


通过连锁分析建立遗传图。①**有性杂交实验**。杂交分离连锁分析，如果蝇、老鼠、玉米、水稻等；②**系谱分析**。不能有计划的遗传试验，如人类、大牲畜及多年生树木；③**DNA 转移**。不发生减数分裂的生物，如细菌与病毒，单倍体基因组。

3.5.1 通过有性杂交实验遗传作图

杂交试验连锁分析：选择已知基因型的亲本，设计杂交方案，获得交配的子代并分析其表型及基因型。①**两点杂交**：两基因连锁分析；②**多点杂交**：多基因连锁分析。

遗传图谱的绘制，首先要鉴定分子标记的等位形式，也就是用标记来鉴定基因型；随后通过两点检验，分析两个标记之间的重组率以确定遗传距离。再随后，进行多点检验，构建连锁遗传图。

下面是一个实际分析的例子：



一、连锁不平衡 (linkage disequilibrium, LD)

又称等位基因关联，是指同一条染色体上，两个等位基因间的非随机相关。即，当位于同一条染色体的两个等位基因 (A, B) 同时存在的概率，大于群体 (人群) 中因随机分布而同时出现的概率时，就称这两个位点处于 LD 状态。

$$LD = f_{AB} - f_A \times f_B$$

两个标记靠的越近越会出现连锁不平衡的遗传现象。它的存在，是进行基因型与表型间的关联分析和表型相关基因精细定位基本条件。

可以用连锁不平衡鉴定单倍型。

3.5.2 系谱分析遗传作图


适合：①不能按遗传规律设计杂交试验的物种，如人类，只能收集家系成员的相关资料进行连锁分析；②繁殖系数很低的物种，如大牲畜；③世代周期很长的物种，如树木。

由于系谱分析所能提供的样品非常有限，必须借助统计学方法对获得的数据进行可信度检验，常用的程序为 LOD 值评价。

一、LOD 值

Lod 值是基因连锁可能性的对数，用于初步判断所研究的 2 个基因是否位于同一染色体上。换句话说，可以回答 2 个基因是否连锁。如果 LOD 分析确定是连锁的，然后可以提供最可能的重组频率的程度。

二、LOD 值的计算



D 为显性疾病基因， d 为隐性基因， $M1/M2$ 为分子标记。该家系中，父亲从祖辈遗传了致病基因 D ，基因型为双杂合子 $D/d-M1/M2$ 。母亲的基因型为隐性双纯合子。6 个子女中，4 个成员的基因型未发生重组 (1, 3, 4, 6)，与双亲 (P) 相同。2 个子女的基因型发生了重组，以 R 标示 (2, 5)。现在要想知道重组型基因型是来自自由组合还是同源染色体之间的交换。

可以设想有 5 种可能，即重组率为 0.5, 0.4, 0.3, 0.2 和 0.1, 0.5 属于完全不连锁。根据重组率可以推算不同的重组基因型源自父亲产生的四种配子的机率，它们和子女基因型的比率是一致的。

重组情况	D-M1	d-M1	D-M1	d-M2	D-M2	d-M2
随机重组	25%	25%	25%	25%	25%	25%
50% 重组率	25%	25%	25%	25%	25%	25%
40% 重组率	30%	20%	30%	30%	20%	30%
30% 重组率	35%	15%	35%	35%	15%	35%
20% 重组率	40%	10%	40%	40%	10%	40%
10% 重组率	45%	5%	45%	45%	5%	45%

根据家族资料按照给定的 Q 值计算似然率。

①第一种估计, D 和 M 不连锁, 随机分配, 6 个子女基因型出现的概率:

$$L_{0.5} = 0.25 \times 0.25 \times 0.25 \times 0.25 \times 0.25 \times 0.25 = 0.00024$$

②第二种估计, D 和 M 部分连锁, 非随机分配, 假定重组率为 0.2, 6 个子女基因型出现的概率:

$$L_{0.2} = 0.4 \times 0.1 \times 0.4 \times 0.4 \times 0.1 \times 0.4 = 0.000246$$

③同理可知 $L_{0.3} = 0.00032$; $L_{0.4} = 0.00034$ 。

随后计算可能性之比 (Odds Ratio), 即发生 0.2, 0.3, 0.4 和 0.5 重组率的概率和随机分配的概率之比, 其含义是假定连锁的概率与不连锁的概率之比:

$$\begin{aligned} \frac{L_{0.2}}{L_{0.5}} &= \frac{0.000246}{0.00024} = 1.08 \\ \frac{L_{0.3}}{L_{0.5}} &= \frac{0.00032}{0.00024} = 1.41 \\ \frac{L_{0.4}}{L_{0.5}} &= \frac{0.00034}{0.00024} = 1.33 \\ \frac{L_{0.5}}{L_{0.5}} &= \frac{0.00024}{0.00024} = 1.00 \end{aligned}$$

计算每种假设的重组率的 LOD score, 即优势值, 它是 odds ratio 以 10 为底数的对数:

$$\text{LOD}_{0.2} = \log_{10} \left(\frac{L_{0.20}}{L_{0.50}} \right) = \log_{10}(1.08) = 0.03$$

$$\text{LOD}_{0.3} = \log_{10} \left(\frac{L_{0.30}}{L_{0.50}} \right) = \log_{10}(1.41) = 0.15$$

$$\text{LOD}_{0.4} = \log_{10} \left(\frac{L_{0.40}}{L_{0.50}} \right) = \log_{10}(1.33) = 0.12$$

$$\text{LOD}_{0.5} = \log_{10} \left(\frac{L_{0.50}}{L_{0.50}} \right) = \log_{10}(1.00) = 0.00$$

注：①当 $LOD > 3$ 时，可认为两个位点是连锁的。如果 $LOD < -2$ ，两个位点是不连锁的。如果 $-2 < LOD < 3$ ，连锁关系不确定。上述例子只是计算一个家系获得的 LOD 值，其中重组率 0.3 的 LOD 值虽然最高，为 0.15，但仍低于 3.0，因此不足以支持两个位点连锁的结论。②收集来自不同家系的资料，分别计算各自的 LOD 值，然后选出各自最大的 LOD 值将其累加。③LOD 值只给出连锁可能性，不给出图距。

3.5.3 单倍体基因组生物的遗传作图

细菌基因组的遗传作图面临的主要困难在于，这类生物一般都是单倍体，不发生减数分裂，因此必需设计一些方法使细菌 DNA 的同源区段发生交换。细菌染色体的遗传图绘制主要采用**部分二倍体** (partial diploid) 作图技术：

①**接合转移** (Conjugation)。2 个细菌机械接触，其中一个细菌（供体）将 DNA 转移到另一个细菌（受体）中。转移的 DNA 可以是供体细胞染色体的一段拷贝，亦可是整个染色体，长度可达 1 Mb。转移的 DNA 也可是质粒，即附加体转移 (episome transfer)。

②**转化** (transformation)。供体细胞释放的一段 DNA（通常小于 50 kb），经受体细胞摄取后整合到基因组中，可借助抗性培养基筛选重组克隆。

③**转导** (transduction)。以噬菌体为媒介，将长度可达 50 kb 的 DNA 片段从供体细胞转移到受体细胞。

大肠杆菌染色体为单倍体，没有有性过程。大肠杆菌的遗传作图采用部分 2 倍体策略，使用三种方法将外源 DNA 导入细胞发生同源重组。其遗传图绘制主要通过接合转移法。通过转移供体染色体片段与受体细菌同源 DNA 发生重组与交换，可绘制遗传图。遗传图距以转移时间计算，图距单位为分钟。

第二节 物理图绘制

采用非遗传重组的方法以 DNA 碱基顺序为图距单位绘制的位于染色体上基因线性排列次序的图谱。绘制物理图很有必要，因为遗传图的分辨率有限、覆盖面低、分子标记的排列有时会出错。位置弄错。在大规模 DNA 测序前，对大多数真核生物的遗传图必须进行验证并利用其他作图技术予以校正和补充。

对大分子来说，DNA 物理图的绘制很有必要。大分子 DNA 是指百万碱基对的 DNA，其易断裂，难分离，难克隆。研究方法包括：①制备，琼脂糖包埋法；②酶切，稀有酶切位点限制酶；③分离，脉冲电泳分离；④克隆，载体设计。

限制性酶切位点物理图

I 型限制性内切酶（识别位点 1Kb 以外的任何位置切割）；II 型限制性内切酶（识别位点中或附近切割，产生确定的片段）；III 型限制性内切酶（识别位点 25-27bp 以外的位置切割）。

具体步骤上，通过实验将限制性酶切位点标定在 DNA 分子的相对位置，根据 DNA 顺序计算机标示电子酶切位点物理图。

如果 DNA 顺序是已知的，可以通过计算机软件搜寻 DNA 顺序中不同限制酶酶切位点绘制 DNA 分子限制性物理图。

4.1.1 琼脂糖包埋法

分离纯化细胞核 → 将收集的细胞核包埋在琼脂糖凝胶薄片 → 蛋白酶消化处理细胞核。

4.1.2 稀有切点限制酶

在基因组 DNA 顺序中只有很少可识别序列的限制酶，一般识别位点在 6-8 碱基对之间，并含有高 G/C 比。选用稀有切点限制酶注意事项：

①非特异顺序识别位点，如 *Hinf*，-G/ANTC-*Hinfl*，*Bgl*，-GCCNNNN/NGCC-，实际是 6 碱基识别。

②高等生物基因组一般 A/T 比较高，应选高 G/C 比限制酶，如-GC/GGCCGC-(*NotI*)，可产生大片段 DNA。

③高等生物基因组 DNA 甲基化比例很高，甲基化敏感限制酶可产生大片段。

一、限制性内切酶的命名规则

限制性核酸内切酶主要是从原核生物中提取的。通用的命名规则：第一个字母是细菌属名的首字母，斜体大写；第二、三个字母是细菌种名的前二个字母，斜体小写；接下去是细菌株的第一个字母，用正体字母。如果同一菌株中有几种不同的内切酶时，则分别用罗马数字 I、II、III 等来书写。

细菌原名	细菌种名	菌株名称	限制酶名称
<i>Arthrobacter</i>	<i>luteus</i>	—	<i>Alu</i>
<i>Bacillus</i>	<i>amyloliquefaciens</i>	H	<i>Bam</i> HI
<i>Escherichia</i>	<i>coli</i>	RY13	<i>Eco</i> RI
<i>Haemophilus</i>	<i>influenzae</i>	Rd	<i>Hind</i> III

基于大分子克隆的基因组作图

常规琼脂糖凝胶电泳只能解决 <30kb 线性分子，脉冲凝胶电泳（Pulsed-field gel electrophoresis, PFGE）分辨率达 10Mb。

4.2.1 脉冲交变电场电泳（OFAGE）

有 2 对电极分别位于凝胶对角线的两端，2 对电极交替通电，产生一个交变电场。在交替改变的电流作用下，DNA 分子在凝胶中不断改变迁移方向。大分子 DNA 转向缓慢，迁移速度落后于小分子 DNA。OFAGE 电泳可分开百万 bp(Mb) 级的 DNA。

4.2.2 均一脉冲电场电泳（CHEF）

设计了 3 对对称的正负极，电极夹角 120°，垂直方向电泳不变，左右两对电极交替开关，电流方向交替改变。均一电场电泳使大分子 DNA 相互分开并保持直线迁移，产生整齐垂直的分离条带。

4.2.3 通过大分子 DNA 技术绘制 E. coli 基因组物理图

大肠杆菌基因组 DNA 经限制酶 Not1 酶切后，经垂直交变电场电泳分离，凝胶经溴化乙锭（EB）染色后显示大分子 DNA 条带的迁移位置，这些条带可以通过杂交，通过分子标记把它识别出来。21 个片段，20-1000kb。

一、遗传图与物理图整合

遗传图上分布了作图用的分子标记。这些分子标记可以和物理图中 DNA 片段杂交进行位置标定。根据共享的分子标记，可将物理图 DNA 片段准确地锚定到遗传图，完成遗传图和物理图的整合。

二、人工染色体克隆载体

①**酵母人工染色体** (yeast artifitialchromosome, YAC)。优点：容量大, 插入片段可达 1 000 kb；缺点：由于稳定性问题，转化效率低；嵌合克隆（同一酵母细胞多个 YAC 引起交换产生嵌合序列）比例高达 48%，克隆 DNA 的制备困难。

②**细菌人工染色体** (bacterial artifitialchromosome, BAC)。是大分子 DNA 克隆的主流技术。这是 mini-F 的衍生质粒，*OriS* 控制单拷贝复制；*repE* 控制 F 因子单向复制；*parA* 和 *parB* 维持低水平质粒拷贝数；*loxP* 为 P1 Cre 蛋白作用位点，可将环状 BAC DNA 转变为线型分子，便于物理图绘制。*HindIII* 和 *BamHI* 为外源 DNA 插入位置，两侧的 *NotI* 位点用于检测克隆大分子 DNA。它克隆的容量可以达到 100 到 300Kb。优点：细菌细胞中单拷贝复制，不存在克隆 DNA 之间的重组问题；操作方便，制备方法类似质粒 DNA。缺点：转化效率低, 克隆片段长度相差较大；空载体 DNA 的制备产量较低。

③**噬菌体人工染色体** (P1-derived artifitialchromosome, PAC)。优点是克隆的 DNA 片段必须在一定长度范围才能保证噬菌体生长繁殖，因而可以确保克隆的 DNA 片段长度达到 120kb 左右。

三、BAC 克隆的步骤

①载体与插入大分子 DAN 的连接：将含有大分子 DNA 的琼脂糖薄片 68 度保温 5 min，降温至 37 度，加入 agarase 消化，然后取出部分 DNA 样品, 按重量比 1:1 加入载体,, 加入连接酶过夜。

②宿主菌制备。选定的宿主菌在完全培养基上培养至光密度 0.2，收集细菌。

③将细菌密度调整到 10^9 ，加入连接反应液，转移到电击杯 (0.1 cm 直径) 中。电击转化参数：25000V/cm。

④氯霉素选择培养基上筛选阳性克隆，阳性克隆白色。

四、克隆作图

根据克隆的 DNA 片段之间的重叠顺序建构重叠群 (Contig)，绘制物理连锁图。大分子 DNA 克隆的作图：染色体步移法、指纹重叠法。

染色体步移：①以起始克隆 A1 为探针筛选基因组文库；②两个与 A1 杂交的阳性克隆分别为 B1 和 B2，根据 A1 两端的顺序可确定 B1 与 B2 的相对位置；③分别以 B1 和 B2 为探针重复杂交，筛选到下一轮阳性克隆 C1 和 C2。不断重复这一过程，可建立一个彼此连接的重叠群。

指纹作图：克隆指纹主要用于重叠群构建。原理是如果两个克隆彼此重叠，一定含有相同的顺序。这些顺序的限制性物理图组成一致，含有相同的重复顺序以及单一顺序 (STS)。**优点：**作图快，可提供详细信息。**缺点：**重复序列干扰，或选择限制酶不当，会出现误排。

荧光原位杂交

序列标签位点


通过 PCR 或分子杂交将**单一 DNA 顺序**定位在基因组染色体位置。

STS 的特征：①一段已知序列的片段，可设计引物或探针；②在染色体上独一无二的位置，即单一序列。

寻找 STS 的方法：①表达序列标签 (expressed sequence tag, EST)：cDNA 克隆中找小段序列，单拷贝基因；或位于基因的非翻译区，具有专一性。②SSLP，微卫星序列；③随机基因组序列。克隆 DNA，或数据库中。

STS 作图原理。①基因组中单一序列标签位点都是独一无二的序列组成，在染色体上的位置是确定的。②位于染色体上近邻排列的 STS 是机械连接的，在外力作用下断裂 DNA 或酶切降解 DNA 时，2 个不同的 STS 出现在同一片段的机会取决于它们在基因组中的相对位置。

4.4.1 辐射杂种作图



作为供体的人体细胞含有**筛选标记基因**，经**辐射处理**后染色体被打断成**长度不一的片段**。X-射线辐射剂量越高，产生的片段越小。辐射处理的人体细胞与仓鼠细胞融合后，人类染色体片段会随机插入到仓鼠染色体中，由此产生的辐射杂种细胞可在筛选培养基上分裂生长。这个融合细胞称之为辐射杂种，这些杂种细胞的集合体成为辐射杂种群。

DNA 分子暴露在 N 拉德 (rad) X 射线剂量下两个分子标记之间发生 1% 断裂的几率，其图距单位为厘镭 (centiRay, cR)。

一、辐射杂种连锁分析

每次从细胞中分离 DNA，用 PCR 检测杂种细胞中含有的 STS 标记。检测到的概率大小决定了两个标记间的距离。

可能的组合：

$$a, b, a + b, 0$$

分布频率：

$$f_a, f_b, f_{a/b}, f_0$$

滞留率 (Φ) 定义为：

$$\Phi = \frac{f_a + f_b}{P_a + P_b - 2P_a P_b}$$

其中 Φ 为滞留率，在给定的 X 射线剂量下，两个标记共滞留的比例。


4.4.2 基因组计划

国际人类基因组计划的主要目标之一，是绘制一张高密度的人类基因组物理图，含有 30 000 个分子标记，达到每 100 kb 含一个特定的标记。这一物理图可启动指导人类全基因组测序。基因组计划的四张图：遗传图谱、物理图谱、转录图谱、序列图谱。

绘制基因组遗传图和物理图时，会使用许多共享的**分子标记**。通过比对遗传图和物理图中共有的处于相同连锁群的分子标记的排列位置是否匹配，可以判断图谱绘制的质量，并彼此整合成基因组图。

图位克隆

- ①粗定位，连锁分子标记的筛查与克隆；
- ②精细定位，将连锁分子标记向靶基因位置逼近；
- ③以紧密连锁分子标记为探针筛选基因组克隆；
- ④染色体步移，构建覆盖靶基因位点的叠连群；
- ⑤以覆盖靶基因位点的 DNA 克隆为探针从 cDNA 文库筛选候选基因；
- ⑥候选基因多态性分析；
- ⑦转基因验证。



- 注：1) 番茄 Pto 抗病基因位于 5 号染色体，两侧标记为 TG475 和 TG504。
2) 以 Pto 紧密连锁标记 TG538 为探针分离到 YAC 克隆，其两端顺序为 PTY528-1 L 和 PTY538-1 R。该 YAC 克隆覆盖了 Pto 基因。
3) 以 YAC 克隆为探针分离到两个 cDNA 克隆 CD186 和 CD127，即候选基因。
4) 以 CD186 和 CD127 为探针，与基因组 DNA 限制酶处理样品杂交，CD127 在抗性品系和敏感品系间表现高水平多态性。转化实验证实 CD127 为抗性基因。

第三章 基础基因组测序技术

DNA 复制为半保留复制，由于 DNA 单链复制延伸时只能以核苷酸单体的 5'-磷酸基团与前一个核苷酸的 3'-羟基所和生成磷酸酯键，因此 DNA 复制是以 5'→3' 方式进行的。

测序所用 DNA 聚合酶

分析 DNA 聚合酶 I。其含有 DNA 聚合酶结构域、3'-5' 外切核酸酶结构域（用于校对 proofreading）；同时还有 5'-3' 外切核酸酶（用于引物清除的结构域 Primer removal）。

因此，一个理想的链终止法测序 DNA 聚合酶应该具有以下特点：①复制时可有效掺入双脱氧核苷酸或其它修饰类似物（如荧光标记）；②具有较高的加工性能；③在缺少外切核酸酶活性时仍然具有很高的保真度；④能产生清晰一致的信号用于读序。

天然 DNA 聚合酶不能直接用于 DNA 测序，必须进行改造。

4.6.1 曾经使用过的测序 DNA 聚合酶

①Klenow(E.coli DNA 聚合酶片段)。加工性能低（ $\square 15$ nt），具 5'-3' 和 3'-5' 外切核酸酶活性，已弃用。

②T7 DNA Pol。需硫氧还蛋白辅助，加工性能达 $\square 800$ nt，具 3'-5' 外切核酸酶活性，保真度高，用于常规测序。

③Taq DNA Pol。耐热聚合酶（最适温度 $72\square$ ， 100 nt/sec），缺 3'-5' 外切核酸酶活性，保真度低，错配率 $1/9000$ ，合成 3'-端具 A 突出；用于 PCR 测序。

④Pfu DNA Pol。耐热聚合酶（最适温度 $72\square$ ， 10 nt/sec），具 3'-5' 外切核酸酶活性，保真度高，错配错配率 $1.3/10^6$ ，3'-端平端，加工性能差；用于辅助 PCR 测序。

目前普遍采用的测序酶为 T7 DNA 聚合酶的改造型 T7 Sequenase 和改造型 Taq DNA Pol。

一、T7 DNA 聚合酶

T7 DNA 聚合酶结构简单，复制效率好于大肠杆菌 DNA 聚合酶 I (DNA polymerase I) 的 Klenow 片段，后者加工性能只有 15nt。AMV 逆转录酶可达 200nt, 但复制速率太低，每秒仅延伸数个核苷酸。此外，T7 DNA 聚合酶最大的优点是不排斥 ddNTP, 适合 Sanger 法测序。

噬菌体 T7 DNA 聚合酶的特点：①T7 DNA 聚合酶的体内活性需要硫氧还蛋白，可提高 T7 Pol 加工性能 100 倍，从一次延伸数个 nt 到一次延伸 800 nt；②T7 DNA 聚合酶缺少 5'-3' 外切核酸酶活性；③T7 DNA 聚合酶具有很强的单链和双链 DNA 3'-5' 外切核酸酶活性，这一活性受 EDTA，还原剂及铁离子等影响。

二、T7 DNA 聚合酶外切核酸酶的活性改造

T7 DNA 聚合酶用于 Sanger 法测序的一个阻碍是其 3'-5' 外切核酸酶活性，在 dNTP 浓度降低时会干扰测序，甚至降解 DNA。通过突变去除天然 T7 DNA 聚合酶外切核酸酶活性结构域中 28 个氨基酸可使 3'-5' 外切核酸酶活性丢失，但不影响其聚合酶功能。

三、测序用 DNA 聚合酶的改造

①T7 DNA Pol。消除 3'-5' 外切核酸酶活性，提高产生一致性的清晰条带；

②Taq DNA Pol。消除排斥 ddNTP 的倾向，提高合成效率。

四、耐热 Taq DNA 聚合酶的改造

DNA聚合酶	掺入碱基速率比值			
	dG/ddG	dA/ddA	dT/ddT	dC/ddC
T7 DNA聚合酶	3.2	3.3	2.8	3.7
T7 DNA聚合酶 Y526F (苯丙氨酸取代酪氨酸)	6,400	7,300	8,400	11,000
E.coli DNA聚合酶 I	140	720	1,100	250
E.coli DNA 聚合酶 I F762Y (酪氨酸取代苯丙氨酸)	0.56	0.72	0.54	0.75
Taq DNA 聚合酶	1,400	4,700	4,500	2,600
Taq DNA 聚合酶 F667Y (酪氨酸取代苯丙氨酸)	0.45	0.59	0.56	0.32

耐热性 DNA 聚合酶在 PCR 循环测序中有特别的优势，但有排斥 ddNTP 的倾向，可达 10000 倍。这一特点决定于 DNA 聚合酶中的单个氨基酸 (T7, 526F, 苯丙氨酸; DNA

聚合酶 I, F762, 酪氨酸; Taq, F667)。更换这一氨基酸, 可消除聚合酶对 ddNTP 的排斥倾向。

注: 聚合酶 O 螺旋位置苯丙氨酸排斥 ddNTP。

一代测序

第一代 DNA 测序的特点: ①间断测序, 双脱氧核苷酸; ②单一测序, 单一模板 DNA; ③携带标记, 同位素或荧光; ④限长测序, 长度有限。

4.7.1 原理

特点是渗入一个双脱氧核苷酸。合成新链要延续, 3' 末端的这个核苷酸一定要有一个 3' 羟基, 脱氧没有羟基。渗入是随机的, 在任何位置上都有中断的可能。对 4 种脱氧核糖核酸进行标记, 通过电泳可以得到一系列的标记。

第一代 DNA 测序的原理是依据 Sanger 设计的双脱氧核苷酸渗入法, 必须同时分别进行 4 组反应。每组反应中都有一种不同的用 ^{32}P 同位素标记的双脱氧核苷酸加入 DNA 复制单个反应液。终止反应双脱氧核苷酸的位置可以通过测序凝胶 DNA 电泳检测, 经 X-光片曝光显示。根据每个泳道相邻的碱基条带推测 DNA 序列。

一、荧光标记同组反应

双脱氧核苷酸的荧光标记技术对实现 DNA 的自动化测序具有非常重要的意义。由于不同的 4 种双脱氧核苷酸可用不同颜色的荧光物质标记, 因而在同一组反应中, 不同颜色的荧光标记核苷酸可以渗入到相应的测序位置。通过检测仪分辨荧光的颜色, 即可判读碱基序列。

二、毛细管电泳测序

一束并列的充满凝胶的用于 DNA 测序的毛细管, 共聚焦荧光扫描显微镜可将核苷酸的荧光标记信号放大并由计算机读取碱基序列, 完成自动化测序。

二代测序

第二代 DNA 测序的特点：①连续测序，焦磷酸反应；②平行测序，芯片设计；③自动化测序，荧光判读；④高通量测序，达到 Gb 级。

4.8.1 焦磷酸测序 (pyrosequencing)

焦磷酸测序技术是一种新的**实时 DNA 测序技术**。它在 **DNA 聚合酶**、**三磷酸腺苷硫酸化酶**、**荧光素酶**和**三磷酸腺苷双磷酸酶** 4 种酶的协同作用下，使引物延伸聚合脱氧核糖核酸。dNTP 释放焦磷酸 PPi 、 PPi 转换为三磷酸腺苷 (ATP)、ATP 在荧光素酶作用下催化荧光素磷酸化，随后发生氧化反应放出荧光。如果渗入的 dNTP 与模板 DNA 碱基不配对，则不发生反应。仪器可自动记录，判读掺入的碱基成员。

454 测序仪**每次**的测序长度最高达 **400-500 bp**，平均为 **100 bp**。

一、DNA 模板制备

磁珠与乳化液。

①**DNA 样品制备**。将机械断裂的待测序 DNA 小片段两端连接引物并加入到乳化反应液中。反应液中含有固定引物的磁珠，dNTP，聚合酶；

②**模板 DNA 制备与纯化**。待测 DNA 单链与磁珠上的通用引物复性，随后进行乳化 PCR。扩增后磁珠上的引物都与 DNA 模板连接。变性后磁珠上连接的均为单链 DNA 模板，利用吸磁和离心收集模板 DNA 磁珠；

③**含有均一的单链 DNA 模板的磁珠；**

④**制备测序模板芯片**。将富集纯化的模板 DNA 磁珠与聚丙烯酰胺凝胶混合铺展在标准的玻片上形成极薄的测序片层；

⑤**进行 DNA 模板平行测序。**

4.8.2 装置

第二代 DNA 测序装置由 3 个主要部件组成：①**4 个核苷酸供应池**。分别盛有 A, T, C, G, 通过输送管与芯片连接；②**芯片反应槽板**。每个小槽中含有携带 DNA 模板的磁珠；③**成像判读装置**。包括摄像头，计算机与可视频幕。

4.8.3 特点

实时连续测序。如果渗入的碱基正确配对，测序反应槽会发出荧光，仪器将记录渗入的核苷酸。如果**连续渗入的核苷酸是相同的**，则会发生**等摩尔倍数亮度**的荧光。参照**设立的对照**，计算机可正确记录测序的碱基数。

效率与准确度。第二代 DNA 测序结合了芯片技术，在每平方毫米的芯片上可安装 480 个小槽。每个小槽含一个磁珠，直径约 28 μm ，可携带**数十万个 DNA 模板**，产生足够的荧光供检测分辨。每块芯片总共 **160 万个反应槽**，可平行测序。每轮 4 次加样，依次为 A, T, C, G。一次测序执行 44 轮总计约 156 次反应。根据统计，二代测序的平均长度为 109.9 bp，精确度为 98%。每轮最高测序达 4-6 亿 bp。

4.8.4 技术分类

主要分为边合成边测序和连接法测序两大类：

①**边合成边测序。**包括 Roche/454 GS FLX、Illumina/HiSeq、Helicos BioSciences/HeliScope™、Dana-her Motion/Polonator 等。

②**连接法测序。**通过引物定位核酸信息，代表平台为 Applied Biosystems/SOLiD™ system。

③**其他平台。**华大智造的 DNBseq-G99、T7 等设备也属于二代测序范畴，通过滚环扩增生成 DNB 进行测序。

一、454 焦磷酸法平台

①首先将待测的目的 DNA 分子打断成 300-800bp 的片段，然后在 DNA 片段的 5' 端加上一个磷酸基团，3' 变成平端，在两端分别加上 44bp 的 A、B 两个衔接子，组成目的 DNA 的样品文库。

②目的 DNA 片段固定到一个磁珠上之后，将磁珠包被在单个油水混合小滴 (乳滴)，在这个乳滴里进行独立的扩增，经过富集之后，每个磁珠上都有约 107 个克隆的 DNA 片段。

③随后将这些 DNA 片段放入 PTP 反应板中进行后继测序。PTP 平板含有 160 多万个由光纤组成的孔，孔中载有化学发光反应所需的各种酶和底物。

④测序开始时，放置在四个单独的试剂瓶里的四种碱基，依照 T、A、C、G 的顺序依次循环进入 PTP 板，每次只进入一个碱基。如果发生碱基配对，就会释放一个焦磷酸

盐 (PPi) 分子。PPi 在 ATP 硫酸化酶的催化下与腺苷酰硫酸反应生成 ATP，ATP 与虫萤光素反应发光，光信号的最大波长约为 560nm。

⑤此反应释放出的光信号实时被仪器配置的高灵敏度 CCD 捕获到。有一个碱基和测序模板进行配对，就会捕获到一分子的光信号，由此一一对应，就可以准确、快速地确定待测模板的碱基序列，读长可达到近 500bp。

二、Illumina 测序

克隆单分子阵列技术。

①将目的 DNA 分子打断成 100-200 bp 的片段，随机连接到固相基质上，经过 Bst 聚合酶延伸和甲酸胺变性的桥 PCR 循环，生成大量的 DNA 簇 (DNA cluster)，每个 DNA 簇中约有 1000 个相同序列的 DNA 片段。

②之后的反应与 Sanger 法类似，加入用 4 种不同荧光标记并结合了可逆终止剂的 dNTP。固相基质上每个孔有八道独立检测的位点，所以一次可以并行八个独立文库，可容纳数百万的模版克隆，可把多个样品混合在一起检测，每个固相基质上一次可读取 10 亿个碱基。

③DNA 簇与单链扩增产物的通用序列杂交，由于终止剂的作用，DNA 聚合酶每次循环只延伸一个 dNTP。每次延伸所产生的光信号被标准的微阵列光学检测系统分析测序，下一次循环中把终止剂和荧光标记基团裂解掉，然后继续延伸 dNTP，实现了边合成边测序技术。

④其主要的缺点是由于光信号衰减和移相的原因使得序列读长较短，可以进行每个 DNA 测序片段的阅读长度仅为 75 bp 的末端双向测序反应。

三、SOLiD

①首先制备 DNA 文库。SOLiD 技术支持两种测序文库，分别是片段文库和配对末端文库。将待测的 DNA 分子打断，并在两端加上接头，则可组成片段文库。而配对末端文库则是先把 DNA 分子打断，在中间加入 EcoP15 酶切位点和 internal 接头后进行环化，然后用 EcoP15 酶切，使得接头的两端各有 27 bp 的碱基，最后在两端加上接头，构成文库，适用于全基因组测序、SNP 分析、结构重排及拷贝数的分析等相关领域。

②第二个阶段与 454 焦磷酸测序法相同，加入磁珠等反应元件进行 emPCR 平行扩增，不同的是该方法的磁珠只有 1 μ m。在连接测序中，底物是 8 个碱基的八聚体单链荧光探针，在 5' 末端分别标记了 CY5、TexasRed、CY3、6-FAM 这四种颜色的荧光染料。3' 端的第 1、2 位碱基类别排序分别对应着一个固定的荧光染料，第 3、4、5 位碱基“n”是随机碱基，第 6、7、8 位碱基“z”是可以和任何碱基配对的特殊碱基。

③一次测序中包括了五轮连接反应。每轮连接反应首先是由 3 个碱基“n”介导，将八聚体连接在引物上，测序仪记录荧光染料信号，然后断裂掉碱基“z”，准备连接下一个八聚体。一次循环后，将引物重置，进行第二轮连接反应，反应位置比前一轮错开一位，这样引物上的每个碱基都会有两次与第 1、2 位的相连接，显著减小了测序误差。

三代测序

第三代 DNA 测序的主要特征可以归结为单分子实时测序 (single-molecule sequencing, SMS)。特点：单分子测序，测序过程无需进行 PCR 扩增，实现了对每一条 DNA 分子的单独测序。

包含两种技术路线：①基于单分子 DNA 合成的实时测序 (single-molecule real-time sequencing)；②纳米孔单分子 DNA 电流阻遏 (current blockage) 测序；

4.9.1 单分子荧光信号测序 (SMRT)

零模式波导测序仪 (zero-mode waveguides, ZMW)。DNA 聚合酶分子通过共价结合的方式结合在纳米孔底部。

①零模式波导测序装置。单分子 DNA 实时测序仪有一个 SMRT Cell 平台，每个上面有 15 万个 ZMW，每次运行能够平行检测大约 75,000 个单分子测序反应，单个测序长度可达 1000bp。

②在 ZMW 孔底部被锚定的聚合酶检测到正确的核苷酸时，将其掺入新生链中，这个过程需要几毫秒，而单纯的扩散只有几微秒。这一时间差提供了荧光标记的信号，被光子显微摄像机识别记录，从而判定 dNTP 的种类，反应完成后荧光标记会被聚合酶切除而弥散出 ZMW 小孔。

③掺入的核苷酸在底部小孔进入延伸单链 DNA 时，不同的掺入核苷酸显示不同的荧光色泽和强度，显微摄像机可依次记录掺入的核苷酸。

4.9.2 纳米孔单分子 DNA 电流阻遏测序

原理：当多聚有机分子通过纳米孔时，可以短暂地占据纳米孔道，并对穿越纳米孔道的离子电流产生阻遏效应，干扰离子电流信号。不同的有机分子产生的电流阻遏 (current blockage) 信号是不同的，根据电流阻遏信号的变化可以用来分析纳米孔内靶分子的特征、浓度、结构及其动态。

一、纳米孔蛋白

纳米孔蛋白 α -HL 和 MspA 均为**跨膜蛋白**，各有两个相连的空腔。MspA 的收缩孔道直径为 **1.3nm**，比 α -HL 的孔道更窄，孔道的长度更短。此外 MspA 上部的空腔空间更大，这一构型使其可容纳更多的溶液。**DNA 分子直径约 1 nm**，进入纳米孔蛋白内腔后，在离子电流作用下穿越收缩区纳米孔狭道，**引起离子电流改变**。箭头为 DNA 分子运动方向。当单链 DNA 分子通过纳米孔道时，由于碱基会对电流产生阻遏引起电流数值的变化，可据此判别碱基的组成 (*Nat Biotechnol* 30: 326–328, 2012)。

二、固相纳米孔

硅片上放置一层极薄的碳膜，中间留出纳米孔道。纳米孔道两侧的碳薄膜与电极相连，通过横向电流的监测识别逐个移动的单分子 DNA 中的碱基。上下位置的电极用于推动溶液中的 DNA 单分子沿纳米孔移动。 I_b 和 I_t ，记录瞬时电流参数 (*Nanotechnology* 23:268-296, 2012)。

三、单分子 DNA 测序的

实现单分子 DNA 的电子阅读必须克服一系列的技术难点, 主要涉及:

- ①建立适合纳米孔单分子 DNA 测序的平台;
- ②确定识别单分子 DNA 序列的技术参数;
- ③控制单分子 DNA 在纳米孔道中的移动速度, 便于电子阅读与记录。

第四章 全基因组测序

遗传图 (Genetic Map): 通过遗传学方法, 以遗传图距 (centiMorgan, cM) 为单位绘制的染色体上基因或遗传标志之间相对位置的连锁图。1 cM=1% cross over。

物理图 (Physical Map): 通过 DNA 克隆, 细胞原位杂交或 DNA 测序等方法将 DNA 克隆或 DNA 分子标记锚定在染色体的确定空间位置上而绘制的连锁图。是一种实物图, 有确定的物理距离, 像碱基对数目 (base pair, bp)。

两种图各有优缺点。①基因组太大, 需要分散测序, 需要将分散顺序按照原来位置组装, 需要图谱指导; ②基因组存在大量重复序列, 干扰排序, 因此需要高密度基因组图; ③两种图各有优缺点, 必须相互整合矫正。

第一节 测序策略

图位法测序 (map-based sequencing)

又名**克隆依次测序** (clone-by-clone sequencing)。特征是按照大分子 DNA 克隆绘制的物理图分别在单个大分子 DNA 克隆内部进行测序与序列组装, 然后将彼此相连的大分子克隆 (contig) 按排列次序搭建**支架** (scaffold), 最后以分子标记为向导将搭建好的支架逐个锚定到基因组整合图上。

作图法测序的基本单元是大分子 DNA 克隆, 如 BAC 或 PAC。根据基因组物理图上已知的 BAC (或 PAC) 克隆从中挑取待测的成员, 提取并纯化克隆 DNA, 然后采用机械断裂 (如超声波) 法制备小分子 DNA。经电泳分离后收集 2kb 大小的 DNA 片段插入到质粒载体中进行克隆, 然后进行两端测序。由自动测序仪记录的测序序列需经 Phred Q20 软件初筛, 认可后用于组装。在进行序列组装前, 必须过滤掉污染的载体序列以及各种重复序列, 如 rRNA 基因、转座子等, 以保证组装序列的质量。

BAC 克隆 (bacterial artificial chromosome) 是细菌人工染色体, 由大肠杆菌天然 F 质粒发展而来, 较大克隆容量, 用于物理图绘制。

5.1.1 作图测序法的物种

这些物种的测序都是首先构建基因组物理图，然后按图索骥，逐段完成。①**大肠杆菌** (Blattner FR et al. *Science* 1997)。第一个完成全基因组测序的原核生物， 4.6×10^6 bp；②**酵母** (Cherry JM et al. *Nature* 1997)；③**线虫**基因组 (The C. elegans Sequencing Consortium. *Science* 1998)；④**拟南芥**基因组测序 (Arabidopsis Genome Initiative. *Nature* 2000)。第一个完成全基因组测序的植物。

图位法的优缺点。优点：①精确度高；②可实现含重复序列都的基因组测序工作；③基因组组装工作有图谱指导，相对容易实现；缺点：①需要精确的物理图谱指导；②耗时长，费用高，工作量大；③难以自动化、高通量生产。

全基因组鸟枪法测序 (whole-genome shotgun sequencing)

这是一种由下而上的测序组装策略。2kb 小片段的两端序列测序后，可搭建一系列的重叠群。由 2kb 两端序列组建的重叠群可以通过 10kb 片段两端序列归并，10kb 两端序列组建的重叠群可以通过 40kb 两端序列归并，依此类推，逐级而上。最后以 BAC 克隆收尾，再根据分子标记锚定到染色体连锁图上。

鸟枪法测序法优缺点。优点：①速度快，效率高；②可实现高通量、自动化；③不需要物理图谱指导；④可实现大型基因组的测序工作；**缺点：**①全基因组组装工作量大；②随机打断片段测序存在随机缺口；③对于含重复序列多的基因组测序有劣势。

作图法测序与鸟枪法测序的区别。作图法测序的大分子 DNA 克隆所在染色体上的位置在测序之前已经标定在基因组物理图上，只需按部就班地对每个大分子 DNA 克隆逐个测序。但在每个大分子 DNA 克隆内部，基因组测序与序列组装用的仍然是随机法测序。鸟枪法测序是直接从全基因组已测序的小片段中寻找彼此重叠的序列，然后依次向两侧邻接的序列延伸，用以构建更大范围的 DNA 序列支架。

5.2.1 鸟枪法测序法的物种

①**第一种原核生物：流感嗜血杆菌。**1995 年，其基因组序列采用鸟枪法测序率先完成，在没有任何遗传图及物理图信息的情况下完成，由 Celera Genomics 完成。

②**果蝇。**果蝇是第一个完全采取鸟枪法完成基因组测序的真核生物。果蝇染色体总长 180Mb，其余为异染色质区（测序困难区），完成草图序列占总序列 2/3。果蝇的基因组与流感嗜血杆菌基因组的组成存在基本的差异，主要表现在重复序列的不同。

一、图位法与鸟枪法结合测序法的物种

①水稻基因组测序。国际水稻基因组计划应用 BAC, PAC 克隆图位法测序粳稻 (japonica)。BAC, PAC 克隆允许 <500bp 的间隙, 于 2003 年完成草图序列, 总长 371Mb; 中国华大基因和美国 syngenta 通过鸟枪法测序于 2002 年完成草图序列 (Yu J et al 2002; Goff SA et al 2002); 2005 年国际水稻基因组合作组织发布完成序列, 覆盖度 95%。

②人类基因组测序计划。建立的参考基因组 (reference genome)。参考基因组是一组涉及特定物种基因组的数字化核苷酸顺序数据, 基因组测序时, 为增强其代表性, 通常由多个供体进行基因组测序, 分别建库, 分别测序, 在序列组装时统一归入到一个虚拟的参考基因组中。参考基因组包含的 DNA 序列只是最接近人类群体不同个体的序列, 并不涵盖所有个体具有的序列。由于测序样本的局限, 参考基因组序列也会随着测序样本的不断扩大而逐步完善。完成序列的百慕大标准 (Bermuda standards, 1997): i. 10,000 个 DNA 碱基中不到 1 个错误, 错误率小于 0.01%; ii. 在连续长 10,000 个 DNA 碱基的序列里没有间隙。

第二节 基因组组装

使用测序方法将待测物种的基因组生成需序列片段 read, 根据 reads 中间的重叠区域对片段进行拼接, 先是拼接成较长的连续序列 (contig), 再将 contigs 拼接成更长的允许包含空白序列 (gaps) 的 scaffold, 通过消除 scaffolds 的错误和 gaps, 将这些 scaffolds 定位到染色体上, 从而得到高质量的全基因组序列。

基因组组装的难题。①测序覆盖度可能存在差异。存在缺失区域或片段化严重; ②部分区域测序效果不佳。GC 含量极端或存在同聚物或低复杂度序列区段; ③部分区域组装困难, 如移动元件; ④高同源性、高拷贝数, 主要对于片段重复序列, 其为组装的最大障碍; ⑤多态性。

提升组装质量的最佳方法是使用更长读长并改善长程连续性。

N50

有两种, 一种对应 contig 一种对应 scaffold。把组装出的 contigs 或 scaffolds 从大到小排列, 当其累计长度刚刚超过全部组装序列总长度 50% 时, 最后一个 contig 或 scaffold 的大小即为 N50 的大小, N50 对评价基因测序的完整性有重要意义。N50 数值越大, 组装质量越好。

间隙

序列间隙 (Sequence gaps)。那些测序时遗漏的序列，这些序列仍保留在尚未挑选到的克隆中，这些序列仍保留在尚未挑选到的克隆中。

物理间隙 (Physical gaps)。构建基因组文库时被丢失的 DNA 序列，它们从已有的克隆群体中永久消失。i. 端粒或着丝粒附近高度重复序列缺少合适酶切位点，难以获得大分子 DNA 克隆；ii. 克隆载体中，高度重复序列不稳定，在扩增中丢失；iii. 某些基因的表达产物对宿主菌具有毒性，因此转染到宿主上容易将其杀死等原因。

覆盖面与测序深度

覆盖面 (Genome coverage)：随机测序获得的序列总长或单倍体总序列总长。基因组的所有 DNA 序列都将包括在内。

测序深度 (Sequencing Depth)：平均每个核苷酸的被测序次数。

计算

6.4.1 根据读长与基因组大小计算测序覆盖面

假设读长 (read length) 为 L ；基因组大小为 G ；且 $L \ll G$ 。

在基因组上观察到某条特定读段的概率 = L/G ；

在基因组上未观察到某条特定读段的概率 = $1 - L/G$ ；

未观察到 N 条读段的概率 = $(1 - L/G)^N \approx e^{(-N \times L/G)}$ ；

至少被一条读段覆盖的概率 = $1 - (1 - L/G)^N \approx 1 - e^{(-N \times L/G)}$

通过整理公式 $P = 1 - (1 - L/G)^N$ ：

①所需读段数 $N = \ln(1 - P) / \ln(1 - L/G)$ ；

②测序深度 = $N \times L/G$ ；

③至少被一条读段覆盖的概率 $\approx 1 - e^{-N \times L/G} = 1 - e^{(\text{测序深度})}$ 。

6.4.2 需要的 reads 量

已知 *E. coli* 的基因组大小 G 为 4.6Mb；读长 $L = 800bp$ 。需要多少 reads N 才能实现拥有大于等于 P 的概率（或，全基因组测序覆盖率 P ）能在参考基因组中检查到一个指定的特异性片段？

已知：

$$\text{所需读段数 } N = \frac{\ln(1 - P)}{\ln(1 - L/G)}$$

$$\text{测序深度} = \frac{N \cdot L}{G}$$

$$\text{至少被一条读段覆盖的概率} \approx 1 - e^{-N \cdot L/G} = 1 - e^{-\text{测序深度}}$$

要达到 $P = 0.9 \rightarrow$ 约需 $N = 13,000$ 条读段，测序深度约 2.3X；

要达到 $P = 0.95 \rightarrow$ 约需 $N = 17,000$ 条读段，测序深度约 3X；

要达到 $P = 0.99 \rightarrow$ 约需 $N = 26,500$ 条读段，测序深度约 4.6X。

因此，至少被一条 read 被覆盖的可能性与 $1 - e^{-\text{测序深度}}$ 成正比。

组装完成的两个阶段

①**草图序列**（draft sequences）。达到普通质量但尚未完成的基因组 DNA 序列，其精确度高于 90%，基因所处染色体位置已知，一般长度约 10kb。根据测序序列 DNA 的质量可分为四个等级：Phase 0= 测序覆盖面一次的 DNA 序列；Phase 1= 测序覆盖面 4 10 次的 BAC 克隆，BAC 及内部片段的位置和排列方向未定；Phase 2= 测序覆盖面 4 10 次的 BAC 克隆，BAC 及内部片段的位置和排列方向已定；Phase 3= 完成序列（Finished Sequences）。

②**完成序列**（finished sequences）。序列差错率（错误碱基数）低于 0.01% 的 DNA 序列，排列方向确定，内部不含间隙，一般测序覆盖率在 8 10 个单倍体基因组。

第三节 全基因组测序方法

由于在全基因组测序的各个阶段都有误差，因此应对重要区域进行优先测序。①外显子测序（whole exome sequencing, 1-2% of genome）；②环境共栖生物基因组测序（meta genome sequencing）；③单细胞 DNA 测序（single-cell sequencing）。

基因组重测序

对有参考基因组物种的不同个体进行的基因组测序，并在此基础上对个体或群体进行差异性分析。分为从头测序（de novo sequencing）与重测序（resequencing）。映射比对组装需要参考基因组（Mapping assembly）；从头测序不需要任何已知的基因组信息。

应用场景。①重复序列注释：串联重复序列注释（卫星 DNA、小卫星 DNA 以及微卫星 DNA 等）和散列重复序列（LTR、LINE、SINE 以及转座子序列等）；②非编码 RNA 的注释：MicroRNA、rRNA 以及 tRNA；③基因结构与功能的注释：基因的启动子、外显子、内含子；④基因预测。主要是特异序列、特异功能蛋白等的预测。⑤系统进化分析。

短读长测序与长读长测序

二代测序中的短读长测序：250-450bp, <600bp。短读长测序的局限：①难以解决基因组中复杂重复片段、高杂合、测序错误、覆盖不足或偏向性等；②组装间隙、测序/拼接错误等对于基因组中的复杂结构变异 (约 50bp) 等的鉴定有影响。

三代测序中的**长读长测序**：长度长测序的 N50 长度最长，Nanopore、Pacbio 为主要代表。其应用场景包括对于具有重要生物学意义的结构变异的识别；对于关键的高重复序列片段的识别。应用场景包括 • 为人类演化与遗传多样性的研究带来新发现；为比较基因组学领域（comparative genomics）带来技术变革，包括基因的结构变异、基因在不同物种中的表达差异。

长读长测序可以为单倍型定相（haplotype phasing）带来优势。单倍型定相在祖先双倍体和目标双倍体中进行比较，通过结合家系分析等手段，可以刻画基因重组率和突变率的演化、回答人群分化、分歧的问题；可以回答人群间基因交流的问题、人群有效群体大小的问题。

第四节 人类参考宏基因组

泛基因组图可表征多样的遗传变异。一个泛基因组变异图由两个要素构成：一是序列图，其节点代表有方向的 DNA 字符串，双向边代表连接关系；二是内嵌的单倍型路径（haplotype paths），这些路径代表了个体的基因组组装结果。

宏基因组的优势：①提升从短读长数据中检测小变异的准确性；②创建一个社区资源，以支持相关方法的开发及基于泛基因组的群体遗传学分析；③基于图的泛基因组参

考序列的关键优势在于其表征多态性结构变异的能力；④改进串联重复序列的表征，这些区域在原本利用短读长数据进行访问和分析时具有挑战性。

人类基因组多样性计划 (HGDP)。对来自 54 个地理、语言和文化多样性人群的 929 个基因组进行了测序，平均测序深度约为 35X，并分析了其中的变异。此外利用链读测序技术，对其中 26 个基因组的单倍型进行了物理定相 (Bergström et al. *Science* 2020)。

尼安德特人草图序列 (2010)

全基因组鸟枪法测序。尼安德特人作为现代人最亲近的演化近亲，曾在消失于三万年前广泛分布于欧洲和西亚地区。通过对三个个体的基因组进行测序，获得了超过 40 亿个核苷酸组成的尼安德特人基因组草图序列。尼安德特人与现今欧亚大陆人群共享的遗传变异，多于与现今撒哈拉以南非洲人群共享的遗传变异。

与现代 DNA 相比，古 DNA 含量很少，长度也很短，在每克骨骼或牙齿中可能只有 1pg-10ng。

针对古人类 DNA 的限制性内切酶富集。利用限制性内切酶来消减微生物 DNA 在文库中的比例，若一个带有 454 接头连接的文库分子被限制性内切酶切割，则无法进行扩增或测序，因为切割后产生的两个分子各自仅携带一个 454 接头。

将 reads 与人类、黑猩猩、河猴与家鼠的基因组进行比对与基因拼装。发现了尼安德特人与现代人类在演化树上存在某些等位基因共享。

第五章 单细胞测序

第一节 单细胞 RNA 测序技术简介

单细胞组学 (single-cell omics): 通过精细调控基因表达来编码细胞功能; 在不同条件和细胞类型下发生显著变化。单细胞组学是基于分子特征 (例如转录谱) 的研究手段。

自 2009 年以来, 单细胞研究与技术爆炸式发展。北大汤富酬教授发明的方法可以比 mRNA-seq 微阵列技术多检测 75% 的基因表达。

为何选择单细胞? 这是因为在研究中, 需要进行批量、单细胞、细胞关系的精确度量。

单细胞分析可以应用于多个领域, 包含发育生物学、癌生物学、老龄化等重要方向。

单细胞工作流程

分离单个细胞 → 高效扩增基因组 → 序列 DNA。

①**基于平板的平台** (SmartSeq2/3/MARSseq)。低吞吐量 (随着机器人技术的增加而增加); 全长测序, 深度增加; 可以与索引排序结合使用; 同源分析; 多组学灵活;

②**基于液滴的平台** (DropSeq, 10X Genomics Chromium)。首先建立一个条形码乳珠引物文库, 随后加入单细胞, 通过控制油滴量形成乳滴, 再进行放大测序。这种方法高吞吐量; 成本效益高; 3' 测序, 深度较低; 可以实现 50-65% 的细胞捕获效率, 可进行 CITE-seq 与 scATAC-seq。

在选择单细胞测序平台时**需要考虑的事项**。在输入上, 考虑需要的最小单元数与细胞条件, 是否需要哦 FACS 分选; 在实验设计上, 考虑收集样本的数量、多组学要求、每个样本所需的细胞数、控制批次效应、成本与可用性。

第二节 10X 单细胞 RNA 测序的工作原理

10x 的工作流程适用于多个组学分析流程。

单细胞 RNA-seq

首先是**输入阶段**。将组织或细胞系制备成高质量的单细胞悬液，要求细胞活性高、团聚少，这是后续数据质量的基础。

其次是**文库构建**。单细胞通过微流控体系被分隔并包裹进液滴，每个液滴中含有带有细胞条形码和分子标签（UMI）的引物。细胞裂解后，mRNA 被捕获并反转录，生成带有细胞身份和分子身份信息的 cDNA 文库。

第三步是**测序**。构建好的文库在高通量测序平台上进行测序，得到原始 reads，其中包含转录本序列、细胞条形码和 UMI 信息。

随后进入**数据分析阶段**，通常由标准化流水线完成：先将 reads 与参考基因组比对，再进行条形码识别与校正，基于 UMI 进行转录本计数，构建基因与细胞的表达矩阵，并开展基础表达分析，如质控、归一化、降维和聚类。

最后是**数据可视化与报告**。分析结果以图表和交互式方式呈现，用于展示细胞群组成、基因表达特征及生物学结论，支持进一步的下游解读与研究决策。

10x Genomics Single-Cell Multiome

首先是**核制备与转座 (Bulk transposition)**。从细胞中分离细胞核，在体外对核进行 Tn5 转座反应，使开放染色质区域被插入接头，从而为后续 ATAC 测序做准备。

接着进入**GEM 生成 (GEM generation)**。转座后的单核与 10x 条形码凝胶珠在微流控系统中被包裹进油包水液滴 (GEM)。理想情况下，每个 GEM 含一个细胞核和一颗条形码珠。

随后是**条形码标记与反转录 (Barcode attachment + GEM-RT)**。在 GEM 内同时完成两件事：一是 mRNA 的反转录，生成带有细胞条形码的 cDNA；二是 ATAC 片段被引入同一细胞条形码，从而实现 DNA（染色质可及性）与 RNA（基因表达）在单细胞层面的统一标记。

之后进行**GEM 破乳与清理 (Post GEM-RT cleanup)**，回收并纯化已完成条形码标

记的 DNA 与 cDNA 分子。

然后是**预扩增 (Pre-amplification)**。对 DNA 与 cDNA 进行共同扩增，以获得足够的文库起始量。

最后进入**文库分离与构建**阶段：ATAC 通道：经 SI-PCR 构建单细胞 ATAC 文库，用于分析染色质开放状态；Gene Expression 通道：cDNA 扩增、片段化、接头连接与 SI-PCR，构建单细胞转录组文库。

第三节 单细胞 RNA 测序分析

应用程序主要用于研究异质系统：细胞类型鉴定，细胞命运决策，肿瘤异质性，基因表达的随机性，细胞间基因调控网络的推断。

读长质控 → 读长 mapping 映射 → 量化 → 细胞质控 → 规范化 → 聚类 → 差异表达分析 → 功能注释。

细胞分析仪 (Cell Ranger)

将由 Illumina 测序仪生成的原始碱基调用 (.bcl) 文件的 **cellranger mkfastq** 解聚和原始文件转换为.fastq 文件。**cellranger count** 使用 **cellranger mkfastq** 生成的.fastq 文件，并执行细胞水平的条带编号、对齐、过滤、条带计数和 UMI 计数。

cellranger count 使用.fastq 文件进行对齐、过滤、条形码计数和 UMI 计数。它使用 10x 条形码生成特征条形码矩阵，确定聚类，并进行基因表达分析。Cellranger 会生成：①网页格式的 QC 报告 (.html)；②filtered_features_bc_matrix 在这个样本中看到的细胞水平条形码。包括 barcodes.tsv.gz，这个样本中看到的细胞水平条形码、features.tsv.gz，量化特征列表（通常为 Ensembl 基因）、matrix.mtx.gz，（稀疏）细胞和特征的计数矩阵。③possorted_genome_bam.bam，映射读取的 BAM 文件，用于速度和 CNV 分析；④raw_feature_bc_matrix.h5，适用于环境 RNA 去除。

一、下游信息分析

QC 和标准化；特征选择；整合以及批次校正；维度降维 (UMAP)；聚类细胞类型、注释差异表达基因、轨迹..... 可以通过 scanpy 与 Seurat。

质量控制 (Quality Control)

对于细胞，主要针对被溶解的细胞、死亡或衰弱的细胞、空的 GEMs、双或更多占用 GEMs、不同细胞周期阶段的细胞。QC 是单细胞 RNAseq 分析中的重要步骤，是为了去除低质量的细胞、死亡的细胞和双胞胎。QC 指标包括最小/最大 UMI；检测到的最小/最大基因；线粒体/核仁基因的百分比；具有表达细胞的基因；双色得分。

11.2.1 细胞周期因素对表达的影响

细胞周期的不同阶段具有相当不同的表达谱。使用基因来分类不同的阶段，以分类细胞的不同阶段。为此，应当排除异常单元格，尝试在定量/差异表达中将细胞周期作为考虑因素。

特征选择、降维与后续处理

特征选择：识别高度变异的基因 → 强调生物信号。有①vst、dsp (Seurat)；②广义线性可加模型 (GLM, SingCellaR) 等。

维度降维。这是由二维到一维的线性降维，需要进行主成分分析 (PCA)。

聚类。包含分层聚类、基于图的聚类 (Louvain、KNN)、k-means 聚类。

细胞类型注释。手动分配是不合理的，不仅因为耗时较长，需要专业知识，同时很有可能主观或不准确。有一些自动标注的软件，包括 scmap、MOANA、SingleR、SuperCT。基于参考的注释有 Symphony/Seurat/scArches 等。

11.3.1 整合

整合是整个过程中最关键的挑战。整合方法有 limma、Combat、Scanorama、Seurat CCA、Seurat WNN、Liger、Harmony。

传统的综合数据方法有：①成分分析，包括细胞类型富集；②柱状图比较百分比，软件有 DAsseq、MiloR。

轨迹分析。轨迹检测方法包括强制导向图 (FDG)、扩散图 (DFM)、Monocle3、PAGA (Scanpy)、Cellrank。

其他的选择包括细胞相互作用 (CellphoneDB)、发展轨迹 (TooManyCells)、拷贝数变异 (推断 CNV)。

AI 虚拟细胞挑战、药物开发、数字孪生。

一、Seurat

可能是最受欢迎的选择，支持良好且经常更新；拥有易于使用的数据模型和使用文档；用于丰富的内置功能，易于扩展。

第六章 基因组注释

第一节 搜寻基因

依赖于生物信息学分析。①依据基因结构的特点，用 ab initio 等软件预测，不依赖已有的表达序列（EST 或 cDNA）；②同源性比较，在同一物种或不同物种中查找已有的基因序列；③基序（motif）或功能域（domain）分析，用于基因功能分析。

基因结构特征

12.1.1 开放读框（open reading frame, ORF）

起始密码 ATG；终止密码 TAA, TAG, TGA；多数基因的 ORF 均多于 50 个密码子。对于同一序列，可能会有很多不同的 ORF 读框方式。

一、外显子

①密码子偏爱（codon bias）。如人类基因中，丙氨酸 (Ala) 密码子多为 GCA, GCC 或 GCT，而 GCG 很少使用。因此，在不同物种中出现了在概率上的摇摆密码子；②不含或含有较少的终止密码。

二、内含子

内含子与外显子的序列组成不同。内含子的 A/T 比例明显高于外显子，内含子有搞比例三种读框的终止密码。

内含子的组成特点：5' 剪接供体顺序 GT 和 3' 受体顺序 AG；近 3' 剪接位的一段富嘧啶区；前体 mRNA 加工所需分支点 A。

癌症中与异常剪接相关的体细胞突变的位置分布，内含子发生的突变较外显子更多 (Jung et al., *Nature Genetics*, 2015)。

体细胞突变也可以导致内含子其他分子事件 (Zhao et al. *Nucleic Acids Research*. 2021)。

三、碱基的组成规律

通常来讲, 真核生物外显子的保守性大于内含子。非编码的调控区 (5' UTR 和 3' UTR) 保守性小于编码区。由于密码子第三位的简并性, 单从 DNA 序列的相似性, 第 3 位要小于第 1、2 位。

同源性比较

当某一 DNA 序列含有这类基因时, 通过与已报道的其他基因序列对比, 可发现其中的相似性。存在某些完全相同的序列, 其他相似性主要集中在: ①ORF 读框的排列类似, 如等长的外显子和读码框; ②ORF 指令的氨基酸序列相同; ③模拟的多肽高级结构相似。

在获得新的 DNA 序列时, 通常会将该序列在已有数据库中进行序列比对或查询 (BLAST), 用以确定新获得的序列与已知的序列之间的关联。

12.2.1 同源性 (homology)

同源性 (homology) 系指起源于同一祖先但序列已经发生变异的序列之间的关联性。分布在不同物种间的同源基因称直向同源基因 (orthologous gene); 同一物种因基因倍增产生的同源基因称共生同源基因 (paralogous gene)。

同源性的查询主要是 DNA 序列与氨基酸顺序之间的区别。在比较时, 会出现部分的一致性氨基酸、部分的可取代氨基酸、部分的趋异氨基酸。比较氨基酸顺序的一致性与相似性时, 主要看:

①**一致性** (identity)。同源 DNA 序列的同一碱基位置上相同的碱基成员, 或者蛋白质中同一氨基酸位置相同的氨基酸成员的比例。

②**相似性** (similarity)。指同源蛋白质的氨基酸序列中一致性氨基酸和可取代氨基酸所占的比例。

在确定同源基因时, 氨基酸序列的比较以及蛋白质高级结构的模拟给出的结果更为可靠。

功能域注释

任何基因编码的蛋白质都由一些在高级结构水平具有特征性的功能域组成,如信号肽、受体区、激酶区、DNA 或 RNA 结合域等。功能域具有很强的保守性,关键的氨基酸组成及其排列顺序是相当保守的,也是鉴定基因功能的主要依据。功能域是目前注释软件确定基因功能的主要内容之一。

12.3.1 根据协同进化进行基因注释

基于机械的或物理的连锁 (physical linkage) 或功能的或互作的连锁 (functional linkage)。蛋白质常常由一个以上的多肽功能域组成,它们的组合不是随机的,彼此间存在相互作用。某些物种中这些功能域集合在同一个蛋白质,在其他生物中它们位于两个或多个独立的蛋白质,其间必定有互作关系。

一个例子,如信号传导蛋白激酶结构域就是植物、昆虫和哺乳动物信号传导蛋白质中共享的功能域。

12.3.2 基因注释软件

目前基因注释程序的编写主要依据两种信息内涵:①信号指令 (signal terms),如起始密码、终止密码、终止信号、剪接受体位与供体位顺序、多聚嘧啶顺序、分支点等保守的顺序组成;②内容指令 (content terms),如密码子使用偏好。

常用的注释软件,如 GenScan, 主要偏重于内容指令,而 FgeneSH 则着重于信号指令。

由于每种生物都有种属专一性的密码子偏好,也存在某些非保守的信号指令,因此注释软件的编写会注意不同物种的特点。超长基因注释常出现假阳性 (false-positive, 多注释) 或假阴性 (false-negative, 少注释)。

第二节 基因命名

迄今为止国际上还没有一个普遍公认的适合所有生物种属的基因命名规则。由于历史、习惯以及其它各种原因,基因命名中常常存在许多同名歧义,或者同义歧名的现象。许多基因在生物的不同发育阶段具有不同的功能,这一点也给准确的基因命名造成了实际困难。很多科学家都希望基因的命名标准化,曾经在 1997 年和 1999 年举行了两次有

关基因命名的研讨会，但因研究领域的不同以及基因命名本身存在的复杂问题, 无法达成一个统一的意见。

目前不同生物种属的基因命名规则仍由各相关领域的专家讨论分别制定, 然后推荐给研究者选择采用。

基因组注释是一个逐步深化的过程。根据 DNA 序列的特点进行基因组的注释不是一步到位的。在基因组注释的初期阶段，仅限于基因编码区的注释。随着对基因组结构与功能的研究与认识的加深，基因组注释逐步向非编码序列如调控元件，表观遗传修饰如 DNA 甲基化，非编码 RNA 如 miRNA 和 lncRNA 等扩展。

另一个值得注意的是有关染色质在细胞核的空间定位，如染色质在细胞核中有特定的疆域，复制与转录有特定的场所。

13.0.1 脊椎动物基因和蛋白质缩写规定

物种	基因简写	蛋白质简写
人类 (<i>Homo sapiens</i>)	<i>SHH</i>	SHH
小鼠 (<i>Mus musculus</i>)	<i>Shh</i>	SHH
原鸡 (<i>Gallus gallus</i>)	<i>SHH</i>	SHH
安乐蜥 (<i>Anolis carolinensis</i>)	<i>shh</i>	SHH
爪蟾 (<i>Xenopus laevis</i>)	<i>shh</i>	Shh
斑马鱼 (<i>Danio rerio</i>)	<i>shh</i>	Shh

注：SHH，基因 *sonic hedgehog* 的简称。

在基因命名符号 (symbol) 时，要求尽可能简短，通常在 3-8 个字母范围。如编码 cytotoxic T-lymphocyte-associated protein 4 的基因简称, 斜体，*CTLA4*；蛋白质简称，正体，CTLA4。

13.0.2 拟南芥基因注释 ID 编写规则

基因 ID 的编写规则：ATxGxxxx0, AT=organism; x=chromosome; G=gene; 00010=gene id. AT: *Arabidopsis thaliana*，代表拟南芥，00010 表示染色体 1 号座位。

基因的编号顺序。染色体短臂为北，长臂为南。基因序号北端开始，向南递增。

为何每个初定的基因 ID 号末尾均为 0(xxxx0)? 初始注释时以每条染色体含 9000 个代码为限。十位数是基因初始排序的个位数，如随后初始注释时以每条染色体含 9000

个代码为限。十位数是基因初始排序的个位数，如随后在基因附近发现新的基因，可在保留的 0 位逐个添加 1, 2, 3 等，如 AT4G00210 或 AT4G00212。

13.0.3 人类的基因注释分类

- ①Known gene。与人类已知 cDNA 和蛋白质顺序同源的基因；
- ②Novel gene。与脊椎动物 cDNA 或其它物种蛋白质同源的基因；
- ③Novel transcripts。与 novel 基因相似，但缺少明确的 ORF；
- ④Putative gene(假定基因)。有同源 EST 支持, 但缺少 cDNA 或 ORF；
- ⑤Predicted gene (预测基因)。数据库中至少有一个外显子支持, 但缺少 cDNA 或明确的 ORF；
- ⑥Pseudogene(假基因)。与已知蛋白质有 50% 的相似性，但 cDNA 残缺，在其它位点存在正常的同源基因的顺序。

一、人类基因命名

- ①属于孟德尔单基因性状，具有确定表型的基因，如 *BBS1* (Bardet-Biedl syndrome 1, Bardet-Biedl 综合征 1)
- ②和一个已知的标记连锁或相关，参与一个复杂性状的形成但未鉴定的基因，如 *IDDM6* (insulin-dependent diabetes mellitus 6, 胰岛素依赖糖尿病 6)。
- ③具有足够的结构、功能和表达的数据证明克隆的 DNA 片段是一个完整的基因，如 *COX8* (cytochrome oxidase subunit VIII, 细胞色素氧化酶亚基 VIII)。
- ④某个基因的无功能的拷贝，即假基因，如 *IL9RP1* (interleukin 9 receptor pseudogene 1, 细胞间质素 9 受体假基因 1)。

二、人类基因符号的命名规则

- ①基因符号应为大写的拉丁字母或大写的拉丁字母和阿拉伯数字的组合；
- ②理想的符号不应超过 6 个字符，基因符号在书写时应用斜体或加下划线；
- ③基因符号的第一个字符必须是字母；
- ④基因符号在书写时应在同一行，不允许在基因符号中使用上标或下标；

⑤除 HLA、免疫球蛋白 (immunoglobulin) 和 T 细胞受体 (T cell receptor) 基因外, 其他基因符号均不使用标点符号。

13.0.4 水稻注释基因类群的划分标准

①Homology(同源的)。与某一蛋白质氨基酸顺序完全一致或相当一致的基因, 有两种水平: 一致的命名 (same name); 可能的 (putative protein) 或类似的 (-like protein) 命名。

②Unknown(未知的)。具有全长 cDNA 或 EST(覆盖几乎整个基因范围) 支持但没有任何同源蛋白质记录的基因。

③Hypothetical(假定的)。由一个或几个注释软件认可的蛋白质, 但缺少 cDNA 或 EST 支持的基因。

第三节 基因功能验证

主要有正向遗传学 (forward genetics) 方法和反向遗传学 (reverse genetics) 方法。

反向遗传学 (reverse genetics) 方法

①上调基因的表达 (gain of function)。

②破坏基因的表达, 如基因剔除 (gene knockout); 下调表达 (gene knockdown), 如 RNAi 等; 进行基因突变, 如插入突变、基因组编辑 (ZFN,TALEN,CRISPR/Cas9, CRISPRi 等)。

利用反向 PCR 鉴定 T-DNA 所插入的基因。反向 PCR 可以借助相向的引物对进行扩增, 可以根据突变体的表型和 T-DNA 插入的基因来推测基因的功能。

第七章 基因组解剖

第一节 原核生物基因组

原核生物基因组主要为单一环状染色体。绝大多数细菌是条环状 DNA (circular chromosome)，少数古菌和细菌可有线状染色体，大小差异巨大 (0.5–10 Mb)。高度紧凑，基因密度高 (>85% 编码区)；非编码区少，没有长内含子；基因组规模可以直接反映生活方式，如寄生原核生物的基因组就较小。

操纵子结构 (Operon)

操纵子是基因组中的一段功能 DNA 片段，单个启动子调控一个或者一组基因。大肠杆菌基因组中，约 73% 操纵子只含一个基因，16.6% 含 2 个基因，4.6% 含 3 个基因，6% 含 4 个及以上基因。

古菌和细菌的操纵子有所不同。以大肠杆菌色氨酸操纵子为例，不同操纵子作用于分支酸到色氨酸的不同反应阶段；对于古菌，操纵子只含一个基因的可能性较高。

15.1.1 色氨酸操纵子

当色氨酸含量低，打开操纵子。没有色氨酸阻遏蛋白不活化，RNA 聚合酶可以启动转录。当结构基因全部表达时，合成色氨酸。

当色氨酸含量高，关闭操纵子。阻遏蛋白-色氨酸复合物形成一个同源二聚体，并且与色氨酸操纵子紧密结合，因此可以阻止转录，该现象的结果是不再合成色氨酸。

质粒

质粒是存在于原核细胞内、独立于染色体之外的小型环状 DNA 分子。可自主复制，通常拥有自己的复制起点，一般由 1-数百 kb 的 DNA 组成，大质粒的长度大于 100kb。

15.2.1 霍乱弧菌的基因组

霍乱弧菌基因组由两条环状染色体组成，是原核生物中罕见的双染色体模式。

呈“核心-附属”基因组加工。Chr1 负责核心生命功能，复制、转录、翻译、核心代谢相关基因；Chr2 含有更多辅助功能基因，如环境适应、应激反应、部分代谢与毒力相关基因。Chr1 一般先启动复制；Chr2 的复制启动与 Chr1 的复制进程有一定协调，以保证整个细胞分裂周期的同步性。

第二节 真核生物基因组、细胞器基因组

线粒体

真核生物的能量代谢中心，线粒体通过氧化磷酸化产生大量能量（ATP），是真核生物中除了细胞核外唯一含有 DNA 的细胞器。

①**氧化磷酸化**（Oxidative phosphorylation）。通过电子传递链建立质子梯度、驱动 ATP 合成。

②**代谢中枢**。是多条代谢通路的交汇点，如三羧酸循环（TCA）、脂肪酸氧化等。

③**信号与命运调控**。参与细胞凋亡、活性氧（ROS）生成、钙离子稳态调控。

物种间线粒体基因组大小比较。动物线粒体基因组大小比较恒定，植物线粒体基因组大小可相差 10 倍，叶绿体基因组大小恒定。

线粒体基因组的大小与生物复杂性无关，酵母的线粒体基因组大小为 75kn，而人类的线粒体基因组大小为 16569bp。

16.1.1 人类线粒体基因组结构

全长 16569bp，双链闭环分子。外环为重（H）链，内环为轻（L）链，编码 37 个基因：13 种多肽链、22 种 tRNA、2 种 rRNA。**总体特点**：编码密度极高，没有内含子，基因之间间隔非常短，甚至存在部分基因重叠。

无内含子。控制区称为 D-loop，是非编码区，1000bp，重链复制起始点，同时含有轻重链转录启动子。4 个高度保守序列，高突变率，平均每 150 年就有 1 个突变。

高等植物叶绿体基因组

分子形式上多为双链环状 DNA，大小范围约 120-170kb。结构十分紧凑拷贝数高，每个细胞有大量叶绿体；实际上是一个高拷贝小基因组。叶绿体基因组大小一般在种内是恒定的。

拥有典型的**四分结构**。大单拷贝区 (Large Single Copy)，含有多数光合作用相关基因；小单拷贝区 (Small Single Copy)；倒位重复区 (Inverted Repeats)，含有 2 段。

细胞器基因组的其他特点

- ①小型环状 DNA，非编码区少，结构紧凑；
- ②高拷贝数，非孟德尔/细胞质遗传，多为母系遗传；
- ③半自主，具有自己的转录翻译系统，但高度依赖核基因组；
- ④起源于内共生，经历了大量基因向核基因组的转移；
- ⑤线粒体基因组以能量代谢相关基因为主，高突变；
- ⑥叶绿体基因组以光合作用相关基因为主，结构相对保守。

16.3.1 多拷贝现象

细胞器基因组为多拷贝，人体细胞线粒体数目平均为 800 个，每个线粒体有 10 个基因组拷贝；酵母细胞平均 65 个线粒体，每个线粒体 100 个基因组拷贝。

16.3.2 核线粒体 DNA 片段

核线粒体 DNA 片段 (NUMT, Nuclear Mitochondrial DNA segments)。线粒体 DNA 在细胞应激 / 损伤 / 自噬等过程中，片段释放到细胞质，少数片段进入细胞核，通过**非同源末端连接** (NHEJ) 等方式整合进核基因组。一旦整合成功，就像普通核 DNA 一样被复制、遗传。

第三节 基因组研究方法与发展

一代测序（双脱氧链终止测序，Sanger 法）

沿革：①1977 年 Sanger 采用此方法揭示了噬菌体 ϕ X174 基因组序列，这是人类历史上首个完整 DNA 基因组序列；②1979 年 Staden 等人改进了鸟枪法测序，通过计算机辅助序列拼接思想，为后来的大规模测序奠定基础；③1981 年，Messing, 单链 M13 噬菌体克隆载体的方法。使模板制备更高效，推动了 DNA 测序自动化；④1987 年，Smith 和 Hood 等人开发了基于荧光的全自动 sanger 测序仪，DNA 测序进入自动化时代；⑤2004 年国际人类基因组计划（HGP），首个人类基因组图谱正式完成。

测序性能上，Sanger 法的测序读长可达 1000bp，准确率高达 99.999%，被誉为基因检测的金标准，因此也是人类基因组计划的主要测序方法。限制为测序费用高、通量低，难以满足大规模样本或群体测序的需求。

17.1.1 步骤

①dNTP 参与正常 DNA 合成。

②荧光基团标记的 ddNTP 终止 DNA 合成，激发光射后会有不同的光学颜色。ddNTP 是 Sanger 链终止测序法的关键试剂。

③得到 N 条相差一个碱基的序列。

④将片段从小到大排列，逆向读取。

第二代测序技术（Next Generation Sequence, NGS）

高通量测序技术（High-throughput sequencing, HTS）是对传统 Sanger 测序革命性的改变，一次对几十万到几百万条核酸分子进行序列测定，因此称其为下一代测序技术（next generation sequencing, NGS）足见其划时代的改变。

二代测序最大的成果是降低了测序成本。目前测定一个人类的全基因组仅需小于 100 美元的成本即可完成。

17.2.1 二代测序平台

- ①Roche/454 FLX: 2004;
- ②Illumina Solexa Genome Analyzer: 2006;
- ③Applied Biosystems SOLiD™ System: 2007;
- ④Helicos Heliscope™ : 2008;
- ⑤Pacific Biosciences SMRT: 2010;
- ⑥华大智造 (MGI) : DNBSEQ™ 2014, T20, T7

三代测序

单分子测序, 不需要任何 PCR 的过程, 有效避免因 PCR 偏向性而导致的系统错误。属于典型的长读长测序 (Long-read sequencing, LRS)。

平台: ①PacBio, Single Molecule Real-Time sequencing, 实时检测单分子聚合酶的**荧光信号**。代表仪器 Sequel II; ②Oxford Nanopore, Nanopore sequencing, 检测 DNA 通过纳米孔时的**电流变化**。代表仪器 PromethION、MinION。

核心优势: ①超长读长: 10 kb–100 kb 甚至更长, 可直接跨越重复序列与结构变异区; ②单分子测序: 无需 PCR, 避免扩增偏倚; ③实时检测: 可同步观察碱基掺入与修饰, 如甲基化; ④结构变异检测更全面: 适用于复杂基因组与多倍体分析。

2022 年公布的 T2T-CHM13 就是由 PacBio 与 Oxford Nanopore 辅助测出的。上一代的 GRCh37-GRCh39 仅能覆盖 92% 的人类基因组区域。

第八章 基因组的复制与进化

第一节 基因组复制模型的发现

1953 年 Watson 和 Crick 发现 DNA 结构的双螺旋模型。①两条平行双链的碱基互补排列；②DNA 双链相互缠绕形成有规律的双螺旋结构；③互补 DNA 双链的走向相反。

DNA 复制的拓扑学问题本质上是 DNA 解链问题。1955 年，Stent 与 Levinthal 发表在 PNAS 上的文章采用同位素标记 (^{32}P) 研究 DNA 的复制模式。这是因为 ^{32}P 容易衰变，缺乏稳定性，代表着 DNA 的拓扑学问题研究进入了实验研究阶段。

1957 年，Taylor 在蚕豆 (*Vicia faba*) 上的实验在表型上发现了染色体水平的半保守复制。

Meselson-Stahl Experiment 首次在分子水平上证明 DNA 的**半保守复制**：DNA 复制时，亲代 DNA 的两条链解开，每条链作为模板合成新的互补链，每个子代 DNA 分子由一条亲代链和一条新链组成。

1963 年，H. John F. Cairns 首次观察到 E. Coli 环状 DNA 双链的 θ 复制模式。

第二节 基因组复制的过程和特点

基因组复制的过程

①解旋酶解开螺旋并分离链段；

②引物酶连接 RNA 引物；

③DNA 聚合酶复制每条链，以 5'→3' 方向进行（在前导链上连续复制，而在滞后链上复制冈崎片段）；

④外切酶和 DNA 聚合酶用 DNA 核苷酸替换引物；

⑤连接酶将所有片段封闭起来。


基因组复制的特点：①**快速**。100 1000 bp/秒；②**完整**。本质上，每个碱基必须被复制。③**准确**。每 10^{10} 个碱基中才有一个错误。

19.1.1 后随链合成的冈崎模型

前导链沿 5'→3' 方向连续复制，子链合成方向与复制叉行进方向相同；后随链沿 5'→3' 方向非连续复制，子链合成方向与复制叉行进方向相反。**冈崎片段**（Okazaki fragments）是在 DNA 后随链不连续复制中，沿着模板链合成的新 DNA 片段。冈崎片段平均长度：真核生物为 100 200 bp，原核生物为 1000 2000 bp。

在两段冈崎片段中总是存在一个 DNA-RNA 缺口，这使得外切酶能够识别并去除引物。

19.1.2 复制体 (Replisome)



DNA 复制过程依赖的多种酶形成复制体 (Replisome)。

一、DNA 拓扑异构酶 (Topoisomerase)

在自然放松状态下，B-DNA 每一圈大约含 10.5 个碱基对。当 DNA 被 **过度缠绕**时，螺旋圈数减少，形成 **正扭转 (+, overwound)**；当 DNA 被 **松解缠绕**时，螺旋圈数增加，形成 **负扭转 (-, underwound)**。

在复制等过程中,复制机器沿 DNA 前进会在前方产生**正超螺旋**,使 DNA 进一步发生空间层面的缠绕 (supercoiling)。

DNA 的扭转状态 (twist) 决定并驱动其超螺旋拓扑 (supercoil) 形成,这是复制、转录中必须调控的物理属性。

DNA 拓扑异构酶能破坏或连接糖-磷酸骨架,产生瞬时的 DNA 单链或双链断链,从而改变 DNA 的拓扑结构。

一型 DNA 拓扑异构酶。切开 DNA 双链中的一条 → 没有被切的互补链通过缺口 → 连接缺口。不需要 ATP。

二型 DNA 拓扑异构酶。结合 DNA → 产生双链断裂 → 未断裂的 DNA 穿过缺口 → 连接缺口需要 ATP。

二、DNA 解链酶 (Helicase)

结合 DNA 单链,定向移动 ($5' \rightarrow 3'$ 或 $3' \rightarrow 5'$),ATP 水解促使解链酶沿 DNA 链滑动。拓扑异构酶与解链酶的区别在于前者破坏糖磷酸骨架,后者破坏氢键。

解螺旋后的 ssDNA **保持结构稳定**的方法。①高亲和结合单链 DNA;②避免单链 DNA 被核酸酶降解;③阻止双链 DNA 退火或形成其他非单链构型;④单链结合蛋白结合的 DNA 碱基仍暴露在外,可被聚合酶复制;⑤复制完成后,单链结合蛋白从 DNA 模板脱落,可被重复利用。

在解旋后,DNA 前导链模板复制快速推进,**单链结合蛋白**迅速结合后随链模板。在原核生物中进行该操作的是 SSB (Single-strand binding protein);真核生物中进行该操作的是 RPA (Replication protein A)。

三、DNA 聚合酶 (Polymerase)

Arthur Kornberg 于 1957 年首次从大肠杆菌中分离出 DNA 聚合酶,1959 年荣膺诺贝尔奖。DNA 聚合酶的 Fingers 部分催化 dNTP 连接,进行双镁离子催化反应;Palm 部分结合 DNA 模板-引物。与磷酸骨架结合,有非碱基特异性。Connection 部分是核酸外切结构域。

DNA 聚合酶 I 具有**三种酶活性**。Klenow fragment: Hans Klenow 1970 年用枯草杆菌蛋白酶处理大肠杆菌 DNA 聚合酶 III 时,得到的两个片段中分子量较大的一个。

DNA 聚合酶的双镁离子催化反应。 Mg^{2+} 位于 DNA 聚合酶的活性中心,可催化引物的 3-OH 与 dNTP 的磷酸基团间形成磷酸二酯键。 Mg^{2+} 与 DNA 骨架上的磷酸基团

结合，稳定 DNA 双链结构。 Mg^{2+} 对 DNA 聚合酶活性有重要影响。

DNA 聚合酶的三种酶活性。①3'→5' 核酸外切酶活性与碱基错配修复。②5'→3' 核酸外切酶活性与引物切除。切口平移（nick translation）是利用 5'→3' 核酸外切酶活性在体外向 DNA 分子引入放射性标记的方法。③5'→3'DNA 聚合酶活性。

原核生物的基因组复制

19.2.1 复制子

复制子（replicon）是 DNA 的复制单位，由复制起始点、复制顺序和复制终点组成。复制子是源于一个起点的复制叉生成的全部 DNA 区域。

物种	染色体数目	复制子数目	基因组大小 (Mb)
<i>E. coli</i> （大肠杆菌）	1	1	4.6
<i>S. cerevisiae</i> （酿酒酵母）	16	350	13
<i>Drosophila</i> （果蝇）	4	1,200–20,000	80
Human（人）	22 + X/Y	~30,000	3000

大肠杆菌的复制起始点是 *oriC*。包括 13bp 的重复序列（GATCTNTTNTTTT），此为单链 DNA 的形成区域；同时还有 DnaA 蛋白的结合区域，也是零散的重复序列，内容为（TTATCCACA）。

19.2.2 大肠杆菌复制起始和延伸

大肠杆菌 DNA 的复制速度为 1000 bp/s。大肠杆菌染色体全长约 4600 kb，双向复制每分钟约前进 120 kb，理论上约 40 分钟可完成整个染色体的复制。实际上大肠杆菌每复制一代约 20 分钟，因为上一轮复制尚未完成时，第二轮复制又开始。

19.2.3 细菌的 DNA 聚合酶

酶的组成	亚基	3'→5' 外切酶活性	5'→3' 外切酶活性	功能
DNA 聚合酶 I	1	+	+	DNA 复制与修复
DNA 聚合酶 II	1	+	—	DNA 修复
DNA 聚合酶 III	至少 10	+	—	主要复制酶
DNA 聚合酶 IV	1	—	—	倾向差错修复
DNA 聚合酶 V	1	—	—	倾向差错修复

19.2.4 滑行夹（sliding clamp）及其加载机制

DNA 聚合酶 III 全酶 (Holoenzyme) 的组成：核心聚合酶通过 τ 蛋白与 γ 复合体（夹加载器）相连，滑行夹负责将聚合酶稳定固定在 DNA 上，从而显著提高复制的过程性。

ATP 依赖的夹加载过程：夹加载器结合 ATP 后使滑行夹打开，并在引物-模板连接处特异性装载到 DNA 上；随后 ATP 水解，加载器释放，聚合酶与滑行夹结合并开始高效延伸。

管来源不同（细菌 β 夹、噬菌体 gp45、真核 PCNA），其环状结构与功能高度保守。ATP 驱动的滑行夹加载是实现高过程性 DNA 复制的关键分子机制。

19.2.5 大肠杆菌复制终止

大肠杆菌基因组中已经鉴定了 7 个 Ter 序列，均为 Tus 识别位点。Tus-Ter 复合物具有方向性阻断特性：复制叉从允许方向可以通过，而从相反方向则被阻断。

在环状染色体上，复制从起点出发形成两个方向相反的复制叉，并在终止区相遇。该终止区含有多个 Ter 序列。Tus 与 Ter 结合后，通过特定碱基翻转并锁定 DNA 解旋酶 DnaB，从而阻止复制叉继续前进。

真核生物的基因组复制

酵母基因组复制起始点 (ARS, autonomously replication sequence, 自主复制序列)。由三部分组成：①B3，ABF1 因子的结合位置，产生扭曲力，促使 B2 解链；②B2，起始解链区；③A 和 B1，长 20bp，ORC（起始识别复合物）的识别序列，为复制调控区。




图 11.7 原核生物和真核生物 DNA 复制起始点比较（引自 Weinberg DH 等，1990）

原核生物与简单真核生物复制起始点具有相似的结构。都有**复制起始蛋白结合区**和**复制泡形成区**，复制起始点的主要功能是促使 DNA 双链的开放，并在单链形成复制复合物。

19.3.1 高等真核生物 DNA 复制起点




图 11.8 HoxB 基因座 DNA 复制起始点的差别利用

“**松弛复制点**” (relaxed replicator)：复杂真核生物基因组复制起始点序列缺少一致顺序。

与复制起始点结合的 ORC 有很强的保守性。ORC 在细胞的整个周期始终与复制起始点结合，仅在细胞分裂的中期短暂离开。

细胞中有许多潜在的 DNA 复制起始点位置，可在不同的时间或状态下差别起始 DNA 复制。

在个体发育的不同阶段，复制起始点序列专一性均会发生重大改变，并涉及大范围 DNA 复制起始点的更换，这与基因的差别表达以及染色体构型重建密切相关。

虽然不同生物中的复制基因和起始蛋白等会有很大差异，但 DNA 复制的起始过程都符合识别复制起点-加载解旋酶-组装复制体这个基本程序。


复制相关蛋白功能	真细菌	真核生物	SV40	HSV-1	古菌
复制起点识别与解旋	DnaA	ORC	T-ag	UL9	Cdc6
解旋酶加载	DnaC	Cdc6 / Cdc18	T-ag	UL8	Cdc6
解旋酶	DnaB	Mcm2-3-4-5-6-7	T-ag	UL5	Mcm
引物酶	DnaG	Pol α -primase	Pol α -primase	UL52	primase
单链 DNA 结合与稳定	SSB	RPA	RPA	UL29	RPA
过程性夹	Pol III 的 β 亚基	PCNA	PCNA	UL42	PCNA
夹加载器	Pol III 的 γ 复合体	RFC	RFC	—	RFC
DNA 聚合酶	PolC, PolA (Pol III, Pol I)	PolB (Pol α , Pol δ , Pol ϵ)	PolB (Pol α , Pol δ)	UL30	PolB, PolD
成熟核酸内切酶	RnhA	Fen1	Fen1	—	Fen1
DNA 连接酶	Ligase	Ligase I	Ligase I	—	Ligase I

19.3.2 人类主要 DNA 聚合酶

Polymerase	Gene	Catalytic subunit	Accessory subunits (kDa)	3'→5' exonuclease	Fidelity	Primary function
Pol α	<i>POLA1</i>	 1462 aa	 <i>PRIM1</i> <i>PRIM2A</i> <i>PRIM2B</i>	No	10^{-4} – 10^{-5}	RNA and/or DNA primers
Pol β	<i>POLB</i>	 335 aa	None	No	5×10^{-4}	Base-excision repair
Pol γ	<i>POLG1</i>	 1239 aa	 <i>POLG2</i>	Yes	10^{-5}	Mitochondrial DNA replication and repair
Pol δ	<i>POLD1</i>	 1107 aa	 <i>POLD2</i> <i>POLD3</i> <i>POLD4</i>	Yes	10^{-5} – 10^{-6}	Lagging-strand synthesis DNA repair
Pol ϵ	<i>POLE</i>	 2286 aa	 <i>POLE2</i> <i>POLE4</i> <i>POLE3</i>	Yes	10^{-6} – 10^{-7}	Leading-strand synthesis

缺乏 5'→3' 外切核酸酶活性时，真核生物引物切除采用 RNA 酶，如 FEN1 和 Rnase H。

19.3.3 复制与转录冲突



转录复合物是复制叉经常遇到的内源性障碍之一，转录-复制冲突可诱导 DNA 复制叉停顿、DNA 重组、DNA 断裂和突变，对基因组稳定性构成了潜在威胁。复制与转录

冲突主要分为两个方向。

为什么会发生复制与转录冲突？①DNA 复制速率是转录速率的 5 倍以上；②哺乳动物细胞周期为 8-10h；③>800kb 超长基因的转录 >10h。

为了避免这个问题，在真核生物中，DNA 复制和转录机器占据不同的细胞核区域，并在 S 期的不同时间点发挥作用。

但是复制与转录冲突还是会发生，影响复制叉的稳定性，导致复制叉停滞、双链断裂或复制叉反转。

复制与转录冲突导致人类疾病。长基因中转录-复制冲突导致 R-loop 形成，引起染色体脆性位点不稳定性，产生染色体缢裂或断裂。


19.3.4 DNA 末端复制问题

根据半保留复制，由于缺乏复制染色体 5' 末端的方法，随着每个细胞的二倍体化，染色体会缩短，最终达到临界点导致细胞衰老或死亡。

物种	端粒重复序列	端粒酶 RNA 模板序列
人类	5'-TTAGGG-3'	5'-CUAACCCUAAC-3'
<i>Oxytricha</i>	5'-TTTTGGGG-3'	5'-CAAAACCCCAAAACC-3'
四膜虫 (<i>Tetrahymena</i>)	5'-TTGGGG-3'	5'-CAACCCCAA-3'

末端复制问题解决的关键：特定的复制起点（端粒）和 DNA 聚合酶（端粒酶）。成果获 2009 年诺贝尔生理学或医学奖。端粒的功能：①作为新的复制起点；②保护染色体末端不被重组或降解。

一、端粒酶



端粒酶本质上是一种以自身 RNA 为模板的逆转录酶。

工作过程：端粒酶首先结合染色体 3' 端单链突出端，端粒酶 RNA 中的模板序列与端粒末端碱基互补配对；随后端粒酶的催化亚基在 RNA 模板指导下，向 DNA 的 3' 端逐个添加端粒重复序列。完成一次合成后，端粒酶沿新合成的重复序列向前移位 (translocation)，再次以同一 RNA 模板继续延长 3' 端，从而实现多轮重复加长。当 3' 端被充分延长后，常规 DNA 聚合酶再以 RNA 引物为起点合成互补链，最终完成端粒的复制。

特性	DNA polymerase	Telomerase
需要 3'-OH 引物	是	是
需要 dNTPs	是	是
具有过程性	是	是
产生单链 DNA	否	是
需要 DNA 模板	是	否
可作用于任意序列	是	否

端粒结构决定了细胞分裂的次数上限。疾病某种程度上是长寿的代价，很多疾病，包括大多数癌症是人的寿命到达一定程度才能显现。

二、T-loop 结构

T-loop 结构保护染色体末端不被降解。护卫蛋白 (Shelterin) 与 DNA 末端结合，使 G 链末端形成 T 环结构 (telomere loop, T-loop)，同时也能调节端粒长度。这种 T 环结构普遍存在，单细胞原生生物的染色体末端也采取 T 环策略。

第三节 真核生物基因组复制的调控

基因组复制与细胞分裂周期一致性。DNA 复制发生在细胞周期的 S 期，一个细胞周期内基因组完成一次复制。

- M 期：细胞核与细胞发生分裂；
- G₁ 期：转录、翻译等生理生化时间；
- G₂ 期：细胞快速生长并大量合成有丝分裂所需蛋白质等物质；
- S 期：基因复制。DNA 复制发生在细胞周期的 S 期，一个细胞周期内基因组完成一次复制。


20.0.1 前复制复合物 (pre-RC)

pre-RC 的组装调控由 S 期开始。复制资格因子结合 ORC，启动 pre-RC 组装。细胞周期蛋白 (Cdc) 与依赖细胞周期蛋白的蛋白激酶 (CDK) 组成有丝分裂促进因子 (MPF) 异源二聚体，这是调控有丝分裂起始的关键因子。CDK 可促使细胞从 G1 期进入 S 期，也可以抑制 G2 期细胞的 DNA 获得复制资格。

项目	G1 期	S 期
CDK 活性	低	高
解旋酶加载	是	否
解旋酶激活	否	是

- ①转录活跃的基因在 S 初期复制，非转录区在 S 晚期复制。
- ②S 初期启动的复制起始点具有组织特异性。

20.0.2 细胞周期检查点



20.0.3 细胞周期中的 DNA 损伤调控

E2F 转录因子家族是细胞 S 期的主要调控因子。E2F 的转录活性在整个细胞周期中收到严格调控。在 E2F 活性正常的细胞中，复制应激延长了 E2F 靶基因的表达，稳定复制叉，减缓复制压力并减少 DNA 损伤。致癌基因导致的高 E2F 活性也产生复制应激，同时可能使细胞能够耐受复制应激。

近 2/3 的癌症突变源于 DNA 复制过程中随机发生的错误。

第四节 突变与人类演化

人类进化的 5 个基本动力元素。包括突变 (mutation)、重组 (recombination)、选择 (selection)、漂变 (drift) 与迁徙 (migration)。

突变是生物的基本特性。突变是一种生物学现象, 指生物个体基因组, 包括病毒, 核外染色体核苷酸序列发生的改变。地球上现存及消失的生物都有发生 DNA 突变的潜能。突变既可为生物进化提供原材料, 也可能对生物个体的生存产生严重影响。

基因组突变

21.1.1 DNA 复制差错的来源

DNA 复制的初始准确性首先来自碱基互补配对和 DNA 聚合酶对底物的选择性, 但仅依赖这些机制时, 错误率仍然较高。随后, 具有 3'→5' 外切酶活性的校对 (proofreading) 进一步纠正错误掺入的碱基, 使错误率显著下降。最后, 复制完成后由错配修复 (mismatch correction) 系统清除残余错误, 将总体复制错误率降至极低水平 (约 10^{-9})。

不同 DNA 聚合酶的保真度: 跨损伤合成聚合酶 (如 Pol η) 错误率最高, 而负责染色体复制的 Pol δ 和 Pol ϵ 在校对与修复机制配合下具有最高的复制准确性。

新突变在基因组中出现的速率与物种的有效种群规模成反比。微生物拥有最大种群数量且突变率最低。

21.1.2 单点突变 (Point Mutation)

Single nucleotide variants (SNV), 单核苷酸变异。包含替换、删除与插入。在替换 (即碱基突变) 上, 又分为两种基本类型: **转换** (transition) 与 **颠换** (transversion)。嘌呤之间 ($A \leftrightarrow G$) 或嘧啶之间 ($C \leftrightarrow T$) 的替换称为转换; 嘌呤与嘧啶之间 ($A/G \leftrightarrow C/T$) 的替换称为颠换。虽然理论上颠换的可能组合更多, 但在人类基因组中, 转换发生得更频繁, 其比例约为 $T_i : T_v \approx 2$ 。

一、突变效应的类型

①**同义突变**。突变前后的密码子指令同一氨基酸, 通常发生在密码子第 3 位碱基。

②**错义突变/非同义突变**。突变前后的密码子指令**不同氨基酸**突变，发生的位置在密码子的**第 1 位和第 2 位**碱基。

③**终止突变**。使原来编码氨基酸的密码子变成**翻译终止密码**，产生残缺的蛋白质。


④**连读突变**。与终止突变相反，终止密码变成指令某一氨基酸的密码子，使**翻译继续进行**。

21.1.3 结构变异 (Structural Variation)

Structural variation, SV。包括：

- ①**缺失 (deletion)**，即一段基因组序列丢失；
- ②**插入 (insertion)**，包括新的外源序列插入或**可移动元件插入**；
- ③**重复 (duplication)**，可表现为相邻的**串联重复**或分散到不同位置的**散在重复**；
- ④**倒位 (inversion)**，即序列方向发生反转但位置不变；
- ⑤**易位 (translocation)**，指不同染色体或远距离基因组片段之间发生交换。

21.1.4 基因组变异注释



DNA 复制错误与人类进化

21.2.1 人类基因组的演变

基因组复制是一种常见的进化现象。

类人猿重复爆发（great ape burst of duplications）。沿着类人猿系统发育树，约 6–8 百万年前、接近人类-黑猩猩分化时期的祖先分支，此阶段重复速率显著升高，远高于其他分支，显示出一次集中发生的大规模片段重复事件。在此之后，不同类人猿谱系（人、黑猩猩、倭黑猩猩、大猩猩、猩猩等）重复速率再次下降并呈现谱系特异差异（Sudmant et al., *Genome Res* 2013）。

人类特异性的基因家族扩张。与其他类人猿相比，现代人群在许多基因家族中都具有更高的拷贝数，且这种扩张在不同人群中普遍存在，而在黑猩猩、大猩猩、猩猩等近缘物种中并未出现。多数与**神经发生、神经元迁移和皮层发育**有关（Sudmant et al., *Science* 2010）。

人类在近期进化中通过基因重复产生了新的调控因子，这些基因通过影响神经祖细胞行为，可能推动了人类大脑体积和复杂度的扩展。①**ARHGAP11B**（约 5.3 百万年前产生）是一个截短重复基因，主要在基底放射状胶质细胞中表达，可增加神经元产生并扩展皮层下室区；②**NOTCH2NL**（小于 3 百万年前产生）为部分重复基因，在放射状胶质细胞中表达，通过调控 NOTCH 信号延缓神经前体细胞分化，从而延长增殖期。

21.2.2 人类基因组多样性的产生

一、高海拔耐受

西藏人群高海拔耐受的关键基因。

Study	Publication	Technology	Genes identified
Beall et al.	<i>PNAS</i> 2010	Illumina 610-Quad	<i>EPAS1</i>
Simonson et al.	<i>Science</i> 2010	Affymetrix 6.0	<i>EGLN1</i> , <i>PPARA</i>
Yi et al.	<i>Science</i> 2010	NimbleGen 2.1M exon capture array + Illumina platform	<i>EPAS1</i>
Bigham et al.	<i>PLoS Genet</i> 2010	Affymetrix 6.0	<i>EGLN1</i>
Peng et al.	<i>MBE</i> 2011	Affymetrix 6.0	<i>EPAS1</i> , <i>EGLN1</i>
Wang et al.	<i>PLoS One</i> 2011	Illumina 1M-Duo v3	<i>EPAS1</i> , <i>EGLN1</i>
Xu et al.	<i>MBE</i> 2011	Affymetrix 6.0	<i>EPAS1</i> , <i>EGLN1</i>
Yang et al.	<i>PNAS</i> 2017	Affymetrix 6.0	<i>EPAS1</i> , <i>MTHFR</i>

同时，藏族人群还携带一些普遍的突变位点。这些位点 90% 以上的藏族人群携带，但是其他人群低于 3%，大多数人群几乎不存在：3.4-kb deletion（TED）；TMEM247（rs116983452）。

不同大陆高原人群和动物在低氧环境下发生的趋同进化（convergent high-altitude adaptation）。**安第斯高原、埃塞俄比亚高原和青藏高原**三个独立高海拔地区的人类群体及当地动物，尽管这些群体在进化历史上彼此独立，它们在适应高原低氧环境时，反复靶向相同或功能相近的基因通路，尤其是与缺氧感应、血红蛋白功能、血管调控和能量

代谢相关的基因。其中 **EPAS1 (HIF-2 α)** 在不同高原人群中多次受到正向选择，是高原适应的关键分子节点 (Witt et al., 2019)。

二、去色化

人类皮肤去色化 (depigmentation) 在不同人群中通过不同遗传途径演化形成的模型。现代人群从非洲祖先分化后，**欧洲人与东亚人并非通过同一组基因发生皮肤变浅**，而是经历了相互独立的遗传路径。人类皮肤颜色变浅并非一次单一事件，而是在不同地区通过不同基因、在相似选择压力下发生的趋同进化结果。与肤色相关的关键位点在全球人群中的等位基因频率差异：①**KITLG** 相关变异在多个非洲以外人群中广泛存在；②**OCA2** 的特定变异主要与**欧洲人群**的去色化相关；③**MC1R** 的变异则更多与**东亚人群**的去色化相关。

同时，不同地理与遗传背景的人群，在相似环境压力下可表现出相似表型特征。热带地区普遍面临高紫外线环境，尽管这些人群分属非洲、南亚、东南亚、大洋洲和美洲原住民等不同谱系，它们在深色皮肤外观上呈现出相似性。在相似的高紫外线环境下，亚洲热带原住民 (TIAs, Tropical Indigenous Asians) 独立演化出了深色皮肤，其程度可与非洲人群相当，体现了人类肤色性状在不同地区的趋同进化 (Deng et al. *MBE* 2022)。

人类深色皮肤形成的三种进化模型：①**平行进化 (祖先驱动)**。深色皮肤源自共同的古老祖先遗传背景，在非洲人与部分亚洲人群中被保留或平行延续；②**趋同进化 (基因交流驱动)**。深色皮肤相关等位基因通过与非洲或古人类的基因交流进入亚洲人群，随后在高紫外线环境下受到选择；③**趋同进化 (突变驱动)**。亚洲人群中独立产生新的功能突变，在强选择压力下迅速提高频率，形成深色皮肤。

基因突变与人群致病

自然选择不会导致完美的身体，而是作用于相对的繁殖适应性。(trade-off)。我们对祖先环境的生物适应与现代生活方式之间的不匹配导致了許多常见疾病。

一、新生突变与父母年龄的关系

父母年龄对生殖系新生突变 (de novo mutations, DNMs) 的影响机制及其性别差异。**女性生殖系**在胚胎期完成大部分卵原细胞分裂，出生后几乎不再分裂，因此随年龄增加突变数增长缓慢；**男性生殖系**中的精原干细胞在青春期后持续、高频分裂，随着父亲年龄增加，复制错误不断累积，从而显著增加精子中的新生突变数量。

子代 DNMs 随父母年龄上升而增加，但**父源效应明显强于母源效应**，父亲每增加 1

年约新增 ~1.3 个突变，而母亲仅 ~0.4 个。大多数子代新生突变来自父亲（Goriely, *Nat Genet* 2016）。

二、新生突变的富集

新生突变（de novo mutations, DNMs）在人类精神疾病，尤其是精神分裂症中显著富集。映射到大脑发育时空背景中，相关基因主要在胎儿前额叶皮层高度共表达，形成紧密的功能网络，涉及神经发生、突触形成和皮层回路建立等关键过程（Cell, 2013）。

某些精神健康问题是人类进化过程中不可避免的副产物。只有**现代人类**在 16p11.2 区域出现了显著的 *BOLA2* 拷贝数扩增，而古人类（尼安德特人、丹尼索瓦人）和其他非人灵长类几乎不具备这种扩增。这种人类特异性的基因重复在全球不同人群中普遍存在，但拷贝数高度可变。这一人类特异性重复也是自闭症最常见的遗传风险因素之一（Nuttall et al, *Nature* 2016）。

三、地中海贫血

地中海贫血是一种由珠蛋白基因多种突变引起的常见单基因疾病。 α /非 α 珠蛋白链比例失衡是致病核心：① β -地中海贫血由于 β 链减少， α /非 α 比例升高；② α -地中海贫血由于 α 链减少， α /非 α 比例降低；③而正常情况下两类链保持平衡。该疾病具有显著的等位突变多样性（已知 >120 种 α -突变、>350 种 β -突变）。

表型统一，但分子起源高度多样（Gao et al., *Nature* 2023）。

东南亚 β -地中海贫血突变并非单一起源，而是由多个地区独立产生，并在后续人群迁移中通过基因流动共同塑造了今天高度多样的突变谱。部分 β -地中海贫血相关突变可能最初源自非洲或南亚，在疟疾选择压力和农业扩张背景下，随人群迁徙传播至东南亚；同时，东亚与东南亚本地也出现了新生突变并被局部选择放大（Zhang et al, *Nat Commun* 2025）。

大约在 5–10 千年前，疟疾相关死亡率显著上升；与此同时， β -地中海贫血在约 5 千年前开始受到强烈正向选择，因为杂合携带者对疟疾具有生存优势。疟疾作为强烈的环境选择压力，推动了血红蛋白病相关突变在特定地区的高频维持（Vento et al., *The Lancet Infectious Diseases* 2006）。

四、亨廷顿舞蹈症

亨廷顿舞蹈症（HD）：常染色体显性遗传病，神经系统变性疾病。27–35 次为中间等位基因，通常不发病但具有不稳定性；36–39 次表现为不完全外显； ≥ 40 次则为完全外显，必然发病。重复次数越多，发病风险越高，且通常发病越早。同时可在代际中发

生进一步的重复扩增。

HD 在委内瑞拉马拉开波湖附近地区具有异常高的患病率，是典型的地区性聚集现象。全球 HD 的平均患病率约为每 10 万人 10 例，而在委内瑞拉马拉开波地区高达每 10 万人约 700 例。高发的原因主要是奠基者效应。当地 18,149 个案例中的 14,761 个集中在一个主家系，共同祖先可追溯到 19 世纪初的一位创始个体。Dr. Nancy Wexler 对当地家系的长期研究，奠定了 HD 致病基因定位和机制研究的基础。

HD 的晚发性可能使其逃避自然选择的清除。由于 HD 多为生育后或中晚年发病，携带致病等位基因的个体在发病前已完成生殖，从而削弱了自然选择对该突变的清除作用，使其得以在群体中长期维持甚至扩散（The U.S.–Venezuela Collaborative Research Project and Nancy S. Wexler, *PNAS* 2004）。

第九章 转录组与基因组转录调控

第一节 基因组层面的转录调控

真核生物基因表达调控层次：①DA：远端启动子区 (promoter-distal)；②近端启动子区 (promoter proximal)；③TATA 盒；④INR：起始顺序 (Initiator)；⑤DPE：下游启动子区 (Downstream-Promoter element)。

真核生物的三种 RNA 多聚酶与其负责的基因分类：①**RNA 聚合酶 I**。负责 28S、5.8S、18S 核糖体 RNA 基因；②**RNA 聚合酶 II**。负责**蛋白质编码基因**、小分子细胞核 RNA (snRNA、U RNA) 基因；③**RNA 聚合酶 III**。**转运 RNA (tRNA)**、5S 核糖体 RNA、U6- snRNA、小分子核仁 R (snoRNA)、小分子细胞质 RNA (sc RNA) 基因。

三种 DNA 聚合酶的命名是根据这三种酶在层析柱上洗脱时出现的先后顺序依次命名。根据基因转录时采用的 RNA 聚合酶类型分别将基因分为 Pol I 基因、Pol II 基因、Pol III 基因。

真核生物基因表达调控的特点。①大范围与小范围调控。染色体水平，如 X-染色体的随机失活，可逆异染色质状态涉及大面积的基因表达调控。②可逆调控与不可逆调控。与发育相关的基因具有不可逆的调控，外界诱导表达的基因多为可逆调控。③有和无调控。“开”与“关”属于有和无的调控；④粗与细调控。表达产物的多少属于粗调，表达产物的加工，修饰和半衰期属于细调。

rRNA 基因 (Pol I 基因)

①真核生物 Pol I 基因只有一种类型，即核糖体 RNA 基因 (rRNA 基因)。

②真核生物 rRNA 基因含 3 个成员，18s, 5.8s 和 28s rRNA 基因, 共同组成一个表达单位。

③所有真核生物 rRNA 基因均为**多拷贝**，**首尾串联**，簇集在染色体的特定区域。

④rRNA 基因转录场所在核仁区。

每个 rRNA 基因重复单位均包括以下几个组成部分：①**非转录间区**（non-transcribed spacer, NTS），含调控元件；②**外转录间区**（external transcribed spacer, ETS）；③**内转录间区**（internal transcribed spacer, ITS）；④**rRNA 基因编码区**。在基因转录时，ETS、编码区和 ITS 一道转录成前体 rRNA，ITS 和 ETS 随后被切除。

注：rRNA 基因的调控区顺序具有种属专一性。

22.1.1 rRNA 基因启动子剖析

接头扫描法剖析 rRNA 基因调控区的结构。在跨越 rRNA 基因的上游-164 至下游 +33 的区段，合成 10bp 的寡聚核苷酸，依次代换原位 10bp 的序列，然后检测它们对 rRNA 基因表达调控的影响。采用这一方法鉴定出上游-164 至下游 +33 位置有两段区域为 rRNA 基因转录调控所必需，分别位于-156 至-107 和-45 至下游 +20。

Pol II 基因

22.2.1 原核生物和真核生物启动子

①Pribnow 和 David（1975）对大量原核生物基因起始转录位置序列进行比较分析发现，上游大约-10bp 和-35bp 处有两个共同的顺序，称为-10 和-35 序列（Pribnow box），即原核生物启动子。

②Hogness 等在真核生物基因中发现了类似 Pribnow 区的 Hogness 区位于转录起始点上游-25~-30 bp 处的共同序列似 TATAAA，也称为 TATA 区（Hogness box）。另外，在起始位点上游-70~-78 bp 处还育另一段共同序列 CCAAT，这是与原核生物中-35bp 区相对应的序列，称为 CAAT 区（CAAT box）

③真核生物 TATA 盒框与 RNA 聚合酶 II 的结合有关，CAAT 则与转录起始频率有关，共同组成了真核生物启动子。古细菌也有类似启动子。

一、高等真核生物蛋白质编码基因表达调控研究

①高等真核生物基因表达调控的研究方法与原核生物有很大的不同。因为高等真核生物基因位于染色体中，在细胞核内转录，很难获得大量的转录产物供实验研究；

②高等真核生物基因的表达调控必须在真核细胞的背景下研究才能获得和体内表达调控相似的结果。原核生物有质粒这样的克隆表达载体，而高等真核生物缺少类似的系统；

③因此高等真核生物基因表达调控的研究首先必须寻找和建立有效的研究体系，它们具有可以进行体外重组 DNA 操作，又可在真核生物细胞内部进行表达研究；

④早期的高等真核生物基因表达研究是从**动物病毒**入手，因为动物病毒具有结构简单、拷贝数高、可以体外操作等优点。同时病毒基因的表达调控直接利用了寄主细胞基因调控装置，可以反映细胞内部的调控机理。

二、SV40 基因组结构与转录

SV40 为猿猴病毒，基因组为一环状 DNA，全长 5 243 bp，编码 7 个基因。有一个双向启动子（PL 和 PR）控制左右两个排列方向基因的转录，产生 7 个不同的转录产物。

解剖分析 SV40 基因组启动子的功能。将 SV40 启动子去分离克隆，随后再整合到表达载体对其结构进行剖析。SV40 启动子有 2 个 72bp 和 3 个 21bp 的重复序列（GC 盒框），TATA 盒位置位于 21bp 盒下游。分别将该调控区从 5' 或 3' 位置部分缺失检测其转录效率，可探知不同区段对基因转录的影响。

三、启动子的功能

①为 RNA 多聚酶的结合提供平台；②确定转录的方向；③规定转录起始点。

22.2.2 增强子

增强子可以定义为距离转录起始点较远的与**转录激活有关的 DNA 序列**；真核生物启动子并不能单独行使转录起始功能，它必须**借助增强子的帮助**；真核生物的增强子有许多可以和转录调控蛋白特异结合的短序列 DNA 组成，可以**决定基因何时何处表达**。

一个典型的例子是，乳糖分解酶基因的增强子活性决定乳糖耐受与否。大部分欧洲人 C→T 的点突变变成单核苷酸多态性（SNP），普遍往乳糖分解酶基因转录活性更高的方向转变。

一、增强子的结构特点

①**增强子无启动子特异性**，例如将 SV40 的增强子插入到兔子 β - 球蛋白启动子的上游区，可提高转录效率 200 倍。双子叶花椰菜嵌病毒 35S 启动子可在水稻细胞中启动报告基因的表达。

②**增强子为顺式作用**，即与启动子位于同一 DNA 链，或者说只要找到编码基因，即可在同一 DNA 链或近或远的位置发现相关的增强子。

③增强子的功能与其排列方向无关，可双向调控，例如当增强子反向插入时，仍然保持其原有功能。

④增强子具有独立的结构，改变其两侧的顺序组成不影响增强子的作用。

⑤增强子调节功能可以超长距离，例如白蛋白基因的增强子位于起始位点上游 10 kb 的位置。

⑥增强子含有许多可与不同转录因子结合的元件，可以不同的组合方式调控基因的表达，在已研究过的绝大多数基因的表达调控模式中都发现组成增强子的不同基序或模块 (module) 之间可形成不同的组合，它们是基因差别表达 (differential expression) 的主要原因。

⑦增强子中的不同基序既有增强表达的成分，也有抑制表达的成分，有些不同的基序之间有顺序重叠。

⑧冗余：有许多增强子的结构成分即模块含有重复拷贝。这些重复拷贝中如果缺失其中某些成员并不丧失整个增强子的正常功能。

二、增强子双向调控

SV40 的调控区含有控制左右两个方向转录的启动子，受双向调控增强子不同顺式元件的控制。B 细胞和 HeLa 细胞使用的顺式元件略有不同，可调控基因的差别表达。

人类基因组中约 11% 的基因为头-头 (head-to-head) 排列，或者说相邻两个基因共享相同的调控元件，它们的表达调控具有协同性 (Lin JM *Genome Res.* 17: 818-827, 2007)。

三、转录因子与增强子元件 GC 盒结合


增强子中的调控元件可与特定的转录因子 (反式因子) 结合，如调控元件 GC 盒的结合蛋白 Sp1 是一个锌指蛋白，含有 DNA 结合域。

四、在全基因组层次上寻找增强子

①表观遗传标记辅助。增强子的特征：H3K4me3(-); H3K3me(+); H3K27Ac(+).

②增强子 RNA。eRNA 特征是双向的、非编码的、低表达、Pol II 转录。

五、增强子可以成簇形成超级增强子



22.2.3 经典案例：酵母半乳糖代谢基因

4 个基因: *gal 1*, kinase, 激酶; *gal 2*, transport enzyme, 转运酶; *gal 7*, translase, 转移酶; *gal 10*, UDP-葡萄糖差向异构酶。上述 4 个基因涉及酵母半乳糖分解代谢途径, 受半乳糖诱导协同表达。

酵母半乳糖代谢突变:

①无半乳糖时 *gal* 基因不表达, 加入半乳糖 *gal* 基因表达。

②*gal4* 基因突变时加入半乳糖阻止 *gal* 基因表达。

③*gal80* 基因突变时 *gal* 基因组成型表达。

④推测 *gal4* 为正调控因子, 与调控顺序结合启动转录 *gal80* 为负调控因子, 与 *gal4* 结合抑制转录。将分离的 *gal4* 蛋白和 *gal80* 蛋白与 DNA 温浴证实, *gal4* 蛋白与 *gal* 基因 5' 结合, *gal80* 不直接与 DNA 结合。

一、转录因子 GAL4 的结构与功能

缺失分析鉴定了 GAL4 蛋白存在 5 个功能区, 分别执行 4 种不同的功能: ①与 DNA 结合; ②形成二聚体; ③与 GAL80 结合; ④激活转录。

GAL4 蛋白 DNA 结合域和激活域检测实验: ①GAL4 的 DNA 结合域只能与 UAS 顺序结合; ②当 GAL4 的激活域和大肠杆菌 *lexA* 蛋白的 DNA 结合域融合时, *lexA* 蛋白 DNA 结合域不识别 UAS 顺序; ③当表达载体的调控元件换成 *lexA* 识别元件结合, *lexA*-GAL4 融合蛋白可与调控区结合。

二、酵母双杂交原理

基于 Gal4 转录因子的结构筛选互作蛋白。酵母双杂交系统中，BD 与 X 蛋白（鱼饵）融合，AD 与 Y 蛋白融合（猎物），如果 X、Y 之间形成蛋白-蛋白复合物，使 GAL4 两个结构域重新构成，则会启动特异基因序列的转录。

Pol III 基因

Pol III 基因分为三类：①**基因内启动子**，包括 tRNA 和 5S rRNA 基因；②**基因外启动子**，如 U6 RNA 和 7SK RNA 基因；③**混合启动子**，如 7SL RNA 基因，它们的转录起始由**上游调控顺序**和**基因内调控顺序**共同负责。A 盒，B 盒，C 盒，均为调控顺序。DSE，远端顺序元件；PSE 近端顺序元件。

22.3.1 tRNA 基因的结构

tRNA 基因的调控序列含有两个盒框，分别位于编码区的 +10 至 +20 bp (A 盒) 和 +55 至 +65 bp (B 盒)。A 盒与 B 盒之间的距离对转录有效性重要，但对序列组成无严格要求。

22.3.2 转录因子

转录因子是基因表达的重要调控者。与启动子或增强子的结合决定下游靶基因的表达与否；转录因子本身在不同生物学过程中呈动态变化，决定了下游众多基因的表达；转录因子之间可形成复杂的调控网络决定生命过程。

一、转录因子的结构特征

①**DNA 结合域** (DNA-binding domain)。其核心成分为 DNA 结合基序 (motif)，它们可识别双螺旋 DNA 的碱基顺序，与靶位专一性结合。具有相同 DNA 结合域的转录因子具有类似的功能，属于同一基因家族成员。

②**激活域** (activation domain)。这是与其它转录因子蛋白互作的结构成分，可控制前起始复合物的组装与转录起始。同一家族转录因子的可变区通常发生在激活功能域，通过可变区顺序的变异扩大调节的范围。

③**二聚体结合区**。许多转录因子是以二聚体形式与 DNA 调控区结合，为了维持二聚体结构，单体蛋白质有二聚体互作区，如亮氨酸拉链蛋白质的拉链区。

④转录因子激活功能域虽然变化很大，但可归于下述三个类群之一：i. **酸性功能域** (acidic domain)。在其激活功能域中含较多的酸性氨基酸（如天冬氨酸和谷氨酸）。这是激活功能域中最为常见的一种；ii. **富谷氨酰胺功能域** (Glutamine-rich domain)。主要出现在同源异形功能域或 POU 类转录因子中；iii. **富脯氨酸功能域** (Proline-rich domain)。比较少见。

⑤有相当部分真核生物转录激活因子的活性状态为同源二聚体或异源二聚体，如亮氨酸拉链蛋白与 MADS 盒蛋白，不同的组合方式赋予二聚体不同的识别功能，使单个激活因子可参与多种基因的表达调控。

⑥同一家族的转录因子通过**可变区顺序的变异**扩大基因调节的种类与范围。

⑦转录因子的 DNA 结合域和激活域在结构上彼此独立，但作为整体互不可缺。在一些遗传学实验中，常常将不同转录因子的结合域和激活域互换组成嵌合基因，用以研究转录因子的调控机制。

二、转录因子家族

①**螺旋-螺旋基序**。

②**锌指基序**。

③**亮氨酸拉链基序**。可以形成一个拉链样的二聚体。

三、转录因子与调控元件保守性

酵母 Gal4p 蛋白是一个**转录因子**，可与启动子的调控元件-CGGACAAGCTGTTGACCG-专一性结合。酵母种间 Gal4p 结合位点碱基序列比较显示，调控元件-CGGACAAGCTGTTGACCG-的碱基代换速率约为 0.32，远低于周边背景序列位点的代换率 0.75。调控元件-CGGACAAGCTGTTGACCG-中，与 Gal4p 蛋白 DNA 结合域专一性互作的位点为碱基 1,2,3,15,16,17。调控元件的 1,2,3,15,16,17 位碱基的代换率又远低于调控元件中的其它碱基位点。

四、转录因子与顺式元件协同进化

酵母反式作用因子 AP1 (bZIP) 可识别**顺式作用元件** YRE。已知祖先 Ap1 蛋白可识别顺式元件 YRE-O (TTACTAA)，在酵母物种光滑假丝酵母 (*Candida glabrata*) 中发现存在顺式元件 YRE 的突变型 YRE-A (TTACGTAA)。检测突变型光滑假丝酵母 YRE-A

的反式因子发现，可与 YRE-O 结合的 AP1 蛋白的 DNA 结合域位置发生了一个精氨酸转变为赖氨酸的代换突变。突变的 Ap1 仍然保持与突变的 YR-AE 元件专一性结合能力 (Kuo D, 2010)。

五、确定转录因子在基因组上具体的结合位置

染色质免疫共沉淀结合深度测序 (ChIP-seq) 法寻找蛋白质在 DNA 上的结合位点。ChIP-seq 的原理：首先通过染色质免疫共沉淀技术 (Chromatin Immunoprecipitation, ChIP) 特异性地富集目的蛋白结合的 DNA 片段，并对其进行纯化与文库构建；然后对富集得到的 DNA 片段进行高通量测序。研究人员通过将获得的数百万条序列标签精确定位到基因组上，从而获得全基因组范围内与组蛋白、转录因子等互作的 DNA 区段信息。

ChIP-seq 的基本步骤：①甲醛交联整个细胞系（组织），即将目标蛋白与染色质连接起来；②分离基因组 DNA，并用超声波将其打断成一定长度的小片段；③添加与目标蛋白质特异的抗体，该抗体与目标蛋白形成免疫沉淀免疫结合复合体；④去交联，纯化 DNA 即得到染色质免疫沉淀的 DNA 样本，准备测序；⑤将准备好的样本进行深度测序和分析。

第二节 组成、加工、降解与定位

转录组 (transcriptome) 广义上指某一生理条件下，细胞内所有转录产物的集合，包括信使 RNA、核糖体 RNA、转运 RNA 及非编码 RNA；狭义上指所有 mRNA 的集合。

转录组概况

23.1.1 转录组与基因组

以 DNA 为模板合成 RNA 的转录过程是基因表达的第一步，也是基因表达调控的关键环节。所谓基因表达，是指基因携带的遗传信息转变为可辨别的表型的整个过程。

与基因组不同的是，转录组的定义中包含了**时间和空间**的限定。同一细胞在不同的生长时期及生长环境下，其基因表达情况是不完全相同的。

23.1.2 转录组的用途

①**阿尔茨海默病** (Alzheimer's diseases, AD) 中，出现神经原纤维缠结的大脑神经细胞基因表达谱就有别于正常神经元，当病理形态学尚未出现纤维缠结时，这种表达谱的差异即可以作为分子标志直接对该病进行诊断。

②将表面上看似相同的病症分为多个亚型，尤其是对**原发性恶性肿瘤**，通过转录组差异表达谱的建立，可以详细描绘出患者的生存期以及对药物的反应等等。

③包含了**细胞状态**的信息，因此可以用来**预测细胞衰老**。


23.1.3 基因类别与 RNA 组成

细胞的总 RNA 中，编码 RNA 占 4%，同时非编码 RNA 占 96%。编码 RNA 要先为 hnRNA (mRNA 前体) 再为 mRNA。编码基因与非编码基因的转录产物是复杂的。

23.1.4 决定转录组的相关因素

①基因类别与 RNA 组成；②组织与发育特异性；③选择性启动子、选择性剪接、选择性多聚腺苷酸化。

一、单个基因的复杂转录模式



果蝇 G 蛋白 β 亚基 13F 基因 ($G\beta13F$) 含有 3 个不同的可变启动子 (绿色箭头、选择性启动子)，8 种可变剪接方式 (斜线、选择性剪接)，10 个不同的 polyA 加尾位置 (红色数字、选择性多聚腺苷酸化)，有 235 个不同的转录产物 (*Nature* 512: 393–399, 2014)。

二、复杂的基因转录单元


人类基因组编码跨膜 G 蛋白 α 亚基基因 $GNAS$ 是一个典型的复杂基因座 (locus)。

①GNAS 的第一个外显子有多重剪接方式，2-13 外显子为共享外显子。

②5' 位置反义链可转录 (Antisense, AS)。


③GNAS 的表达具有基因组印记模式 (P, 父源表达；M, 母源表达)。

【例 1】*TMEM107* 基因具有哪种复杂转录模式？




TMEM107 是一个具有**多转录本、可变剪接、编码与非编码转录本并存**的基因。

【例 2】*TP53* 基因具有哪些复杂转录模式？*WRAP53* 与 *TP53* 是什么关系？



TP53 具有**多启动子、多剪接形式和多转录本**的复杂转录模式；*WRAP53* 是与 *TP53* 基因座重叠、位于相反链上的反义基因，在转录调控层面与 *TP53* 密切相关。

【例 3】*HPS1* 基因具有哪些复杂转录模式？



HPS1 是一个典型的**复杂基因座**，其特征包括：多启动子、大规模可变剪接、可变 3' 端、编码与非编码转录本共存（NM 是编码转录本，NR 是非编码转录本）与反义转录调控。

转录组与 mRNA 编辑

23.2.1 mRNA 加帽

目前已知所有 Pol II RNA 聚合酶转录物 mRNA、U RNA (snRNA、snoRNA)、miRNA 前体、siRNA 前体、piRNA 前体均有 5' 加帽。

一、mRNA 加帽的功能

四个方面：①阻止 mRNA 的降解，mRNA 的 5' 端加上 m^7GpppG 帽子后，带有 3 个连接磷酸 5' 帽结构可阻止 RNase 切割；②提高翻译效率，核糖体结合 mRNA 需借助加帽结构；③进出细胞核的识别标记；④提高 mRNA 的剪接效率。


23.2.2 mRNA 加 polyA 尾

真核生物 mRNA 的 3' 端含有三个涉及多聚腺苷酸化信号，AAUAAA，CA 和 G (U)n 区。

①提高 mRNA 的稳定性；②控制与提高 mRNA 翻译效率，这是因为 Poly(A) 可起始翻译；③有助于 mRNA 前体最后一个内含子的剪切；④调控 mRNA 加尾的长短可用于控制 mRNA 的翻译。

U1 snRNP 在保护 mRNA 完整转录上起重要作用 (Michael G Berg et al., *Cell*. 2012 Jul 6;150(1):53-64)。

一、Poly(A) 与起始翻译有关




二、Poly(A) 长度可调控翻译起始

许多动物卵细胞的成熟依赖于母源 mRNA 的加尾。一些母源 mRNA 的 Poly(A) 尾太短（少于 20 nt），不能起始翻译。原因是加尾蛋白 CPSF 在 Maskin 的作用下不与加尾信号结合。孕激素激活 Aurpra，可使 CPEB 磷酸化，减弱 Maskin 抑制作用，促使 CPSF 与加尾信号结合，在细胞质中将母源 mRNA 的 Poly(A) 延伸至 80-150 nt，促使翻译进行。

三、Poly(A) 位点的选择可改变蛋白质的质和量

选择性多聚腺苷酸化 (alternative polyadenylation, APA)。①内含子中的 polyA 位点可导致产生不同碳末端的蛋白质；②3'UTR (3' 非翻译区) 上的 polyA 位点可改变其长度影响蛋白的量。

23.2.3 前体 mRNA 剪接



①真核生物有两种前体 mRNA 加工方式：GU-AG，AU-AC；


②参与 mRNA 剪接加工的小分子 RNA 可分 4 种类群；

③参与 mRNA 剪接加工的 snRNA 和 snoRNA 转录后加工，有两次加帽，分别在细胞核和细胞质。

以果蝇神经生长导向因子为例。外显子包含：增强因子 SR 与剪接增强子（ISE 或 ESE）的结合促使 U2AF 和 U1-snRNP 组装成剪接体，使得该外显子被成熟 mRNA 包含。

mRNA 前体的可变剪接扩充了基因的信息内涵，表明基因组序列中包含的遗传信息是高度压缩的。

一、参与 mRNA 剪接的 U RNA




催化前体 mRNA 剪接的分子实际是 U2（或 U12）RNA。

二、转录与 mRNA 加工偶联

RNA 聚合酶 II (PolII) 通过 3 个步骤完成基因的转录：起始、延伸与终止。这 3 个步骤中，每一步都涉及 mRNA 前体的加工。Pol II 酶的 **C-端域 (CTD)** 是一段 7 数氨基酸重复序列，**磷酸化**后起始转录。在转录时 CTD 可装载加工因子，**转录的同时进行 mRNA 加工**。

三、前体 mRNA 的可变剪接



原肌球蛋白 (tropomyosin, **TM**) 是细肌丝中与肌动蛋白的结合蛋白，其编码基因含有 12 个外显子。图中所示为 TM 基因在 7 种细胞中的可变剪接产物的外显子组成，说明基因的可变剪接产物在不同的组织细胞中可能执行略有差异的功能 (*Nucleic Acids Res* 30:3548-3557, 2002)。

四、外显子如何包含或跳跃

①**外显子跳跃**。剪接抑制因子 hnRNP 与剪接沉默子（ISS 或 ESS）的结合阻止 U2-snRNP, U2AF 和 U1-snRNP **组装成剪接体**, 使成熟 mRNA 跳过该外显子。

②**外显子包含**。增强因子 SR 与剪接增强子（ISE 或 ESE）的结合促使 U2AF 和 U1-snRNP **组装成剪接体**, 使得该外显子被成熟 mRNA 包含。

五、真核生物 mRNA 可变剪接比例

将顺序表达标签（EST）和 mRNA 进行序列比对可以发现同一基因是否存在多种转录产物, 可估算不同生物 mRNA 发生可变剪接的比例;

2008 年发表在 Nature 上的基于高通量测序的研究发现人类基因中 92-94% 的比例存在可变剪接 (Wang et al.)。

23.2.4 基因组转录面积

一、真核生物的 mRNA 数目

真核生物基因组究竟有多少区域转录迄今仍然是一个待解之谜, 人类 21 和 22 号染色体的转录物组检测发现, 有 49% 的 mRNA 转录产物在已注释的基因之外。

可以用 RNA-seq 来检测基因组转录面积。大概有 76% 的人类基因组是可以转录出 RNA 的。

mRNA 的定位与降解

mRNA 定位: 成熟 mRNA 在输出细胞核进入细胞质后转移到特定位置进行翻译的过程。生物学意义: ①**降低蛋白质异位翻译后运输到工作场所的成本**; ②**蛋白质异位翻译难以在运输过程中保持原有修饰状态**; ③**蛋白质异位翻译不利于功能复合物的组装**; ④**靶位翻译可提高蛋白质的修饰与加工效率**; ⑤**靶位翻译便于蛋白质的精细调控**。

一、小鼠神经成纤维细胞 β -actin mRNA 定位的作用

ZBP1 (Zip-code binding protein 1) 蛋白控制 β -actin mRNA 转运及其翻译的工作模型: **ZBP1 在细胞核中与 β -actin mRNA 结合**, 输出细胞核后立即与 40S 核糖体亚基结合, 并

通过 MP(马达蛋白) 装载到细胞骨架运输线上。在到达指定位置 (突出生长边缘), 然后在 Src 激酶作用下 ZBP1 与 mRNA 脱离, 释放的 mRNA 和 40S 亚基再与 60S 亚基结合起始翻译 (*Nature* 438:512-515, 2005)。

23.3.1 mRNA 的定位

一、mRNA 定位在果蝇躯体发育中的作用

果蝇卵细胞在发育过程中母源 mRNA 的分布与翻译时 mRNA 的分布有所不同, 这种 mRNA 位置改变的现象称 mRNA 定位 (mRNA location), 这些躯体规划 mRNA 的分布决定了躯体模式。

二、mRNA 定位荧光标记检测技术

①**MS2 系统**。衣壳蛋白 MCP 可与专一性 RNA 序列 (MS2 标签) 结合。MCP-荧光蛋白融合蛋白与插入目标 RNA 分子内的 MS2 结合即可显示 mRNA 踪迹; ②在目标 mRNA 分子内插入一段 **RNA 适配体** 序列, 可检测 mRNA 位置; ③利用 **分子信标** 与目标 mRNA 杂交, 显示 mRNA 位置; ④将目标 mRNA **连接荧光基团** 直接显示。

三、动物表皮细胞的极性形成

果蝇胚胎和滤泡表皮细胞中 *crb*, *sdt* 和 *Patj* mRNA 特征性地分布在细胞次顶部位置。在早期滤泡表皮细胞 *sdt A* mRNA 含 10 个外显子, 和跨膜蛋白 *Crb* 在顶侧位置共积累。晚期滤泡期 *sdt B* RNA 缺少外显子 3, 在细胞中呈弥散分布 (*PLoS Genet*, 2008, 4(1): e8)。

23.3.2 mRNA 的降解

mRNA 的降解是基因表达调控的重要内容之一, mRNA 的降解涉及 **正常 mRNA** 和 **异常 mRNA**。人类细胞平均约 20% 的 mRNA 编码残缺蛋白质, 也有无终止密码子的 mRNA 占用翻译装置, 影响核糖体的利用效率。细胞必须将 **不再需要的 mRNA** 和 **异常的 mRNA** 及时清除, 以保证细胞正常的功能。真核细胞有多种 mRNA 降解机制, 针对不同的 mRNA。

性质和状态不同的 mRNA 半衰期相差很大。

一、降解 mRNA 的类型


从编码功能可将 mRNA 划分为正常 mRNA 和非正常 RNA：

①**正常 mRNA**。具有正常编码顺序,但细胞内已经不再需要的 mRNA，不同 mRNA 的半衰期有很大差别，从数分钟到几十分钟。

②**非正常 mRNA**。i. 无终止密码 mRNA；ii. 密码子前移 mRNA。非正常 mRNA 主要来源于：i. 发生点突变的假基因；ii. mRNA 加工过程中发生差错产生的 mRNA，如缺少 poly(A) 的 mRNA；iii. 可变剪接产生的非正常 mRNA。

非正常 mRNA 的一个例子。*PTEN* 基因外显子 3 的跳跃和外显子 6 的包含产生不具有编码能力的 RNA。

二、mRNA 降解的 4 条路线



①依赖于 3' poly(A) 脱腺苷酸和 5'-脱帽的 5' →3' 降解路线，涉及正常 mRNA 和部分非正常 mRNA，是主要的 mRNA 降解路线。

②依赖于 3' poly(A) 脱腺苷酸的 3'→5' 降解路线，采用 exosome(外切酶体) 降解 mRNA。

③内切核酸酶降解路线。

④独立于 3' poly(A) 脱腺苷酸，直接 5'-脱帽的 5'→3' 降解路线，或称**质量监控路线**。

第三节 非编码 RNA

依据发生途径为小 RNA 分类。①miRNA: microRNA, 微小 RNA; ②siRNA: small interfering RNA, 小干扰 RNA (RNAi); ③ta-siRNA: miRNA + siRNA, 兼有两者特点; ④piRNA: Piwi-interacting RNA, Piwi 蛋白作用 RNA。

RNAi 的发现

RNA 干扰 (RNAi) 是一个分子生物学过程, 在这个过程中双链 RNA 以一种非常确定的方式抑制基因的表达。自 1998 年发现以来, RNAi 已经作为一种有效的基因沉默技术应用于许多分子生物学领域。RNAi 在 2005 年被 Science 杂志选为当年科学领域十大进展之一。

①**植物转基因沉默**。1989 年 Matzke 等将控制紫色花的基因导入矮牵牛细胞, 获得再生植株。由于导入矮牵牛的转基因含有反向尾-尾重复的结构, 产生正义和反义基因转录产物, 基因转录产物形成 dsRNA, 导致转基因和内源基因的沉默, 使原本产生紫色花色的花瓣变成白色。1 这是首次双链 RNA 导致基因沉默。称之为转录后基因沉默 (PTGS)。

②**真菌转基因沉默**。

③**线虫 RNA 注射实验**。i. 负对照线虫胚胎, 未注射 RNA, 无探针杂交; ii. 未注射线虫胚胎, 探针杂交。显示强杂交信号, 说明有内源 mRNA; iii. 单链反义 RNA 注射线虫胚胎, 弱杂交信号; iv. 纯化双链反义 RNA 注射线虫胚胎, 内源目标 RNA 完全降解。

④**线虫发育突变研究**。1995 年 Cornell 大学的研究人员 Guo 和 Kemphues 在研究阻断秀丽新小杆线虫中 *par-1* 基因时, 意外发现正义 RNA 也可以阻断 *par-1* 基因表达, 当然也验证了反义 RNA 阻断表达。1998 年 2 月 Fire 和 Mello 证实, Guo 等报道的结果源于微量 RNA 双链污染所致。纯化的双链 RNA(dsRNA) 阻断靶基因的表达效率高于单链反义 RNA 约 2 个数量级。Fire 等对 dsRNA 调控内源基因表达称之为: RNA interference, 简称 RNAi, 即 RNA 干扰, 所产生的 dsRNA 即 siRNA (Small interfering RNA)。

植物 VIGS 技术及其运用

病毒诱导的基因沉默 (virus-induced gene silencing, VIGS) 一词最早用于描述被病毒侵染的植物恢复原有表型的现象, 是一种天然的植物抗病毒侵染的免疫机制。利用这种天然机制, 通过将目的基因片段整合到病毒基因组中, 在重组病毒感染宿主细胞后, 重

组病毒激活宿主细胞产生 VIGS，从而抑制植物内源基因表达。这一遗传技术，可用于植物内源基因的功能分析。

产生内源性 siRNA (nat-siRNA/ta-siRNA) 的基因组位点

①**倒位重复** (inverted duplication) 途径。基因组中存在倒位重复序列，转录后单条 RNA 自行折叠形成发夹结构 (近乎完全互补的 dsRNA)。该 dsRNA 被 **Dicer** 直接切割，产生一系列 **siRNAs**。这是最直接、最结构驱动型的 siRNA 来源。

②**反向启动子** (opposing promoters) 途径。同一基因座上存在相向的启动子，分别转录正义链和反义链 RNA。两条互补转录本在细胞中退火形成 dsRNA，随后同样被 **Dicer** 加工生成 **siRNAs**。这是转录调控驱动型的 dsRNA 形成方式。

③**植物 TAS** (trans-acting siRNA) 途径。TAS 基因首先被转录为单链 RNA，随后被 **miRNA-AGO** 复合物特异性切割。切割后的 RNA 片段招募 RDR6，合成互补链生成 dsRNA，再由 **DCL4** 精确加工，产生具有相位性的 **tasiRNAs**。这些 tasiRNAs 可反式调控其他基因，是一种**高度调控、级联放大的 RNA 沉默机制**。


miRNA

1988 年夏 Abros 小组克隆影响线虫幼虫发育 lin-4 基因，lin-4 基因突变阻止线虫从 L1 期进入 L2 期。他们发现 lin-4 可能是非编码 RNA。

1993 年 Ruvkun 实验室克隆到线虫突变基因 lin-14，lin-14 突变使 L4 期线虫多蜕一次皮。lin-14 基因 3' 末端与 lin-4 基因 3' 末端有互补序列。

2000 年 Ruvkun 等采用定位克隆分离到 let-7 基因。let-7 基因编码小 RNA，可使 lin-41 基因沉默，使幼虫过早进入成虫期。这些小 RNA 现在被称为 **microRNA**，即 **miRNA**。

24.4.1 *lin-4* 和 *let-7* RNA 发育调控



线虫的发育受时序调控基因控制：①**L1 末期**：*lin-4* 表达上调，*lin-14* mRNA 水平降低，幼虫进入 L2 期。②**L3/L4 期**：*lin-7* 表达上调使 *lin-41* mRNA 水平降低，幼虫进入成虫期。*Lin-14*，*Lin28*，*Lin-41* 和 *Lin-29*，编码蛋白质基因。*Lin-4*，*Let-7*，编码干扰 RNA 基因。

一、*Lin-7* miRNA 打靶基因 *lin-14* mRNA

lin-4 和 *let-7* 基因的转录产物为 RNA，在细胞中可形成茎环结构，并加工成 22 nt 双链小 RNA。*lin-7* 转录产物与被调控的 *lin-14* 基因 3'-端的 7 个重复序列互补。

24.4.2 miRNA 转录与加工

- ①miRNA 基因首先转录成 **pri-miRNA**，在细胞核内形成茎环结构。
- ②茎环结构被 **DGCR8** 识别，随后由 Drosha 在基部切离并释放 **pre-miRNA**。
- ③pre-miRNA 进入细胞质与 **RNaseIII 酶 Dicer** 结合，酶切产生 22nt 双链 RNA。
- ④双链 RNA 中有一条**单链 miRNA** 与 RISC 结合，随后与靶 mRNA 互作，打靶 mRNA。

24.4.3 miRNA 如何调控基因表达

- ①**影响 mRNA 的翻译**。抑制 Cap-40S 翻译起始装置的组装；抑制核糖体大亚基 60S 组装成核糖体；抑制翻译延伸；将核糖体驱逐脱离翻译模板；使翻译的新肽链降解。
- ②**影响 mRNA 的定位**。将 mRNA 滞留 P-小体中。
- ③**影响 mRNA 的降解**。促使 mRNA 降解；切割 mRNA。

④**影响 mRNA 的转录**。介导染色质重排抑制转录。

一、miRNA 的抑制效果比较温和

①研究发现，每个特异 miRNA 均可抑制多个靶 mRNA。在脊椎动物 miRNA 抑制效果表明，平均**每个 miRNA** 可抑制约 400 个保守的靶基因。

②实验证实，单个 miRNA 虽可抑制数百个不同蛋白质的翻译，但就抑制效果而言，干扰程度微弱，处在温和水平，低于两倍数量。

因此，虽然 miRNA 是一种保守的起源古老而且分布广泛的转录后调控基因表达的方式，但只是在**精细调控上发挥作用**。因而有人将其称之为是一种基因调控中的“**消震**”措施。

24.4.4 动物和植物 miRNA 的区别

①**序列组成及靶标**：植物 miRNA 序列与靶 mRNA 序列互补程度高，导致靶 mRNA 降解。动物 miRNA 序列与靶 mRNA 序列互补程度略低，抑制靶 mRNA 翻译。

②**作用位点**：动物中 miRNA 的作用位置主要在靶 mRNA 的 3' -UTR。植物中 miRNA 的作用位置可在靶 mRNA 的 3' -UTR，但更多在编码区。

③**加工场所**：植物**成熟 miRNA** 在**细胞核**内完成，动物成熟 miRNA 在**细胞质**内完成。

④植物 miRNA 的两个 3' 末端-OH 被**甲基化**。

24.4.5 siRNA 与 miRNA 的区别

①**来源不同**：miRNA 主要由基因转录的 mRNA 生成，siRNA 则来源于 mRNA，转座子或异染色质转录 RNA，以及病毒 RNA。

②**结构不同**：miRNA 的前体分子 pre-miRNA 形成茎环结构，siRNA 前体分子为长双链 RNA(dsRNA)。

③**加工不同**：每个 pre-miRNA 经 Dicer 酶切只生成单个 miRNA，而 siRNA 的前体双链 RNA 分子经 Dicer 酶切可产生许多序列不同的 siRNA。

④**保守性不同**：miRNA 在亲缘物种间有很强的保守性，而内源 siRNA 序列缺少保守性。

piRNA (piwi-interacting RNA)

①PIWI 与 AGO 蛋白同源，在 miRNA 和 siRNA 打靶时，**催化配对靶分子的切割**。

②piRNA 主要来源于着丝粒周边和亚端粒区转座子及重复序列的转录加工，可**阻止逆转座子的转座**，维持基因组的稳定。

③piRNA 的长度为 24-33 nt。

24.5.1 小鼠小 RNA 的结构与表达

A) 小鼠睾丸组织小 RNA 可明显分为两大类：①**18-26 nt** 和 **24-33 nt**。这两类小 RNA 都在 5' 端含有尿嘧啶残基。②小鼠睾丸组织 **MILI** 和 **MIWI** (PIWI 同源蛋白) 的表达谱。28 nt piRNA 在精原细胞到圆形精子细胞的发育阶段表达水平较高。

24.5.2 piRNA 扩增及降解靶标的乒乓模型

初始 piRNA 来自基因组中 piRNA 簇集 DNA 的转录或细胞中母源 piRNA。打靶转录物来自转座子的转录。切割事件的位置及方式，由图中剪刀模式表示。

24.5.3 piRNA 的生物学功能

转座子可在基因组中不断转移。**新转座子**在基因组中跳跃最终会**落入 piRNA 序列簇集中**，此时该转座子就进入**基因组监测记忆库**，系统可产生相应的 piRNA 攻击入侵者。只要转座子落入 piRNA 簇集，细胞就获得了相应的**免疫力**。

转座子可在基因组中不断转移。新转座子在基因组中跳跃最终会落入 piRNA 序列簇集中，此时该转座子就进入基因组监测记忆库，系统可产生相应的 piRNA 攻击，同时伸出援手的还有其他知名只综合还是。入侵者。只要转座子落入 piRNA 簇集，细胞就获得了相应的免疫力。

一旦 piRNA 发现转座子，它们即可跟踪转座子 RNA。piRNA 与 Piwi 蛋白结合，通过 ping-pong 循环剪切转座子 RNA。剪切产物经修饰后又与其它 Piwi 蛋白联手。剪切 piRNA 簇转录本，产生新 piRNA。

第十章 蛋白质组

第一节 蛋白质的翻译调控

一、功能基因组 (functional genome)

①**基因组** (Genome): 特定生物全部染色体的遗传物质的总和; **宏基因组** (metagenome): 研究一类在特殊的或极端的环境下共栖生长微生物的混合基因组。

②**转录物组** (transcriptome): 在某一特定条件下单个或一组细胞所具有的 mRNA 的总和。

③**蛋白质组** (proteome): 包括分析全部蛋白质组所有成分以及它们的数量, 确定各种组分所在的空间位置、修饰方法、互作机制、生物活性和特定功能。

翻译过程及其简单调节

25.1.1 mRNA 翻译起始复合物组装

eIF 即真核**翻译起始因子** (eukaryotic Initiation Factor), 包含①eIF4E, m7G-帽结合亚基; ②eIF4A, RNA 解旋酶; ③eIF4B, 激活 4A 并与 eIF3 (携带 43S) 互作; ④eIF4G, PABP, 与 eIF4E, eIF3, eIF4A 结合; ⑤eIF3: 核糖体解离蛋白, 促使 mRNA 和 tRNA 与核糖体 40S 亚基结合; ⑥eIF2, GTPase, 依赖 GTP 将起始 tRNA 与核糖体 40S 结合。

25.1.2 翻译起始与延伸

翻译起始所需其它蛋白:


①核糖体小亚基 40S 与 Met -tRNA/eIF2 复合物结合, 形成 **43S 翻译前起始复合物**

②Poly(A)n/PABP 复合物与翻译起始复合物 5' 帽结合蛋白 eIF4G/4E/4A 结合形成**翻译帽结合起始复合物**;

③帽结合起始复合物与 43S 翻译前起始复合物结合完成组装；

④翻译起始与延伸。

翻译调控点



1) 5' 帽结构；（很重要，部分其他因子是 5' 帽依赖的，部分是 5' 非依赖的。）

2) 5' 非翻译区发夹结构；

3) 5' UTR 蛋白互作区；

4) uORF；

5) 内部核糖体识别序列, IRES；

6) kozak 顺序；

7) 程序性移码；

8) miRNA；


9) 3' UTR 蛋白互作区；

10) Zip-CODE；

11) CPE(cytoplasmic polyadenylation element)；


12) 3' PolyA 尾。

25.2.1 5' 帽结构与翻译整体调控



eIF4E (帽结合蛋白) 结合蛋白 (4E-BPs) 的功能。4E-BP 与 eIF4E 的结合阻止 eIF4E 与 eIF4G 的结合，翻译受阻。当 4E-BP 分子磷酸化时，4E-BP 与 eIF4E 分开，释放的 eIF4E 蛋白与 eIF4G 结合起始翻译。


25.2.2 Poly(A) 与翻译调控



CPE(cytoplasmic polyadenylation element) 是 mRNA 3' UTR 区中一段与翻译起始调控相关的序列。CPE 结合蛋白 CPEB 磷酸化后被活化，活化的 CPEB 与 CPE 结合可促使 mRNA 延伸 Poly(A) 尾，促使翻译起始。

具体机制上，孕激素刺激卵母细胞可使 Aurora 蛋白磷酸化 CPEB 的 Ser174，活化的 CPEB 与 CPSF(cleavage and polyadenylation specificity factor) 结合促使其进入多聚腺苷活化位置，随之 CPSF 征调 PAP 从而使 mRNA 尾多聚腺苷化，解除 Maskin 的抑制作用。

一、母源 mRNA 脱腺核苷酸抑制翻译




非洲爪蟾的卵细胞中有许多母源 mRNA，必须储存到受精卵发育时才进入翻译。这些 mRNA 在转录后加帽与加尾，随后会经历去 3'-端腺苷酸化进入专门储存 mRNA 的颗粒中。在受精卵发育时在细胞质中激活加尾翻译。

25.2.3 mRNA 5' 发夹结构与翻译的专一性调控

- ①mRNA 5' 发夹结构可影响核糖体扫描，是翻译调控的位点之一；
- ②发夹结构的形成与 5' UTR 序列有关；
- ③发夹结构由翻译起始复合物 eIF4A 解除；
- ④解除发夹结构需要能量。


一、5' 发夹结构影响翻译起始效率



5' 引导序列的二级结构也对翻译效率有重要影响。如果在转录起点与 AUG 之间引入一段可以形成发夹结构的序列，可明显阻止 mRNA 的翻译。


当发夹结构 ΔG 稳定性处于 -125.52kJ/mol (-30kcal/mol) 时, 翻译效率开始降低。如 ΔG 增至 -209.2kJ/mol (-50kcal/mol) 时, 抑制效率可达 85% – 95%。许多植物基因 5' 引导序列可形成二级结构, 如植物醇溶性蛋白 (zein) 基因编码的 mRNA, 其引导序列含有不完全的反向重复序列, 产生一段 20bp 长的双链 RNA, ΔG 值为 -83.68kJ/mol (-20kcal/mol)。如果这段重复序列缺失, 翻译效率可增加 50 倍。

二、铁蛋白吸收与转运基因 5'-UTR 发夹结构与翻译调控



细胞铁蛋白 mRNA 的翻译控制: 铁蛋白和铁转运蛋白的 mRNA 均含有茎环结构, 称之为铁响应元件 (IRE)。IRE 可与铁响应蛋白 (IRBP) 结合。铁蛋白 mRNA 的 IRE 位于 5' 非翻译区, 铁转运蛋白 mRNA 的 IRE 位于 3' 非翻译区。铁饥饿时 IRBP 与铁蛋白及转运蛋白 mRNA 的 IRE 紧密结合阻止翻译, 但可稳定这两个铁响应蛋白 mRNA。当铁过量时, IRBP 与铁元素结合, 离开两种 mRNA, 导致转运 mRNA 降解, 铁蛋白 mRNA 翻译。(*Science* 238: 1570, 1988)

三、镁离子转运基因 5'-UTR 发夹结构与翻译调控




沙门氏菌（salmonella enterica）细胞内存在一种对环境中镁离子浓度响应的双调控系统。当细胞外镁离子浓度较低时，位于细胞膜上的 PhoQ 蛋白可以感受并激活胞内激酶域使 DNA 结合蛋白 PhoP 磷酸化促使镁离子跨膜转运蛋白基因 *mgtA* 转录并合成 MGT A 蛋白。当细胞内镁离子浓度增高时，体内的镁离子可与 *mgtA* 的 mRNA 5' UTR 区的核酸开关（riboswitch）互作产生茎环结构阻止 *mgtA* mRNA 的翻译，从而减少镁离子输入。（*Cell* 125: 71-84, 2006）

25.2.4 翻译的专一性调控因子 miRNA

miRNA 在 mRNA 的翻译起始调控中具有广泛的作用，可在 mRNA 的 5'-UTR 区与特定的序列结合，促使翻译起始（A, B）。也可在 mRNA 的 3'-UTR 区与特定的序列结合抑制翻译。（*Int. J. Mol. Sci.* 2013, 14, 480-495）

25.2.5 uORF 与 5' 专一性翻译调控



①酵母细胞在氨基酸饥饿时需要合成不同的氨基酸，氨基酸合成酶基因的转录受 GCN4 蛋白调控。GCN4 基因 5' 非翻译区长 600 bp，含有 4 段很短的非翻译 ORF (uORF)，它们可调控 GCN4 蛋白的合成。

②将 GCN4 的引导顺序与 lacZ 基因构建嵌合基因，依次将 4 个 uORF 突变。在富含氨基酸条件下检测 lacZ 酶活性，可发现 uORF 具有抑制翻译功能。

25.2.6 mRNA 内部起始翻译的 IRES 顺序

内部核糖体进入位点 (IRES, internal ribosome entry site)。由 Sonenberg N 和 Wimmer E 分别报道, 引起小儿麻痹症的脊髓灰质炎病毒 (poliovirus) RNA 和脑心肌炎病毒 RNA 中存在一种可吸引核糖体起始翻译的结构, 将其定名为 IRES。(*Nature* 334, 320-325, 1988)

IRES 是 mRNA 5'-UTR 一段序列, 可形成特征性的二级结构或三级结构, 核糖体可识别该结构并在这一位置组装起始翻译。目前为此, 尚未发现 IRES 的普遍性结构。

一、生物学意义

①**病毒侵染**。小 RNA 病毒 (picornavirus) 进入侵染细胞后, 利用自身蛋白酶破坏宿主 eIF-4G 分子使其不能起始翻译, 但为了自身生存病毒可利用 IRES 起始翻译。

②**真核细胞生长**。在有丝分裂和凋亡时, 细胞可使 eIF-4E 去磷酸化抑制翻译。许多有丝分裂必需蛋白的需要翻译, 这些 mRNA 利用 IRES 结构继续。


③**程序性死亡**。病毒感染真核细胞后, 破坏 eIF-4G 减少翻译, 但细胞程序性死亡仍需要一些功能蛋白质表达, 相关的 mRNA 含有 IRES 可在细胞的程序性死亡时仍然正常翻译。

二、IRES 的分子生物学功能

在压力条件下, 有些 mRNA 翻译被抑制, 但有些具有 IRES 的 mRNA 可以正常翻译。4E-BP(eIF4E-binding protein) 是一个翻译整体抑制调控蛋白。在饥饿状态, 4E-BP 可与 eIF4E 结合, 阻止依赖 5' -帽翻译起始路线, 但对一些具有 IRES 的 mRNA 的翻译不起作用。

ITAFs(IRES trans-acting factors) + eIF4GI or p97/DAP5/NAT1 水解片段 + eIF4G 远缘同源蛋白 → 激活 IRES 翻译。(*Nat Rev Mol Cell Biol.* 6:318-27, 2005)

三、脑心肌炎病毒的 IRES



IRES 结构域及其与转录相关因子的结合区域 (by footprinting): **eIF4G/4A 复合体** (蓝/绿色), **ITAF 45**(菱形), **PTB**(灰色)。PTB 包含 4 个 RRM 功能域, 结合 EMCV-like IRESs 的多个位点。PTB 蛋白和 IRES 中的茎环结合稳定 IRES 并可招募 40S 核糖体亚基 (红色, 携带 tRNA 和 eIF3 蛋白) 与 mRNA 结合, 由此起始翻译装置的组装。

25.2.7 Kozak 顺序与顺式调控

真核生物翻译起始最佳顺序							
-3	-2	-1	+1	+2	+3	+4	
A	C	C	<u>A</u>	<u>T</u>	<u>G</u>	G	
酵母翻译起始一致顺序							
			+1				
<u>A</u>	<u>A</u>	<u>A</u>	<u>A</u>	<u>A</u>	<u>A</u>	<u>T</u>	<u>G</u>
T		C		C		T	C
植物翻译起始一致顺序							
C	A	A	C	A	<u>A</u>	<u>T</u>	<u>G</u>
						G	C
							N


Kozak 顺序 (Kozak consensus): —ACCAUGG—, 是一段位于翻译起始密码前后 (-3, -2, -1 和 +4) 的碱基序列 (RccAUGG, R 为任意嘌呤)。

25.2.8 程序性移码

真核生物逆转录病毒的 Gap/Pol 基因可产生两种蛋白质 Gap 和 Gap-Pol 融合蛋白。在 Gap 蛋白的终止密码下游有一段序列可形成发夹结构, 可指令翻译装置在这一位置发生程序性移码翻译。

核糖体作图

核糖体作图 (Ribosome profiling) 是一种分子生物学技术。通过检测核糖体在 mRNA 分子上停留的位置来确定哪些 mRNA 在翻译, 在何处起始翻译。可提供某一时刻, 某一细胞中 mRNA 的整体翻译场景 (global snapshot), 对翻译的起始位置与分布, 核糖体的翻译速度进行监测。使用交联剂可使正在翻译中的核糖体与 mRNA 固着结合, 随后提取结合物。消化裸露的 mRNA 后, 可提取核糖体保护的 mRNA 片段测序。



核糖体 E 位抑制剂的翻译场景作图。CHX 和 LTM 可与核糖体 E 位结合抑制翻译。当翻译核糖体 E 位空置时，CHX 可与所有核糖体结合，阻止翻译延伸。但 LTM 在 E 位空置时只与翻译起始位的核糖体结合阻止翻译起始。同时进行 CHX 和 LTM 处理，可对翻译起始位置和延伸停留位置作图。

25.3.1 应用

发现了隐藏在遗传密码中以前未被认识到的信息。细微的遗传变化会带来重要的影响，导致蛋白质翻译速率降低到正常速度十分之一或更低。(Nature 484: 538–541, 2012)

一、揭示翻译场景


- 1) 翻译速度在小鼠胚胎干细胞中每秒 6aa。
- 2) 在小鼠胚胎干细胞 1100 个基因中发现 1500 个主要的翻译停留，为标准的 25 倍，即延长了停留时间。
- 3) 翻译停留位置主要为：Pro-Pro-Glu，脯-脯-谷氨酸。
- 4) 检测的 5 000 个基因中，类翻译起始位置（AUG）为 13454 个。其中约 65% 的 mRNA 含 1 个以上起始位置，16% 含 4 个以上翻译起始位置。
- 5) 在上游区发现大量 uORF，其起译密码子多偏离 AUG，多数为发生了单碱基代换的 AUG 如 CUG 和 GUG。
- 6) 鉴定了 570 个上游起译位置可产生 N-端不同的蛋白质，下游 870 个起译位置可产生残缺蛋白。
- 7) 上游存在的起译位置多于常规分析 10 倍。

第二节 蛋白质的翻译调节

蛋白质的剪接


26.1.1 内含肽 (Intein)

内含肽是指翻译产生的多肽序列中被切除的内部多肽顺序。含有内含肽的蛋白质必需将内含肽切除将两侧的外显肽连接才能成为成熟的蛋白质。目前已在古细菌、真细菌和真核生物中发现 130 多种具内含肽的蛋白质，内含肽的切除机制基本相同。



内含肽有保守的顺序组成。DOD 归巢核酸内切酶 (DOD Homing Endonuclease)。

26.1.2 蛋白质的反式剪接



注：蓝细菌 *Synechocystis* sp. PCC6803 基因组中编码 DNA 多聚酶 111a 亚基的基因 *DnaE* 由两个分开的区段组成，*dnaE-n* 和 *dnaE-C*，并位于两条相反的 DNA 链上预期 *dnadE-n* 编码多肽由 Ext-n 及随后 123 aa 的 Int-n 组成，而 *dnaE-c* 编码多肽由 Ext-c 及随后的 36 aa 的 Int-n 组成。

蛋白质的折叠

蛋白质在合成之后必须经历一个正确折叠的加工过程才能成为成熟的蛋白质，细胞中蛋白质折叠的场所所有：胞质溶胶、线粒体、叶绿体、内质网。


折叠方式。蛋白质多肽链折叠的马尔可夫模型，在无外力干扰下，蛋白质多肽链可有多种随机方式折叠成三维构型。

26.2.1 蛋白质的折叠过程

蛋白质合成后，由于多肽链含有亲水或疏水氨基酸，在水溶液状态，会产生疏水性氨基酸的随机聚合，形成无规律的构型。

分子伴侣。细胞中蛋白质从核糖体上合成后，分子伴侣蛋白（chaperone）即可与新生多肽链结合，阻止疏水性氨基酸之间的自发聚合，典型例子是 Hsp70。

一、蛋白质折叠体的功能




蛋白质在折叠体 **GroEL/GroES** 复合物中的折叠过程：

①GroEL 由两层 7 亚基蛋白环状结构组成，每个亚基蛋白可与 ATP 结合。

②ATP 的水解提供蛋白质折叠所需的能量。

③图中每个亚基蛋白上的圆点表示 ATP 或 ADP 分子。

二、叶绿体中蛋白质的折叠



三、膜蛋白的折叠

α -螺旋膜蛋白折叠的“两阶段模型”：①多肽链基于疏水作用，插入脂质双分子层，并通过螺旋内氢键形成二级结构，只有极少数 α -螺旋膜蛋白能够自主插入，大多需要易位子（translocon）跨膜蛋白复合体帮助；②已形成的跨膜螺旋之间相互作用，进一步组装成更加紧凑的三级和四级结构。

β -折叠膜蛋白的折叠，多肽链在易位复合体系统和伴侣蛋白的协助下到达目标位置后，由 β -桶组装复合物（BAM）来催化折叠和膜插入。

蛋白质的修饰

基因组仅能编码 20 种氨基酸，均由标准密码指令，但实际蛋白质类型的复杂性远比编码预期的水平高出 2-3 个数量级（Walsh et al, 2005）。这种有限的编码能力促使大量蛋白质的翻译后修饰，以产生众多“新”氨基酸类型，扩展了基因组编码的蛋白质复杂性。

已发现超过 400 种蛋白质修饰类型，其中三种主要的蛋白质修饰是磷酸化、乙酰化和泛素化，占有报道修饰的 90% 以上（Ramazi et al, 2021）。

修饰类型	修饰的残基	可逆性	功能
磷酸化 (phosphorylation)	丝氨酸、苏氨酸、酪氨酸、组氨酸等	是, 或否	信号传导、蛋白质活性调节、蛋白质之间的相互作用等
硫酸化 (sulfation)	酪氨酸、丝氨酸、苏氨酸	否	蛋白质之间的相互作用、运输和定位等
糖基化 (glycosylation)	丝氨酸、苏氨酸、天冬酰胺、色氨酸等	否, 或是	蛋白质溶解度、稳定性、细胞识别、分泌与相互作用等
乙酰化 (acylation)	N-末端、赖氨酸等	是	染色质稳定性、基因转录调控等
甲基化 (methylation)	赖氨酸、精氨酸等	是	蛋白质之间或与核酸的相互作用、染色质沉默与基因转录调控等
异戊二烯化 (prenylation)	半胱氨酸	否	蛋白质相互作用、内容作用调节、蛋白质运输等
豆蔻酰化 (myristoylation)	甘氨酸、赖氨酸	否	稳定蛋白质结构成熟、信号传导、细胞外通讯等
羧基化 (carboxylation)	谷氨酸	否	蛋白质功能等
ADP 核糖基化 (ADP-ribosylation)	精氨酸、天冬酰胺、天冬氨酸、谷氨酸等	是	蛋白质的活性、结合能力、影响蛋白质的泛素化降解等
泛素化 (ubiquitination)	赖氨酸等	是, 或否	蛋白质降解信号、蛋白质相互作用、活性、定位的调控等
羟基化 (hydroxylation)	脯氨酸、赖氨酸、天冬酰胺等	否	蛋白质的成熟和稳定性、转录因子活性等

26.3.1 蛋白质修饰的方式

磷酸化: 至少三分之一的真核蛋白可能被磷酸化, 蛋白质磷酸化酶称为激酶 (kinase), 是最大的一类蛋白质修饰酶。细胞内的磷酸化与去磷酸化处于动态平衡。磷酸化后, 二价阴离子磷酸基团 (PO_4^{2-}) 取代了中性的羟基 (OH), 导致蛋白质构象、化学和静电性质的变化, 进而引起活性的变化。被磷酸化的信号蛋白可以进一步催化下游蛋白质的磷酸化, 发生磷酸化级联反应, 是细胞内信号传导的主要路径之一。

乙酰化: 组蛋白的乙酰化是表观遗传密码的组成部分, 参与了基因转录的选择性调控。组蛋白含有大量的赖氨酸和精氨酸, 携带正电荷。乙酰化中和了赖氨酸侧链上的正电荷, 促使 DNA 与组蛋白结合的松弛, 便于转录因子进入核小体覆盖的染色质区域, 激活基因的转录起始。细胞中还存在大量乙酰化的非组蛋白, 广泛参与各类生物学过程。

泛素化: 泛素本身是一种蛋白质, 因此也具有许多潜在的修饰位点, 会受到如磷酸化、乙酰化等进一步的修饰, 称为“泛素密码”, 参与更广泛的非蛋白降解功能 (Swatek et al, 2016)。

糖基化: 是最复杂的蛋白质修饰, 其复杂性即体现在修饰基团大分子多糖本身的分子组成, 又存在于靶标蛋白质修饰位点和连接方式上。

26.3.2 蛋白质修饰的功能

修饰调节了蛋白质的物理化学性质、结构、活性以及与其他生物大分子之间的识别与互作, 进而在基因表达调控、信号转导、细胞周期、生理代谢、环境应激等生命体各个阶段发挥重要的生物学功能。

各种修饰不是孤立出现的, 或多个聚集、或多种组合, 在实际的功能机制中相互协同、增益, 或彼此抑制、干扰。

一、信号转导

磷酸化信号级联反应：①相同的磷酸盐分子从一个蛋白传递到另一个蛋白，称为**磷酸传递系统**；②当 1 个上游激酶磷酸化激活 1 个以上的下游激酶，即**信号放大**；③许多蛋白质具有多个磷酸化位点，成为不同激酶的靶点、**整合不同信号通路的信息**，磷酸化作为信号积分器，为**信号协同或增强**提供途径。

二、基因表达调控

组蛋白受到**磷酸化、乙酰化、甲基化、泛素化**等多种蛋白质修饰，是表观遗传学的重要基础。组蛋白**多个氨基酸残基**是修饰位点，同一位点还包含**渐进式的不同程度修饰**。如 H3K9ac、H3K27ac、H4K5ac、H3K4me1、H3K4me3 等通常是转录激活标记，H3K27me3、H3K27me 和 H4K20 的甲基化与转录抑制相关，H3K4me2 在线虫里与表达正相关、在水稻里负相关。

转录在混合修饰的背景下发生的，不同位点的不同修饰会产生**共激活和共抑制的平衡**，形成复杂、微妙的协同调控功能（Berger et al, 2007）。

三、蛋白质的稳定性与蛋白质修饰

参与的主要修饰是泛素化；靶蛋白的磷酸化为泛素连接酶提供了靶标；乙酰化与泛素化竞争相同的赖氨酸残基位点；糖侧链可以增强糖基化蛋白的稳定性、溶解度，保护其不被降解。

26.3.3 蛋白质修饰的动态性和不均质性

动态性。蛋白质修饰的**可逆性**，产生了修饰的动态性特征。动态性使得生物体面对环境中的微小变化、可以精确迅速的进行功能调整，而不必耗时耗能进行蛋白质的合成和降解，或在进化上储备过多的功能基因。

不均质性。修饰不必发生于特定靶蛋白的所有分子中，而是以**化学计量比例**式存在，并在**时间或空间分布**上也存在差异，总体呈现为修饰的不均质性。整体来看，群体中的不同个体之间存在修饰位点、类型、水平的差异和多样性，最终体现为**群体功能的复合体特征**。

蛋白质的定位

准确的蛋白质分选和定位是其成熟的必需过程，蛋白质定位也是细胞内功能调控、环境应激响应的一种分子机制。在基因组、蛋白质组学研究过程中，预测蛋白质亚细胞定位的能力将有助于表征未知表达序列功能，蛋白质定位动态变化产生的复杂性，也扩展了基因组功能的复杂性（Yu et al, 2006；Carrie et al, 2009）。

26.4.1 蛋白质的定位信号

蛋白质的定位信息或可识别的定位标记，称为靶向结构域或定位信号，作为**邮政编码**（zip codes）携带于蛋白质初始的一级序列中，通常在到达目的地后被水解去除。多数定位信号没有简单的一致性序列，但可能具备相似的组成特征。

靶向细胞器	信号名称	信号位置
内质网	signal peptide (SP)	N-末端
叶绿体	chloroplast transit peptide (cTP)	N-末端
类囊体	lumenal transfer peptide (ITP)	N-末端
线粒体	mitochondrial transfer peptide (mTP) / presequence	N-末端
过氧化物酶体	peroxisomal targeting signal (PTS)	N-末端, C-末端
细胞核	nuclear localization signal (NLS)	N-末端, 内部, C-末端
液泡	vacuolar sorting signal (VSS)	N-末端, 内部, C-末端

26.4.2 蛋白质的分选与转运

不包含 SP：翻译完成后在细胞质中释放，随后或留在细胞质中，或被转运到线粒体、叶绿体、过氧化物酶体、细胞核等细胞器，称为**翻译后转运**。

包含 SP：进入**分泌途径**（secretory pathway），多肽的翻译合成和转运同时发生，称为**共翻译转运**（cotranslational translocation）。真核细胞的分泌途径包含一个广泛的膜系统，膜泡膜蛋白也是识别货物蛋白靶向结构域的受体。

一、核蛋白质定位信号

NLS 核定位信号可被**输入蛋白 α** 识别。输入蛋白 α 本身也含有双体信号，可被**输入蛋白 β** 识别。

与其他定位信号的不同之处在于，蛋白质入核后 NLS 不会被切除，使得核蛋白具有重复入核的能力，当细胞分裂期间核被膜破裂、核蛋白被释放到细胞质中之后，这种能力帮助细胞核重新收集自身成分。

与穿过内质网和线粒体膜的蛋白质不同，核蛋白以折叠状态进入细胞核。

核蛋白进出细胞核的转运过程也是细胞内功能调控手段之一。例如，细胞质中的抑制因子通过结合核蛋白 NLS 区域，能阻碍输入蛋白 α 与 NLS 的识别，使核蛋白留在细胞质；环境刺激或生长控制信号，如光、胁迫、激素等，对抑制因子产生磷酸化/去磷酸化等修饰，使其释放 NLS，促进核蛋白入核发挥功能。因此，一些核蛋白的核定位会表现出组织特异性、或环境刺激响应的差异化特征。

蛋白质的降解


26.5.1 蛋白质降解的顺式信号

①**毁坏盒**：人类蛋白质 I κ B α 和 β -catenin 以及 HIV 病毒 Vpu 蛋白含有 -Asp-Ser-GlyX-X-Ser-序列；细胞周期蛋白(cyclin)A、B1 和 B2 含有识别顺序-Arg-Leu-Gly-X-X-X-Ile-Gly-，也是蛋白质磷酸化的位点。

②**PEST 序列**：如富含脯氨酸 (P)，谷氨酸 (E)，丝氨酸 (S) 和苏氨酸 (T) 序列片段的蛋白质半衰期短于其他蛋白质，是蛋白质快速水解的信号。

③**降解子**：酵母中发现至少有 10 种不同的蛋白质降解信号，它们包括 i.N 端降解子 (N-degron)，位于蛋白质 N 端的一段氨基酸顺序；ii. 通过对蛋白质 N-端的修饰提供降解的信号。

26.5.2 蛋白质降解系统



细胞内部有两条降解蛋白质的路线：

①以**蛋白酶体**为降解场所，负责清除细胞内体积较小的错误折叠蛋白和受损蛋白等；

②以**溶酶体**为降解场所，通过自噬识别并清除体积较大的蛋白质及异质性物质（如蛋白质聚集体、细胞器、脂滴或入侵细菌等），由蛋白酶消化降解。

这两种方式之间存在功能联系和相互通信，以协调它们在蛋白质稳态中的作用。它们最显著的共同点是使用**泛素化**作为降解靶标的标记。

细胞内蛋白质的降解主要分为 3 个步骤：1) **泛素化**，给降解的蛋白质贴上标签；2) 泛素化蛋白质**转移到 26S 蛋白酶体**；3) 蛋白酶体中蛋白质被**降解为小多肽和氨基酸**。

一、蛋白酶体的结构与功能

蛋白酶体是细胞内蛋白质降解的场所，由 19S 亚基和 20S 亚基组成。

19S 亚基有两个复合物：唇盖（Lid）有 8 个亚基，接纳泛素化蛋白质底物；基盖（Base）有 9 个亚基，内含 6 个 ATP 酶亚基，可将折叠的蛋白质底物线性化，使其进入蛋白媒体内腔。

20S 亚基像一个柱状物体，由 4 个环形蛋白质复合物组成。外部两层为 α 亚基层，各含 7 个亚基，内部两层为 β 亚基层，也含 7 个亚基，具有类胰凝乳蛋白酶活性。蛋白质底物进入蛋白酶体后在 β 环形柱内部降解。

二、溶酶体途径的膜蛋白质降解

溶酶体是分解蛋白质、核酸、多糖等生物大分子的细胞器。内含许多水解酶及酸性环境。进入溶酶体降解的膜蛋白需要经过识别、泛素化标记、分拣和转运，然后转移到 MVB（multivesicular bodies，多囊泡体）。MVB 与溶酶体融合，泛素化蛋白质在溶酶体中降解。

三、泛素介导的蛋白质降解是一个有序的级联反应

蛋白质泛素化是一个程序化过程：首先泛素需经泛素激活酶 (E1) 活化，然后转移到泛素配位酶 (E2)。与此同时，泛素连接酶 (E3) 与选择的降解底物蛋白质结合，并和 E2 协作将泛素转移到蛋白质，使蛋白质泛素化。

四、识别降解蛋白的三种方式

①组成型识别，例子是 N-端法则。

②修饰识别，例子是磷酸化 (IkB α)

③借助辅助蛋白识别，例子是 p53 或 Hsc70 介导的降解。

五、细胞周期调控依赖蛋白酶体

真核生物的细胞周期严格受到细胞周期蛋白及其激酶的调控，这是一个有序的过程。在前一个周期蛋白及其激酶降解后，细胞周期才进入下一个步骤。

六、APC/C 与细胞周期控制

APC/C 是一个与细胞周期调控有关的泛素化 E3 酶复合物 (细胞周期体), 有 11-13 个亚组成, 包括 cullin(Apc2) 和 RING (Apc1), 类似 SCF。APC^{Cdh1} 或 APC^{Cdc20} 复合物可将 Securin 泛素化降解, 从而解除 Securin 对分离酶 (separase) 的束缚。游离的分离酶可破坏凝聚蛋白 (cohesin), 使粘连的姐妹染色体彼此分开, 促使细胞分裂进入后期。

APC/C 复合物的功能主要是通过将特定的蛋白质 (Securin 和细胞周期蛋白 cyclin) 泛素化使其降解, 从而触发细胞分裂周期从中期向后期转变。


①Securin(分离酶抑制蛋白) 与磷酸化的 Separase (分离酶) 结合, 使之处于无活性状态;

②APC/C 促使 Securin 降解, 释放活性 Separase;;

③Separase 降解凝集蛋白使姐妹染色单体分开, 细胞分裂周期进入末期。

26.5.3 蛋白质泛素化过程

蛋白质泛素化就是给需要降解的蛋白质贴上泛素多肽标签的过程。



蛋白质泛素化系统由 3 个组分构成：①**泛素激活酶 E1** 利用 ATP 释放以其半胱氨酸残基（Cys）的巯基与泛素（Cys）的巯基与泛素 C-端的甘氨酸残基（Gly）形成硫酯键；②连接在 E1 上的泛素转移到另一个**泛素结合蛋白 E2** 上；③被选中的靶蛋白与第三个组分即靶蛋白**泛素连接酶 E3** 结合。E2 将与其连接的泛素转移到靶蛋白上，并与靶蛋白赖氨酸残基（Lys） ϵ -NH₂ 基团形成异肽键（isopeptidebond），E2 被释放；④循环逐个添加泛素分子。

选择哪个蛋白质进行泛素化主要取决于 E2 和 E3。

一、泛素化类型

底物蛋白质命运的差异取决于**泛素化数量和位置结构**的不同。泛素自身的 7 个赖氨酸（Lys）残基（Lys6、Lys11、Lys27、Lys29、Lys33、Lys48 和 Lys63）或 N-端甲硫氨酸（Met1）都可以被泛素化，逐步组成**直链、分支链**等不同结构的多聚泛素链。

泛素化修饰有多种方式：单个泛素化，多位点单个泛素化，单位点同型多泛素化，单位点异型多泛素化，单位点侧支多泛素化（引自 Foot N et al, 2017）。

26.5.4 其他与蛋白质降解相关的机制

一、借助磷酸化修饰识别降解蛋白质

免疫应激反应借助磷酸化促使转录抑制蛋白降解, 启动相关基因的表达。NF κ B 转录因子由亚基 p50 和 p65 组成。结局由小 RNA 的结构与表观遗传

二、植物激素响应涉及抑制因子降解

植物激素如生长素 (a) 和赤霉素 (b) 诱导下游基因表达涉及抑制因子的降解 (c), 由此释放转录激活蛋白, 从而启动下游激素路线响应基因的表达。

lncRNA

lncRNA 是 long non-coding RNA 的简称, 即长非编码 RNA; lncRNA 早和由鱼约好自己的稿子, 发现 lncRNA 由 Pol II RNA 聚合酶转录, 具有 mRNA 的结构特征但无编码功能。

lncRNA 一般长度大于 200 nt, 缺少功能的 **ORF** (开放读码框)。

26.6.1 第一个 lncRNA

H19。cH19 基因含 5 个外显子，mRNA 全长 2.3 kb，小鼠 H19 mRNA 潜在的 ORF 共有 35 个，但缺少跨越 2 个连续外显子的 ORF。直到 2013 年才明确 lncRNA H19 的功能，其能够拮抗 *let-7*。在小鼠 C2C12 成肌细胞中敲低 H19 或过表达 *let-7* 均可导致多核肌管形成增加。

26.6.2 第一个功能 lncRNA

SRA 是类固醇受体 RNA 激活因子 (Steroid receptor RNA activator) 的简称，是第一个阐明具有功能的非编码 RNA，可反式激活增加类固醇受体蛋白的活性 (*Cell* 97:17-27, 1999)。SRA 基因含 5 个外显子，mRNA 长 0.7–0.85 kb。SRA 基因有两个表达产物：SRA lncRNA 和 SRAP 蛋白。SRA lncRNA 可与许多转录调控蛋白结合，起一个复合物骨架的作用，增强类固醇受体蛋白基因转录活性。SRAP 蛋白也可与 SRA lncRNA 结合，但起抑制转录的作用。此外，SRA lncRNA 还可介导 p68 和 CTCF 的结合，CTCF 是绝缘子 (DNA 序列) 结合因子，隔离临近基因转录的干扰。

SRA lncRNA 的功能主要是转录共激活复合物的骨架分子。

26.6.3 Xist RNA

Xist (X-inactive specific transcript, 失活 X 染色体专一性转录物) 是一个编码 RNA 的基因，只在胎盘哺乳动物的失活 X 染色体表达。Xist 基因含 7 个外显子，小鼠转录产物全长 15 kb，没有保守的 ORF。*Xist* RNA 的转录与 X 染色体的沉默有关。 X_a ：活性 X 染色体； X_i ：失活 X 染色体 (Barr 小体)。

26.6.4 lncRNA 的特点

一、RNA 雾霾

围绕基因区的各种 ncRNA: 1) mRNA; 2) 反义 RNA; 3) 3'-端独立转录物; 4) 末端 RNA(TASRs); 5) 二次加帽 mRNA; 6) 转录起始点 RNA; 7) 启动子关联短 RNA(PASRs); 8) 第一外显子反义 RNA; 9) 核心启动子双向转录 RNA; 10) 部分重叠 ncRNA; 11) 启动子关联长 RNA(PALRs); 12) 启动子上游 RNA; 13) miRNA, 内源 siRNA; 14) 外显子加帽 RNA。

二、转录组中的 lncRNA

人类基因组的转录物中约 20% 编码蛋白质，约 80% 为非编码 RNA (lncRNA)。FANTOM 发现，有 35000 个非编码转录物来自约 10000 个基因组位点，具有典型的 mRNA 结构。

小鼠基因组转录物测序估计转录产物总数约 180000，其中编码蛋白质基因的转录物约 20000，其余的 160000 为 lncRNA。

总体看，人类基因组中 lncRNA 的确切数目很难获知。据估计人类基因组 lncRNA 数目在 7000-23000。Lipovich L 等估计，人类基因组保守的 lncRNA 基因数约在 3000。

ENCODE project 根据证据确定了 14 880 个 lncRNA，其中 9518 个为基因间区转录 (lincRNAs)，5362 个在基因位置转录（正义链，反义链或内含子区）。

三、lncRNA 的结构特点赋予其功能多样性

- ①lncRNA 分子具有**快速周转**的特点；
- ②lncRNA 分子具有**可塑的高级结构**，可灵敏感应细胞内环境的变化；
- ③lncRNA 分子可与 RNA，DNA，蛋白质，有机分子甚至金属离子（镁离子）互作，是理想的**信号传递中介分子**；
- ④lncRNA 分子的遗传信息可保留在 DNA 序列中，具有很强的容错性，适应**快速的进化**。

四、lncRNA 适合识别 RNA 和 DNA

RNA 可以通过一个短序列（如 8 碱基）与 RNA 或 DNA 配对。但蛋白质识别 8 碱基 RNA 序列，按 35-39 aa 识别一个碱基计算，总共需要 105-117 个 aa，基因组必须提供 840-936 bp 长度 DNA。与 RNA 的识别能力比较，蛋白质识别相同序列的 RNA 需要更多的基因组 DNA 顺序。

五、RNA 分子的高级结构提供了分子间的识别界面

RNA 分子可以折叠成复杂的三维结构，由此可以提供一个多面的识别界面。这种结构极大地扩展了 RNA 与不同生物大分子靶标结合的亲和性与专一性。因此 RNA 分子在细胞内被选择用于和各种大小不同的分子（从有机分子到蛋白质）结合，执行不同的生物学功能。

六、RNA 具有快速表达灵活周转的特点

RNA 分子适合快速的瞬时表达。RNA 分子在转录和加工后可立即成为具有完全功能的形式,能迅速降解,因而 RNA 能适应快速信号响应与传导。依赖蛋白质的生物学过程要进行 mRNA 的转录和蛋白质的及时降解,其效率远不及 RNA。此外,配体与 RNA 的结合可以触发 RNA 的构型改变,使其具有灵活的动力学特性。

26.6.5 lncRNA 的其他生物学功能

①**信号感应转录抑制调控的 lncRNA (COLDAIR & COOLAIR)。**拟南芥冷诱导开花调控 lncRNA: 在拟南芥 FLC 基因区内检测到与 FLC mRNA 同向转录的非编码 RNA, COLDAIR RNA。此外检测到反向转录非编码 COOLAIR RNA。功能分析证实,春化处理诱导 COLDAIR RNA 的转录,可抑制 FLC 的表达,解除 FLC 基因开花抑制效应,促使植株转入生殖生长 (*Science* 331, 76–79, 2011)。

②**感应 DNA 损伤的 lncDNA。**在人类细胞中,已鉴定出对辐射诱导 DNA 损伤响应 lncRNA-D1 pncRNA。D1-pncRNA 来自 D1 基因 (cyclin D1, 细胞周期蛋白) 启动子区转录。D1-pncRNA 可与 TLS 蛋白 (脂肪肉瘤转位, translocated in liposarcoma/fused in sarcoma) 结合,导致 D1 基因关闭。在 D1 基因的启动子区, CBP/p300 转录因子和与 CREB(cAMP response element binding protein) 一道与 CRE 元件结合通过 CBP/p300 的 HAT 活性激活 D1 基因的转录。在 DNA 损伤时, D1-pncRNA(promoter-associated non-coding RNA) 被转录, TLS 与 D1-pncRNA 结合,招募 CBP/p300, 并与结构蛋白 p/CAF 组成复合物,抑制 D1 基因活性。

③**诱捕 lncRNA。***GAS5* (growth arrest-specific 5, GAS5) lncRNA 可与糖皮质激素受体蛋白结合,抑制后者与应答元件的结合,阻止靶基因表达;逆转座子来源 lncRNA 可通过结合抑制性转录因子 SFPQ 上调抗病毒基因 *RELA*。

④**介导作用 lncRNA。**主要是环化 DNA。在人类 HOXA 基因簇座位,采用瓦式芯片杂交分别在 HOXA1 和 HOXA2 基因之间,在 HOXA6 和 HOXA7 基因之间和 HOXA13 基因的上游区发现 3 个非编码 RNA: HOTAIRM1, Mira 和 HOTTIP。这 3 个 lncRNA 可正调控邻近 HOXA 基因的表达。MLL1, WDR5: 表观遗传修饰复合物成分。

⑤**骨架作用 lncRNA。**HOTAIR 是位于人类 Chr.12 染色体上编码 RNA 的基因。HOTAIR RNA 全长 2158 nt, 缺少保守的 ORF。HOTAIR RNA 可以作为蛋白质复合物的骨架把两个表观修饰的酶复合物捆绑在一起,调控 Chr.2 染色体 HOXD 座位转移抑制基因的转录。

一、lncRNA 与翻译调控

①**lncRNA 调控 mRNA 翻译水平**。lncRNA SINEB2 可与泛素羧基端酯酶基因 (*ubiquitin carboxyl-terminal esterase L1, Uchl1*) mRNA 的 5' 端结合, 增强后者的翻译水平。

②**lncRNA 调控 mRNA 稳定性**。mRNA 的降解机制中有一种称为无义降解路线 (nonsense-mediated decay)。某些 mRNA 的 3' 端含有 Alu 重复序列, 而有的 lncRNA 也含有可与 Alu 互补的序列。这类 lncRNA 与 Alu-mRNA 互作, 即可发生称之为 Staufen 介导的无义 mRNA 降解。

二、lncRNA 与基因调控机制的转型

Croft LJ 等分析了 89 个已测序的原核生物中调控因子与基因数目同步增加的比例关系: 随着复杂性 (基因数目) 的增加, 调控因子具有加速度增加的趋势。生殖支原体基因组有 450 个基因, 有 2 个调控基因。大肠杆菌基因组有 4 289 个基因, 有 275 个调控基因。大肠杆菌基因数约为生殖支原体的 10 倍, 但调控基因数增加了 100 多倍, 以几何级数 (二次方) 增长。他们推算, 在超出 20 000 个基因之后, 每增加一个基因, 就必须增加一个以上的调控因子。以蛋白质为主要调控手段的原核生物复杂性的极限是 10 000 个基因。多细胞真核生物的基因总数在 10 000-50 000 之间, 真核生物面临调控因子数目与基因数目增加的矛盾。真核生物突破这一瓶颈的方法是进行调控模式的转型, 选择 lncRNA 为主要的调控方式。

26.6.6 lncRNA 研究中的主要问题

lncRNA 的数量庞大, 但已知功能的 lncRNA 数极其有限。令人惊讶的一点是, lncRNA 还可以编码微肽并发挥生物学功能 (Niu et al. *Science Advances* 2020)。lncRNA 的研究存在以下需要面对的问题:

①**lncRNA 对点突变有很强的耐受性和容错率**, 一般情况下很难通过诱变获得 lncRNA 缺陷突变体;

②**仅仅根据注释的 lncRNA 中开放读框 (open reading frame, ORF) 的长短来判断是否真实的 lncRNA 并不可靠**;

③**缺少可以预测功能 lncRNA 的方法**;

④**在基因间区发现的 lncRNA 如果远离编码基因, 一般很难找到其作用的靶基因**。

第十一章 表观遗传

第一节 表观遗传和表观遗传现象

例子 1：扬子鳄卵在孵化温度为 28.5 摄氏度时，孵出的全部为雌鳄；当气温在 33.5 摄氏度到 35 摄氏度时，孵出的全为雄鳄；气温在 30 摄氏度时，雌雄比例相等。温度越高，孵化出的雄性幼鳄越多。基因型不变，但表型依环境变化发生改变，这是典型的表观遗传现象。

例子 2：蜜蜂中的工蜂与蜂后。

例子 3：**副突变**。指在一个基因座上，一个等位基因可以诱导另一个等位基因，发生可遗传的表达模式的改变。

表观遗传：研究 **DNA 序列不发生改变**的情况下，调控基因表达的**可遗传**的变化的现象和机制。

一个跨代遗传的例子。怀孕的雌性小鼠暴露在双酚 A（bisphenol A, BPA）中可导致其子代小鼠的肥胖，该效应在 F6 之后才会消失。

表观遗传的来源包括 DNA 甲基化及其衍生物；组蛋白修饰、变体与重塑、非编码 RNA、RNA 表观遗传修饰、三维基因组等。

第二节 DNA 甲基化

广义的 DNA 甲基化是指在 DNA 碱基上增加甲基基团的化学修饰。在表观遗传领域，DNA 甲基化一般特指 5-methylcytosine (5mC/5 mC)。5mC 不改变 DNA 的顺序组成，也不影响 GC 互补配对。

CpG 与甲基化

哺乳动物中的 DNA 甲基化位点主要在 CpG。哺乳动物基因组 DNA 中 5mC 约占胞嘧啶总量的 2%-7%，并且绝大多数的 5mC 存在于 CpG 二核苷酸中的胞嘧啶，称为甲基化的 CpG 位点。例如在人胚肺成纤维细胞 IMR-90 细胞株中，99.98% 的 5mC 在 CpG 中，但是在 H1 胚胎干细胞中，75.5% 的 5mC 在 CpG 中。

哺乳动物中 70%=80% 的 CpG 位点都是高度甲基化的。高度甲基化的序列包括卫星 DNA、重复元件、非重复基因间 DNA 和外显子。大部分序列是根据 CpG 二核苷酸的频率被甲基化的，唯一的例外是 CpG 岛 (CpG islands, CGIs)。


28.1.1 CpG 岛

CpG 岛 (CpG islands, CGIs) 是人类基因组中富集 CpG 序列 (GC 含量大于 50%，基因组 GC 含量平均为 40%)，长约 200bp-2kb 的区域。大部分 CpG 岛位于基因的启动子或者 5' 区域，大约 60% 的人类基因启动子含有 CpG 岛。

DNA 甲基化反应

DNA 甲基化反应是指生物体在 DNA 甲基转移酶的催化下，以 S-腺苷甲硫氨酸 (SAM) 为甲基供体，将甲基转移到特定的碱基上的过程。


28.2.1 DNA 甲基化酶的结构



图中所示为 3 个 DNA 甲基化酶的结构图: 图中罗马数字表示具有催化功能的结构域。NLS, 核定位信号; RFT, 复制场靶向结构域 (replication foci-targeting domain); BAH, 邻接 bromo 同源结构域 (bromo-adjacent homology domain); PWWP, 保守的脯氨酸-色氨酸

酸-色氨酸-脯氨酸结构域; **PHD**, 非典型植物同源异型富光氨酸区 (a cysteine-rich region containing an atypical plant homeodomain)。

28.2.2 DNA 重新甲基化与维持甲基化



重新甲基化是将甲基基团在 DNMT3A/B 的作用下直接连接到胞嘧啶 5-C 位置。**DNA 维持甲基化**是指 DNA 复制后以母链中保持的甲基化胞嘧啶为模板，将新链中对称的胞嘧啶甲基化。

28.2.3 DNA 甲基化与基因沉默

一般认为 DNA 甲基化与基因沉默相关，非甲基化与基因活化相关；去甲基化与沉默基因的重新激活相关。甲基化和去甲基化的 CpG 岛能够招募不同的 DNA 结合蛋白，动态调节染色质的结构与转录活性。

28.2.4 5mC 影响基因表达的分子机制

通过吸引或排斥 DNA 结合蛋白。5 位甲基位于 DNA 双螺旋的大沟内 (major groove)，许多 DNA 结合蛋白在这里与 DNA 结合。

基因组印记 (genomic imprinting)

因为等位基因来源于不同亲本而使其表达模式发生改变的现象称为**印记** (imprinting)。它有两个特点：①子代的两个等位基因中有一个发生沉默, 即不表达；②哪一个等位基因沉默取决于等位基因的亲本来源。

28.3.1 小鼠 *Igf2* 基因印记

老鼠类胰岛素生长因子 *Igf2* 的基因突变纯合子表现为侏儒症。杂合子中, 如果突变等位基因来自父亲, 表型异常 (显性)。如果来自母亲, 表型正常, 即母源 *Igf2* 基因在子代被抑制 (隐性)。

这是在哺乳动物中最早发现的表观遗传现象。

一、*Igf2* 基因印记的调控

Igf2 基因印记的调控受甲基化对增强子作用的抑制所决定。

母源染色体: 绝缘子未被甲基化 (有 CTCF 结合), 因此可以屏蔽增强子的作用, *Igf2* 基因不表达。

父源染色体: 绝缘子被甲基化导致 CTCF 无法结合, 因此不能屏蔽增强子的作用, *Igf2* 基因表达 (Ratajczak et al., *Leukemia*, 2013)。

去甲基化

DNA 去甲基化有两种方式, 主动去甲基化与被动去甲基化: ①**主动去甲基化**为间接脱甲基, 通过错配切除修复路线更换非甲基化胞嘧啶。②**被动去甲基化**不需酶参与, 只涉及维持甲基化酶的表达量。随着细胞的不断分裂, 维持甲基化酶被逐渐稀释, 最终导致新合成的 DNA 不再甲基化。

28.4.1 哺乳动物基因组程序化周期

哺乳动物全生育期有一个周期性的甲基化和去甲基化循环。受精后直到胚胎植入子宫前, 基因组经历全面去甲基化。胚胎植入子宫后, 开始重新甲基化。当胚胎原生殖细

胞 (primordial germ cells, PGCs) 形成时 (约在胚胎形成的 E8.5-11.5 期), 全基因组去甲基化。待配子形成后, 又开始重新甲基化, 一直持续到受精后。

28.4.2 5mC 羟甲基化介导的去甲基化机制

5mC 被 TET 氧化为 5fC 或者 5caC, 随后被 TDG 识别并切除, 之后经过 BER 过程修复为未被修饰的 C (Kohli R M, Zhang Y. *Nature*, 2013)。

甲基化 DNA 测序

甲基化 DNA 测序又称为亚硫酸氢盐测序 (Bisulfite sequencing), 其原理是基于亚硫酸氢盐如亚硫酸氢钠 (Sodium bisulfate) 处理 DNA 时可将未甲基化胞嘧啶 (5C) 转变为尿嘧啶 (U), 而甲基化胞嘧啶 (5mC) 不受影响。随后将处理的 DNA 片段和未处理的 DNA 片段分别扩增和平行测序。因脱氨基胞嘧啶转变为尿嘧啶可与 A 配对, 5mC 仍然与 G 配对。将两组平行测序结果比较, 即可发现甲基化胞嘧啶位置。

亚硫酸氢盐测序技术目前已用于全基因组测序, 但仍存在一些技术问题: ①测序片段较短, 降低可读序列的复杂性; ②亚硫酸氢盐处理可引起 DNA 片段降解, 需要大量样品和沿革的纯化步骤除去亚硫酸氢盐; ③需要多次重复实验才可排除假阳性。

第三节 组蛋白修饰与其他表观遗传效应


花斑型位置效应 (position effect variegation, PEV) 是一种遗传突变, 源于果蝇染色体重排, 影响到眼睛颜色基因的表达模式, 由 Muller HJ 于 1930 年发现。当某一基因由于染色体重排从原来的常染色质区移到异染色质区附近, 因异染色质的扩散效应, 造成基因表达的改变。这种抑制效应的差别使基因表达受抑程度不同, 由此产生嵌合。

真核生物染色体

真核生物染色体的结构单位为核小体, DNA 缠绕在核小体上, 组成染色质纤丝。经过 4 次压缩, 基因组 DNA 的长度压缩了 8400 倍, 构成染色体。细胞间期染色质螺旋结构松散, 呈网状或斑块状。浓集状态的染色质称异染色质; 分散状态的染色质称常染色质。

由于 DNA 缠绕在核小体上，转录调控因子难以接触 DNA。因此在基因表达时，缠绕在核小体上的 DNA 必须伸展便于转录因子识别与结合。

29.1.1 染色质构象与基因表达



基因表达时转录因子必须与基因调控元件结合，以便在启动子区组装转录起始复合物。这就要求染色质结构松弛，缠绕在核小体上的启动子 DNA 处在伸展状态。当基因表达结束时，转录装置则必须离开调控区，DNA 回复到与核小体紧密结合的状态。

29.1.2 细胞的遗传记忆

多细胞生物是由不同的属性细胞组成的。虽然多细胞生物个体的发育来自同一个受精卵，但在生长与发育过程中，伴随着细胞的分化和组织器官的形成。细胞的属性决定于细胞中基因组程序化的表达模式，即有些基因开放，有些基因关闭。

细胞中基因组程序化的表达模式在同一类细胞中是可以传递的，被称为遗传记忆。细胞属性的传递不是简单的基因组 DNA 的复制，而是基因表达模式的传递，即表观遗传。

基因组中基因表达模式的改变或传递均与染色质的结构状态有关：处于松弛或开放状态的染色质，位于其中的基因表现活性；处于收缩或沉默状态的染色质，位于其中的基因完全关闭。

因此细胞属性的遗传记忆直接与染色质的构型状态有关，染色质状态的改变称之为**染色质重建或重塑** (chromatin remodeling), 是表观遗传的核心之一。

核小体组蛋白与基因调控

H2B, H3 和 H4 的 α 螺旋结构具偶极子特点, 在接触 DNA 一侧积累了纯正电荷, 可与带负电荷的 DNA 磷酸骨架互作。此外 H3 和 H4 的 N 端尾部肽链可分别插入围绕在外的 DNA 分子的两个小沟中。

1988 年 Kayne PS 等首次报道, 组蛋白 H4 对酵母生长与抑制沉默结合座位是必需的, 而转录激活因子可解除 H4 的抑制。由此开始, 人们开始改变了关于组蛋白只是一种单纯的机械结构成分的看法。

染色质重建或重塑主要涉及核小体重排, 与组蛋白的修饰状态有关。组蛋白的修饰主要是尾部肽链氨基酸的化学修饰, 包括: ①**甲基化**: 如组蛋白 3(H3) 和组蛋白 4(H4)N 端多肽链赖氨酸 (K) 和精氨酸 (R) 的单甲基化 (me1), 双甲基化 (me2) 和三甲基化 (me3); ②**乙酰基化**: 主要是 H3 和组 H4 的 N 端多肽链赖氨酸 (K) 的乙酰化; ③**磷酸化**: 主要是丝氨酸 (S) 的磷酸化; ④**泛素化**: 主要是 H2A 和 H2B 的赖氨酸 (K) 泛素化; ⑤**SUMO**(Small Ubiquitin-like Modifier, SUMO): 一种类似泛素的小蛋白质, 可修饰赖氨酸 (K)。

29.2.1 组蛋白修饰位点及专一性修饰酶

组蛋白修饰位置主要在 N-端, 修饰位点大多分布在**赖氨酸**和**精氨酸**位置。乙酰化和甲基化修饰具有**可逆性**特点, 不同位点的化学修饰由**专一性修饰酶**执行。

29.2.2 组蛋白修饰的生物学意义

目前已知, 与基因表达调控有关的涉及染色质状态的组蛋白修饰主要是甲基化和乙酰化:

①**甲基化**。赖氨酸和精氨酸的甲基化主要是提供一个可被识别的标记, 被称为**表观遗传密码**。以便其它修饰因子可以此作为靶点促使染色质状态的改变, 导致基因的活化或关闭。

②**乙酰化**。组蛋白赖氨酸乙酰化修饰使赖氨酸残基正电荷减少, 从而使原本带正电荷的组蛋白赖氨酸与缠绕其上的 DNA 互作弱化。直接后果是**染色质结构松弛**, 便于转录激活因子接触 DNA, **基因激活**。

③**磷酸化**。组蛋白磷酸化的位点主要在丝氨酸。磷酸化可增加组蛋白的负电荷, 改变组蛋白与 DNA 的互作。

29.2.3 组蛋白密码

- ①增强子 (enhancer) 常富集 H3K4me1, 活化的增强子还伴随 H3K27ac;
- ②启动子 (promoter) 的活跃状态以 H3K4me3 为特征;
- ③转录活跃的基因体 (gene body) 富集 H3K36me3, 与转录延伸相关。

相反, 带有 H3K9me3 或 H3K27me3 的启动子通常处于抑制或沉默状态, 即使基因体可能存在 H3K36me3, 也无法启动转录。

座位控制区 (locus control region, LCR)

一段可以调控与其连锁的常染色质区域表达活性的 DNA 区段。其功能是以顺式 (cis-) 方式调控与其连锁的基因表达, 第一个 LCR 首先在人类 β -球蛋白基因座位区发现 (Blood, 100:3077-3086, 2002), 位于该基因簇上游约 16kb, 可控制整个基因簇的开放与关闭, 但每个基因仍有各自独立的增强子。

绝缘子与 3D 基因组

①1985 年, Udvardy 等在果蝇染色体 87A7 条带**热激蛋白基因座**的**两侧**发现了两段取名为 scs 和 scs' (特异染色质结构) 的顺序。scs 和 scs' 长分别为 350 bp 和 200 bp, 对 **DNAase I 有高度抗性**。这两个序列的两侧均有 DNAase I 超敏位点, 各为 100 bp;

②将 scs 置于控制眼睛颜色的基因两侧然后导入果蝇, 转化的果蝇品系不管转基因位于何处, 均可产生类似表型, 说明 scs 可使转基因免受内源染色质位置影响;

③这种可以**阻止邻近位置激活或失活效应**的 DNA 顺序称为绝缘子 (insulator) 或隔离子。

29.4.1 绝缘子的三种特性

①真核生物增强子具有双向作用, 超长距离功能, 从而带来位置相邻基因之间的彼此干扰问题。**绝缘子**插在增强子和启动子之间, 可**阻止相邻基因调控干扰**。

②有些基因位于异染色质邻近, 会受到抑制效应的干扰。绝缘子可**阻止异染色质效应的扩散**。

③绝缘子还有一种内在的功能，即在三维水平使**染色质环化**，促使远距离的调控因子互作。

29.4.2 染色质环挤出模型 (loop extrusion model)

增强子可以通过染色质环与远距离（可达 ~1 Mb）的基因启动子发生相互作用，从而激活转录。但当绝缘子序列存在并被 CTCF 蛋白结合时，环挤出过程在该位置被阻断，增强子无法跨越绝缘子去作用于下游基因。CTCF 标记的绝缘子往往形成 **TAD**（拓扑关联结构域）边界，将基因组划分为相互独立的调控单元，使增强子-基因作用被限制在同一 TAD 内。

29.4.3 3D 基因组

一共有四种不同的级别。

①**染色体疆域** (Chromosome territory)：每条染色体在细胞核中占据相对独立的空间区域，彼此较少混合。

②**染色质区室** (A/B compartment)：染色体内部进一步分为 A 区（转录活跃、开放染色质）和 B 区（转录抑制、靠近核纤层）。

③**拓扑关联结构域** (TAD / sub-TAD)：在区室内形成局部自相互作用的结构单元，增强子和启动子主要在同一 TAD 内发生作用。

④**长程相互作用/染色质环**：由 cohesin 介导、CTCF 定位的染色质环，将增强子与启动子拉近，实现精确的基因调控。